

# modenanalyse\_\_2fe2s

Version 1.2.3

---

## Handbuch und theoretische Dokumentation

---

Mode-aufgelöste Bindungs-Reorganisations-Analyse  
von [2Fe-2S]-Eisen-Schwefel-Proteinen  
aus Gaussian-16- und ORCA-6-Frequenzrechnungen

Lukas Knauer  
AG Schünemann  
RPTU Kaiserslautern-Landau

- Cluster-Typ:** [2Fe-2S], reduziert oder oxidiert,  
für Rieske-, Ferredoxin- und mitoNEET-artige Liganden
- Input:** Gaussian-16 `.log` (`freq=hpmodes` bevorzugt;  
Standard-Block als Fallback) oder ORCA-6 `.hess`  
PDB-Datei mit gleichem Cluster (optional, aber empfohlen)
- Output:** Excel-Reports (Modenanalyse, SCSD,  
Reorganisations-Energien, Modulations-Spektren,  
UMAP-Cluster), Befund (Plain-Text), Plots (PNG)
- Externe Pakete:** `numpy`, `scipy`, `pandas`,  
`matplotlib`, `openpyxl`,  
`scikit-learn`, `umap-learn`,  
`hdbscan`, `scsdpy`
- Referenzen:** Marcus, *J. Chem. Phys.* **24**, 966 (1956)  
Marcus, *Angew. Chem. Int. Ed. Engl.* **32**, 1111 (1993)  
Hammes-Schiffer & Soudackov,  
*J. Phys. Chem. B* **112**, 14108 (2008)  
Huang & Rhys,  
*Proc. R. Soc. Lond. A* **204**, 406 (1950)  
Kingsbury & Senge, *Chem. Sci.* **15**, 13638 (2024)
- Lizenz:** GNU General Public License v3.0 oder später  
(`GPL-3.0-or-later`, siehe LICENSE)
- Copyright:** © 2026 Lukas Knauer,  
AG Schünemann, RPTU Kaiserslautern-Landau

## Inhaltsverzeichnis

|                                                                         |           |
|-------------------------------------------------------------------------|-----------|
| <b>Foreword (English)</b>                                               | <b>7</b>  |
| <b>I Einführung und Theorie</b>                                         | <b>8</b>  |
| <b>1 Einführung</b>                                                     | <b>8</b>  |
| 1.1 Was <code>modenanalyse_2fe2s</code> liefert . . . . .               | 8         |
| 1.2 Voraussetzungen . . . . .                                           | 10        |
| 1.3 Konventionen in diesem Handbuch . . . . .                           | 10        |
| <b>2 Theoretische Grundlagen</b>                                        | <b>10</b> |
| 2.1 Normalmoden aus Gaussian: <code>hpmodes</code> -Format . . . . .    | 10        |
| 2.2 Unsicherheits-Propagation . . . . .                                 | 12        |
| 2.3 Migrationshinweise zu v1.0.4 . . . . .                              | 13        |
| 2.4 OOP/INP-Klassifikation . . . . .                                    | 15        |
| 2.5 Fe-Ligand-Bindungs-Zerlegung: Stretch, Bend INP, Bend OOP . . . . . | 18        |
| 2.6 SCSD nach Kingsbury & Senge . . . . .                               | 20        |
| 2.7 Heuristische Kern-Klassifikation . . . . .                          | 23        |
| 2.8 Embeddings: UMAP und HDBSCAN . . . . .                              | 24        |
| 2.9 Marcus-Hush-Theorie der Reorganisation . . . . .                    | 29        |
| 2.10 Huang-Rhys-Theorie und unser $\lambda_X$ . . . . .                 | 32        |
| 2.11 NRVS-Theorie soweit relevant für Bandenidentifikation . . . . .    | 35        |
| 2.12 Mode-aufgelöste Bindungs-Reorganisations-Energien . . . . .        | 37        |
| 2.13 HP/Standard-Frequenz-Konsistenzcheck . . . . .                     | 42        |
| <b>Referenzen</b>                                                       | <b>44</b> |
| <b>II Anwendung</b>                                                     | <b>44</b> |
| <b>3 Konfiguration</b>                                                  | <b>44</b> |
| 3.1 Beispiel-Konfiguration . . . . .                                    | 44        |
| 3.2 Vollständige Parameter-Referenz . . . . .                           | 44        |

|          |                                                                                                 |           |
|----------|-------------------------------------------------------------------------------------------------|-----------|
| 3.3      | Eingabe und Ausgabe . . . . .                                                                   | 46        |
| 3.4      | Frequenzbereich und Fenster . . . . .                                                           | 46        |
| 3.5      | Thermik . . . . .                                                                               | 47        |
| 3.6      | Cluster-Erkennung . . . . .                                                                     | 48        |
| 3.7      | Fe-Liganden-Erkennung (PDB-basiert) . . . . .                                                   | 48        |
| 3.8      | OOP/INP-Klassifikation . . . . .                                                                | 48        |
| 3.9      | SCSD und Sekundärstruktur . . . . .                                                             | 48        |
| 3.10     | PCET / Marcus-Hush-Reorganisation . . . . .                                                     | 49        |
| 3.11     | Numerische Parameter . . . . .                                                                  | 49        |
| 3.12     | Embeddings (UMAP) . . . . .                                                                     | 50        |
| 3.13     | Sonstiges . . . . .                                                                             | 51        |
| 3.14     | Validierungsregeln . . . . .                                                                    | 51        |
| <b>4</b> | <b>Workflow-Beispiele</b>                                                                       | <b>51</b> |
| 4.1      | Wie startet man einen Lauf? . . . . .                                                           | 51        |
| 4.2      | Szenario A: Einzelnes Cluster (Standard-Anwendung) . . . . .                                    | 53        |
| 4.3      | Szenario B: Multi-Cluster-System (Dimere und mehr) . . . . .                                    | 54        |
| 4.4      | Szenario C: WT-vs.-Mut-Vergleich (PCET-Validierungs-Test) . . . . .                             | 56        |
| 4.5      | Szenario D: Vollständig durchgearbeitetes Beispiel (Cys <sub>4</sub> -Modell-Cluster) . . . . . | 58        |
| <b>5</b> | <b>Ausgabe-Sheets</b>                                                                           | <b>63</b> |
| 5.1      | Hauptauswertungs-Excel: Modenbezogene Sheets . . . . .                                          | 63        |
| 5.2      | Hauptauswertungs-Excel: Liganden- und Strukturbezug . . . . .                                   | 64        |
| 5.3      | Hauptauswertungs-Excel: Sekundärstruktur und Embeddings . . . . .                               | 65        |
| 5.4      | Hauptauswertungs-Excel: Lauf-Metadaten . . . . .                                                | 65        |
| 5.5      | Plain-Text-Befund . . . . .                                                                     | 66        |
| <b>6</b> | <b>Modul-Übersicht</b>                                                                          | <b>66</b> |
| 6.1      | Datenfluss . . . . .                                                                            | 67        |
| <b>7</b> | <b>Validierung und UMAP – Anwendungshinweise</b>                                                | <b>68</b> |
| 7.1      | Reproduzierbarkeit (Seed-Test) . . . . .                                                        | 68        |
| 7.2      | Z-Scores, Fisher-F und der Diskriminanz-Score . . . . .                                         | 68        |

|            |                                                                        |           |
|------------|------------------------------------------------------------------------|-----------|
| 7.3        | Sinnvolle Cluster? . . . . .                                           | 71        |
| 7.4        | Vergleich verschiedener Systeme im Embedding . . . . .                 | 71        |
| <b>8</b>   | <b>Fehlerbehebung</b>                                                  | <b>71</b> |
| 8.1        | Installation . . . . .                                                 | 71        |
| 8.2        | Lauf-Fehler . . . . .                                                  | 72        |
| 8.3        | Output und Excel . . . . .                                             | 73        |
| 8.4        | Performance . . . . .                                                  | 73        |
| <b>9</b>   | <b>Lizenz und Zitierung</b>                                            | <b>74</b> |
| 9.1        | Lizenz . . . . .                                                       | 74        |
| 9.2        | Zitierung . . . . .                                                    | 75        |
| 9.3        | Beitrag und Issue-Tracker . . . . .                                    | 75        |
| <b>10</b>  | <b>Validierung an [2Fe-2S]-Modell-Clustern und Proteinen</b>           | <b>75</b> |
| 10.1       | Ebene 1: Modell-Matrix . . . . .                                       | 75        |
| 10.2       | Ebene 2: Vollständiges Protein-System (mitoNEET H87C, QM/MM) . . . . . | 77        |
| 10.3       | Ausblick: Cys <sub>3</sub> His-Wildtyp-Validierung . . . . .           | 79        |
| 10.4       | Erfolgskriterien des Validierungs-Tests . . . . .                      | 80        |
| <b>III</b> | <b>Anhänge</b>                                                         | <b>80</b> |
| <b>A</b>   | <b>Mathematische Notation und Konventionen</b>                         | <b>80</b> |
| A.1        | Skalare, Vektoren, Matrizen, Tensoren . . . . .                        | 81        |
| A.2        | Indizes . . . . .                                                      | 81        |
| A.3        | Einheiten-Konventionen . . . . .                                       | 81        |
| A.4        | Vorzeichen-Konventionen . . . . .                                      | 82        |
| A.5        | Summen-, Produkt- und Erwartungswert-Konventionen . . . . .            | 82        |
| A.6        | Notation für algorithmische Schritte . . . . .                         | 83        |
| <b>B</b>   | <b>Symbolverzeichnis</b>                                               | <b>83</b> |
| B.1        | Lateinische Buchstaben . . . . .                                       | 84        |
| B.2        | Griechische Buchstaben . . . . .                                       | 85        |
| B.3        | Sonderzeichen und Abkürzungen . . . . .                                | 86        |

|          |                                                                     |           |
|----------|---------------------------------------------------------------------|-----------|
| <b>C</b> | <b>Glossar</b>                                                      | <b>86</b> |
| <b>D</b> | <b>Algorithmus-Pseudocodes</b>                                      | <b>91</b> |
| D.1      | Cluster-Erkennung . . . . .                                         | 91        |
| D.2      | Cluster-Normale via SVD . . . . .                                   | 93        |
| D.3      | Kabsch-Alignment (PDB $\leftrightarrow$ Gauss) . . . . .            | 93        |
| D.4      | Mode-Loop mit thermischer Skalierung . . . . .                      | 94        |
| D.5      | Reorg-Aggregation pro Mode . . . . .                                | 95        |
| D.6      | HA-Reaktionskoordinaten-Berechnung . . . . .                        | 95        |
| D.7      | Modulations-Spektrum und kumulative Reorg-Kurve . . . . .           | 96        |
| D.8      | HDBSCAN-Clusterung des Embeddings . . . . .                         | 97        |
| <b>E</b> | <b>Excel-Sheet-Vollreferenz</b>                                     | <b>98</b> |
| E.1      | Hauptauswertungs-Workbook (*_analysis.xlsx) . . . . .               | 98        |
| E.2      | Embeddings-Workbook (*_analysis_Embeddings.xlsx) . . . . .          | 102       |
| E.3      | Interpoliertes-pDOS-Workbook (*_analysis_interp0.05.xlsx) . . . . . | 103       |
| E.4      | Sekundärstruktur-Workbook (*_analysis_SSE.xlsx, optional) . . . . . | 103       |

## Foreword (English)

**Note for English-speaking readers:** This manual is written in German, reflecting the package's origin in a German-speaking research group at RPTU Kaiserslautern-Landau. A full English translation is planned for a future release.

The English-language entry points to this software are:

- `README.md` – complete English overview, installation instructions, quick start, and output structure description.
- `CHANGELOG.md` – English release notes for v1.0.0.
- `CONTRIBUTING.md` – English contribution guidelines.
- Source-code public API (function signatures, class fields): all identifiers are in English.
- Command-line interface (`modenanalyse-2fe2s -help`): all option help texts are in English.

The internal documentation (this manual + most source-code docstrings and inline comments) remains in German for now. Public English documentation covers the API surface that external users need; this manual goes much deeper into theory, validation and implementation details for German-speaking users (typical audience: graduate students and postdocs in a German-speaking biophysics group).

For citation, see `CITATION.cff` (English).

## Teil I

# Einführung und Theorie

## 1 Einführung

`modenanalyse_2fe2s` ist ein wissenschaftliches Python-Werkzeug zur Auswertung von Normalmoden in DFT-Frequenzrechnungen (`freq=hpmodes`) von Eisen-Schwefel-Proteinen mit [2Fe-2S]-Cluster. Es kombiniert geometrische Klassifikation, strenge Symmetriezerlegung und nuklear-inelastische Streuung (NIS) in einem einheitlichen Workflow. Anwendungsfelder sind Mechanismus-Studien zu Proton-gekoppeltem Elektronen-Transfer (PCET), Vergleich von Rieske- und Ferredoxin-artigen Systemen sowie Mutations-Effekte (z. B. HH→CC).

### 1.1 Was `modenanalyse_2fe2s` liefert

Das Werkzeug fokussiert sich auf die strukturelle Analyse von Schwingungsmoden in DFT-Frequenzrechnungen von [2Fe-2S]-Clustern. Die Hauptergebnisse pro Mode sind:

- **Cluster-spezifische Klassifikation:** Erkennung des [2Fe-2S]-Kerns, Klassifikation jeder Mode nach Out-of-plane / In-plane-Charakter, Symmetriezerlegung in  $D_{2h}$ -Irreps.
- **Liganden-Auflösung:** PDB-basierte Erkennung koordinierender His-, Cys-, Asp/Glu-Reste; Fe-N-, Fe-S- und Fe-O-Streckkennzahlen pro Mode.
- **Marcus-Hush-Reorganisationsenergien:** pro Mode  $\Delta r_X$  und  $\lambda_X$  fuer die Bindungskanaele FeFe, FeN, FeS, NH und HA. System-Aggregate (Total-Reorg, Modulations-Spektren, kumulative  $\Lambda_X(\omega)$ ) fuer die Banden-Identifikation extern in Origin.
- **Multi-Cluster-Unterstützung:** Erkennung mehrerer [2Fe-2S]-Cluster im selben System (z. B. Glutaredoxin-Dimer) und parallele Auswertung als First-Class-Feature.
- **Embeddings** (UMAP, HDBSCAN-Clustering): zweidimensionale Projektion des Mode-Featureraums zur explorativen Analyse.
- **ORCA-Support** (eigenständiger `.hess`-Parser): Mode-Analyse direkt aus ORCA-Frequenzrechnungen.

NIS-Spektren, Fe-pDOS, Lamb-Mößbauer-Faktor und Fe-projizierte Thermodynamik sind *nicht* Teil dieses Pakets. Diese Größen lassen sich aus derselben DFT-Frequenzrechnung mit spezialisierten Werkzeugen separat berechnen.



**Changelog-Höhepunkte seit v1.0.0.** Diese Manual-Ausgabe beschreibt das Paket im Stand v1.2.3 (vollständige Liste in `CHANGELOG.md`). Inhaltliche Änderungen seit v1.0.0:

- **v1.0.2:** Bugfix in `_build_group_map` – verhindert stille Nullzeilen in den `Groups_OOP/INP/Tors`-Blättern, wenn Residuennummern mit Nicht-Protein-Einträgen überlappen (z. B. HOH-Wasser). Für Proteinsysteme mit Lösungsmittelresiduen ist mindestens v1.0.2 erforderlich.
- **v1.0.3:** neue Diagnose-Ausgaben – das `Coordination`-Blatt dokumentiert die Ligand- und Gruppen-Atomzuordnung (§E.1); zwei zusätzliche UMAP-Einbettungen (SSE-UMAP und Ca-UMAP) zielen auf Protein-Domänenmoden bzw. räumlich lokalisierte Moden (§E.2, §E.2).
- **v1.0.4:** auditgetriebene Korrekturen der Unsicherheits-Fortpflanzung (§2.3). Werte unverändert; die `s_*`-Spalten für N-H-Stretches, SSE-Element-Amplituden und SCSD-Amplituden ändern ihre Größenordnung. Halb-offene Fenstergrenzen und defensive Warnmeldungen sind ebenfalls Teil dieses Release.
- **v1.0.5:** physikalische Korrekturen der Sekundärstrukturelement-Analyse – die SSE-UMAP-Features `bending_*` (stets Null) wurden durch die tatsächlichen `lateral_*`-Schlüssel ersetzt; `tilting_angle` ist jetzt eine echte Starrkörper-Kippung; `com_amplitude` (je Element und für den Clusterkern) ist massengewichtet; und die SSE-Hauptachse stammt aus dem  $\alpha$ -Rückgrat. Die SSE-Blätter und ihr UMAP ändern sich, betroffene Systeme also einmal neu ausführen; der SSE-UMAP-Featuresatz wurde zudem auf eine dekorrelierte Fünf-Metrik-Auswahl reduziert.
- **v1.1.0:** die Abkürzung *SS* (Sekundärstruktur) wurde projektweit zu *SSE* umbenannt – Sheet-Namen, der Ausgabedateiname (`*_analysis_SSE.xlsx`), Konfigurationsschlüssel und Funktionsnamen. Das behebt die Mehrdeutigkeit mit Disulfid (S–S) und entspricht der üblichen Bezeichnung *secondary structure element*. Alte TOML-Schlüssel (`analyze_ss`, `ss_chain`) werden weiterhin akzeptiert.
- **v1.2.0:** Kritik-Review-Release. Multi-Cluster-Läufe brechen nicht mehr beim ersten fehlschlagenden Cluster den ganzen Prozess ab; die SCSD-Symmetriezerlegung (die gegen das veröffentlichte `scsdp` still ausgefallen war) ist wiederhergestellt; die PCET-Wasserstoffbrücken-Erkennung erhält ein D–H···A-Winkelkriterium ( $\geq 120^\circ$ ) und eine korrigierte Akzeptor-Abstandsgewichtung; die His-Protonierung ist auf das richtige Residuum beschränkt; die Kabsch-Ausrichtung nutzt elementgematchte Anker mit RMSD-Akzeptanzschwelle; und die Massengewichtung verwendet die QM-eigenen Atommassen. Mehrere dieser Punkte ändern das numerische Ergebnis, betroffene Systeme also einmal neu ausführen und die Kennzahlen neu validieren. Ein im Standardlauf ausgeführter Regressionstest fixiert  $\Lambda_{\text{FeFe}}/\Lambda_{\text{FeS}}$  für das Referenzsystem.
- **v1.2.1:** Die reduzierten ORCA-Massen werden als  $\mu_k = \sum_i m_i |l_{i,k}|^2$  rekonstruiert (verifiziert an realen ORCA-`.hess`-Dateien und übereinstimmend mit der Gaussian-“Red. mass”-Konvention) und ersetzen einen 1.0-amu-Platzhalter, der die absoluten ORCA-Amplituden um  $\sqrt{\mu}$  zu groß machte. Der Gaussian-Pfad bleibt unverändert.
- **v1.2.2:** Das Interpolationsraster von `*_analysis_interp##.xlsx` und `*_analysis_SSE_interp##.xlsx` umfasst jetzt exakt den angeforderten Frequenzbereich, statt auf [erste Mode – `interp_edge_extend`, letzte Mode + `interp_edge_extend`] beschnitten zu werden. Eine fehlende `freq_min` bedeutet

## 1.2 Voraussetzungen

- Python  $\geq 3.11$  mit `numpy`, `scipy`, `openpyxl`, `matplotlib`, `pandas`, `scikit-learn`, `umap-learn`, `hdbscan`, `scsdpy`. Alle werden *automatisch* über das Wheel installiert.
- Eine **Gaussian-16-Logdatei** aus einer `freq=hpmodes`-Rechnung des optimierten Clusters (mindestens vier optimierte Schweratome: zwei Fe und zwei brückende S) **oder** eine **ORCA-6 .hess-Datei**.
- Optional: **PDB-Datei** mit dem gleichen Cluster, für Liganden-Auflösung und Sekundärstruktur-Analyse.

## 1.3 Konventionen in diesem Handbuch

- **Achsen:** Wo immer möglich wird die kanonische Cluster-Orientierung verwendet:  $\hat{\mathbf{x}}$  entlang Fe-Fe,  $\hat{\mathbf{y}}$  entlang S-S,  $\hat{\mathbf{z}} = \hat{\mathbf{n}}$  als Cluster-Normale. Das ist konsistent mit der SCSD-Referenzgeometrie (siehe §2.6).
- **Einheiten:**  $\text{cm}^{-1}$  für Frequenzen, Å für Längen, AMU für Massen, meV für Energien, Kelvin für Temperaturen. Für Boltzmann-Faktoren wird  $1/k_{\text{B}} = 11.6048 \text{ K/meV}$  verwendet.
- **Heuristisch vs. rigoros:** Wo eine Größe aus einer Heuristik abgeleitet wird (z. B. die Bewegungsmuster-Scores Breathing, Hinge, ...), ist sie explizit als *heuristisch* ausgewiesen. Strenge Symmetriezerlegung kommt aus SCSD.

**Lese-Tipp.** Wer das Programm zum ersten Mal benutzt, sollte §1 und §3 lesen und mit dem Beispiel in §4 starten. Die theoretischen Kapitel §2 können bei Bedarf vertieft werden, sind aber für den Routine-Einsatz nicht zwingend.

# 2 Theoretische Grundlagen

## 2.1 Normalmoden aus Gaussian: hpmodes-Format

Eine DFT-Frequenzrechnung in Gaussian-16 liefert nach erfolgreicher Geometrieoptimierung die zweite Ableitung der Energie nach den kartesischen Atomkoordinaten – die mass-gewichtete Hesse-Matrix  $\mathbf{F}$ . Diagonalisierung von  $\mathbf{F}$  liefert die Eigenvektoren  $\mathbf{L}$  und Eigenwerte  $\omega_l^2$  der Normalschwingungen [11]:

$$\mathbf{F} \mathbf{L}_l = \omega_l^2 \mathbf{L}_l, \quad l = 1, \dots, 3N - 6 \quad (1)$$

mit  $N$  als Zahl der Atome im Cluster (genauer: dem optimierten Modell-Bereich). Die kartesischen Verschiebungen pro Atom  $i$  in Mode  $l$  erhält man durch Demassengewichtung [11]:

$$\mathbf{e}_{l,i} = \frac{1}{\sqrt{m_i}} \mathbf{L}_{l,i}, \quad (2)$$

wobei  $m_i$  die atomare Masse von Atom  $i$  ist.

### HP-Block versus Standard-Block

Mit dem Schlüsselwort `freq=hpmodes` schreibt Gaussian die Eigenvektoren in einem zweiten Block (*High-Precision Modes*) mit fünf Nachkommastellen aus. Der *Standard-Block* dagegen verwendet zwei Nachkommastellen und ist für sehr kleine Verschiebungen (z. B. Modes unter  $100 \text{ cm}^{-1}$  in großen Systemen) unzureichend.

`modenanalyse_2fe2s` liest beide Blöcke. Die HP-Eigenvektoren werden bevorzugt; nur wenn ein einzelner HP-Block fehlt (selten, z. B. bei Versionsmischung im Logfile), greift der Reader auf den Standard-Block zurück. Diese Fallback-Logik ist in `logio.read_blocks` implementiert.

### Konsistenzcheck zwischen HP und Standard

Beide Blöcke geben die Frequenzen  $\omega_l$  unabhängig aus. `modenanalyse_2fe2s` prüft beim Lauf, ob die HP- und Standard-Frequenzen für dieselben Modennummern übereinstimmen (`logio.check_hp_std_frequencies`). Eine Abweichung  $\Delta\omega \leq 0,01 \text{ cm}^{-1}$  deutet auf:

- einen unvollständig geschriebenen Logfile (Job abgebrochen),
- einen Mismatch zwischen Lese-Offset und tatsächlichem Block-Anfang (z. B. wenn ein Job mit `Restart` fortgesetzt wurde),
- oder eine Verwechslung zweier Logfiles.

Konsistenzfehler werden als Warnung in den Befund geschrieben; das Programm läuft weiter, kennzeichnet die betroffenen Modes aber im Befund.

### Skalierung der Eigenvektoren

Für alle nachfolgenden Auswertungen werden die rohen Gaussian-Eigenvektoren mit der RMS-Amplitude  $u_{\text{rms}}(\omega_l, m_{\text{red}}, T)$  skaliert (`core.compute_thermal_amplitude`) [5, 11]:

$$u_{\text{rms}}(\omega, m_{\text{red}}, T) = \sqrt{\frac{\hbar}{2 m_{\text{red}} \omega} \coth\left(\frac{\hbar\omega}{2k_{\text{B}}T}\right)}. \rightsquigarrow \text{core.compute\_thermal\_amplitude} \quad (3)$$

$m_{\text{red}}$  ist die reduzierte Masse, die Gaussian für jede Mode mitliefert. Bei  $T = 0$  reduziert sich Gleichung (3) zur Nullpunkts-Amplitude  $u_{\text{rms}} = \sqrt{\hbar/(2m_{\text{red}}\omega)}$ .

Die mit  $u_{\text{rms}}$  multiplizierten Eigenvektoren haben Einheit  $\text{\AA}$  und beschreiben die thermisch (oder bei  $T \rightarrow 0$  rein quantenmechanisch) gemittelte Auslenkung pro Mode. Sie sind die Eingabe für sämtliche geometrischen Auswertungen ab §2.4.

## 2.2 Unsicherheits-Propagation

Jede numerische Observable, die das Werkzeug ausgibt (`stretch`, `bend`, `kern_d`, `amplitude_mean`, `hn_stretch`, die SCSD-Amplituden, ...), wird mit einer Begleitunsicherheit versehen (`s_stretch`, `s_bend`, `s_kern_d`, ...). Diese werden in erster Ordnung Gauss-propagiert aus zwei zugrundeliegenden Rauschquellen:

- $\sigma_e := \text{cfg.sigma\_eigvec}$  (Standard  $5 \cdot 10^{-4}$ ): numerisches Rauschen pro Eigenvektor-Komponente, in kartesischen Einheiten des unskalierten Gaussian-Eigenvektors. Steuert die Schwelle “unbedeutender Beitrag” für verschiebungsbasierte Observablen.
- $\sigma_c := \text{cfg.sigma\_coord}$  (Standard  $10^{-3} \text{\AA}$ ): Koordinatenrauschen in  $\text{\AA}$ , für die SCSD-Referenz.

### Konvention: thermisch skaliertes Sigma

Alle geometrischen Observablen verwenden den *thermisch skalierten* Eigenvektor  $\mathbf{e}_{l,i} u_{\text{rms}}(\omega_l)$  mit Einheit  $\text{\AA}$ . Das begleitende Sigma wird mit derselben Skalierung propagiert:

$$\sigma_e^{\text{therm}}(l) = \sigma_e \cdot u_{\text{rms}}(\omega_l), \quad \rightsquigarrow \text{core.analyze\_his\_hn}, \text{core.analyze\_fe\_ligand} \quad (4)$$

so dass das dimensionslose *Signifikanzverhältnis*  $|\text{Observable}| / \sigma$  unter der Wahl von  $u_{\text{rms}}$  invariant ist. Diese Konvention ist essenziell für die Wert/Sigma-Verhältnisse, die in der Farbkodierung der Excel-Blätter verwendet werden.

**Konkrete Beispiele.** Für eine typische Niederfrequenz-Mode mit  $u_{\text{rms}} \approx 0,05 \text{\AA}$ :

- Fe-X-Stretch ( $i = \text{Ligand}$ ,  $j = \text{Fe}$ ):  $|\mathbf{e}_i - \mathbf{e}_j|$  ist eine Differenz zweier unabhängiger Gauss-Rauschkomponenten, also  $\sigma(\text{stretch}) = \sigma_e^{\text{therm}} \sqrt{2} \approx 3,5 \cdot 10^{-5} \text{\AA}$ .
- Bend INP/OOP: gleicher Faktor  $\sqrt{2}$  (Pythagoräische Zerlegung ändert die Rauschausbreitung entlang einer einzelnen Achse nicht), also  $\sigma_{\text{bend\_inp}} = \sigma_{\text{bend\_oop}} = \sigma_e^{\text{therm}} \sqrt{2}$ .
- N-H-Stretch (`analyze_his_hn`, `include_hn_vibration`) folgt derselben Konvention:  $\sigma_{\text{hn}} = \sigma_e^{\text{therm}} \sqrt{2}$ .
- SSE-Element-Amplitude:  $\sigma_{\text{amp}} = \sigma_e^{\text{therm}} \sqrt{N_{\text{atoms}}}$ , wobei das  $\sqrt{N}$ -Wachstum aus der Mittelung über  $N_{\text{atoms}}$  im Sekundärstruktur-Element kommt.
- SCSD-Amplituden: getrennte Sigmas für “Referenz” und “Verzerrung”. Die Referenz ist die statische Geometrie-Unsicherheit  $\sigma_c \sqrt{2}$ , die Verzerrung kombiniert Referenz- und Thermisches Rauschen:  $\sigma_{\text{SCSD,dist}} = \sqrt{2} \sqrt{\sigma_c^2 + (\sigma_e \cdot u_{\text{rms}})^2}$ .

**Änderung in v1.0.4.** Drei dieser Sigma-Propagationen waren zuvor inkonsistent implementiert (§2.3): dem N-H-Stretch fehlte die thermische Skalierung, das SSE-Element verwendete eine fest verdrahtete Konstante statt `cfg.sigma_eigvec`, und SCSD verwendete fest verdrahtete Referenzkonstanten statt `cfg.sigma_coord` und `cfg.sigma_eigvec`. Mit v1.0.4 respektieren alle Sigmas Gleichung 4 und die TOML-Einstellungen `cfg.sigma_eigvec/sigma_coord`.

## 2.3 Migrationshinweise zu v1.0.4

Version 1.0.4 ist ein Bugfix-Release, das die *ausgegebenen Unsicherheiten* einiger Observablen verändert, während die zugrundeliegenden *Werte* unverändert bleiben. Falls Sie v1.0.2- oder v1.0.3-Ergebnisse besitzen (z. B. für ein Paper oder eine Dissertation), bitte vor dem Ziehen von Signifikanz-Schlussfolgerungen diesen Abschnitt lesen.

**Was sich nicht geändert hat.** Alle geometrischen und energetischen Observablen – `stretch`, `bend`, `kern_d`, `lambda_X`, SCSD-Amplituden, `hn_stretch`, SSE-Element `amplitude_mean`, Einbettungs-Koordinaten – liefern *numerisch identische* Werte über v1.0.2, v1.0.3 und v1.0.4 für dasselbe Eingabe-Log. Keine physikalische Interpretation bestehender Werte wird invalidiert.

**Was sich geändert hat.**

- `s_hn_stretch`: skaliert jetzt mit  $u_{\text{rms}}$  (Gl. 4). Für typische Niederfrequenz-Moden ( $u_{\text{rms}} \sim 0,05 \text{ \AA}$ ) macht das `s_hn_stretch` etwa  $20 \times$  **kleiner** als in v1.0.2/v1.0.3. Konsequenz: viele N-H-Stretches, die unter der alten Konvention “unter dem Rauschen” erschienen, sind nun korrekt als signifikante PCET-Signale identifizierbar.
- `s_amplitude_mean` / `s_axial_amplitude` / `s_tilting_angle` ... in `analyze_sse_element`: vor v1.0.4 wurde eine fest verdrahtete Konstante  $1 \cdot 10^{-4}$  statt `cfg.sigma_eigvec` verwendet. Mit dem Standard  $\sigma_e = 5 \cdot 10^{-4}$  sind die neuen Sigmas etwa  $5 \times$  **größer**. Reklassifikation: SSE-Element-Einträge, die unter dem alten Code als “signifikant” markiert waren, können nun als “marginal” erscheinen.
- `s_SCSD_*`: vor v1.0.4 wurden fest verdrahtete Konstanten  $5 \cdot 10^{-7}$  /  $5 \cdot 10^{-6}$  statt `cfg.sigma_coord` und `cfg.sigma_eigvec` verwendet. Neue Sigmas sind etwa  $1000 \times$  **größer**; die vorigen Werte waren physikalisch unplausibel.
- Fenstergrenzen-Behandlung: der Multi-Window-Modus (`freq_windows`) verwendete *abgeschlossen-abgeschlossene* Intervalle  $[lo, hi]$ , sodass eine Mode mit Frequenz exakt auf einer Grenze in *zwei* benachbarten Fenstern erschien. Ab v1.0.4 sind die Grenzen *halb-offen*  $[lo, hi)$ , wobei das letzte Fenster  $[lo, hi]$  bleibt. Praktische Auswirkung: keine bei typischen Float-Frequenz-Rechnungen, aber  $B$ -Faktor und  $\Lambda(\omega_{\text{cut}})$  sind nun garantiert ohne Doppelzählung.
- Defensive Warnmeldungen: einige interne Lookup-Fehler (Fe-Ligand *c2l*-Miss, His-H *c2l*-Miss, fehlender PCET-Acceptor-Index, Null-Zeilen in den Excel-Blättern, mehrdeutige PDB-Gaussian-Atomzuordnungen) waren zuvor stille Durchläufe. Mit v1.0.4 wird für

jeden dieser Fälle bei seinem ersten Auftreten in einem Lauf ein **UserWarning** ausgegeben (pro Session dedupliziert). Falls Sie in einem zuvor stillen Log neue Warnungen sehen, prüfen Sie die betroffenen Liganden- oder Atomzuordnungen, bevor Sie den entsprechenden Excel-Zeilen vertrauen.

- Interpolations-Randanker (FUND 12, vom Anwender gemeldet): wenn `freq_max` gesetzt ist und die nächste Mode oberhalb mehr als `interp_context_cm1` (Standard 5 cm<sup>-1</sup>) entfernt liegt, wurde vor v1.0.4 keine Kontextmode geladen und die interpolierte pDOS fiel knapp unterhalb `freq_max` steil ab. Mit v1.0.4 wird genau *eine* zusätzliche Mode – die nächste oberhalb `freq_max` – als Fallback-Anker geladen, sodass `np.interp` unabhängig von der Modendichte immer einen Randanker hat. Derselbe Fallback wirkt symmetrisch bei `freq_min`. Das Run-Log dokumentiert, wann der Fallback ausgelöst wurde.
- Synthetischer Null-Anker am oberen Rand (FUND 13): wenn keine reale Mode oberhalb `freq_max` existiert (das DFT-Spektrum endet innerhalb des Analysebereichs), fügt v1.0.4 eine *synthetische Null-Mode* bei `freq_max + interp_context_cm1` mit allen Observablen = 0 ein. Das ergibt einen glatten Abfall der interpolierten pDOS über die Pufferzone statt einer Stufe am oberen Rand. Die synthetische Mode ist mit `mode_type = "synthetic_zero"` und `precision = "synthetic"` markiert und trägt per Konstruktion null zu *B*-Faktoren,  $\Lambda_X^{\text{total}}$  und den Modulationsspektren bei.

**Post-Release-Audit-Patches (Mai 2026).** Nach dem v1.0.4-Release identifizierte ein Audit eines realen [2Fe-2S]-Cys<sub>2</sub>His<sub>2</sub>-Batch-Runs (Rieske-Typ in beiden Protonierungszuständen) vier zusätzliche Warn- und Reporting-Probleme. Keines beeinflusst numerische Ausgaben. Vollständige Beschreibungen sind im Supplement (FUND 14–17); in Kürze:

- FUND 14: Die Warnung “**His\_HN NICHT erkannt**” wurde pro deprotoniertem His *zweimal* statt einmal ausgegeben. Behoben durch Verschiebung der Warnung aus der inneren PDB-vs-Gaussian-Fallback-Schleife heraus.
- FUND 15: Für Systeme mit deprotonierten His-Liganden (z. B. Rieske-Typ Cys<sub>2</sub>His<sub>2</sub> im deprotonierten Zustand oder mitoNEET-Typ Cys<sub>3</sub>His nach Deprotonierung) sagte die PCET-Disabled- Meldung “**no His ligands at cluster**”, obwohl `Fe_N_His`-Blätter und `Lambda_FeN` klar belegten, dass His-Liganden vorhanden waren. Der Entscheidungstext unterscheidet jetzt zwischen “keine His überhaupt” und “His vorhanden, aber alle deprotoniert”.
- FUND 16: Die Warnung “**interp\_boundary\_mode='context' but no context modes available**” wurde auch bei Full-Spectrum-Runs ausgegeben (`freq_min/freq_max` beide `None`), wo gar kein Context-Loading versucht wird. Die Warnung wird jetzt nur emittiert, wenn der Benutzer explizit ein Fenster gesetzt hat.
- FUND 17: REPORT.txt zeigte `freq_filter: - - - cm-1`, wenn nur `freq_windows` gesetzt war, und versteckte damit den aktiven Filter vom Audit-Trail. Der Report emittiert jetzt eine zusätzliche `freq_windows: [...]`-Zeile.

**Re-Berechnung vorhandener Daten.** Empfehlung: führen Sie vorhandene TOML-Konfigurationen unter v1.0.4 erneut aus und vergleichen Sie die `s_*`-Spalten von `Fe_S_Cys.xlsx`, `His_HN.xlsx`, `SCSD.xlsx` und die SSE-Element-Blätter. Die Werte sind identisch; nur Sigmas und die Signifikanz-Färbung ändern sich.

## 2.4 OOP/INP-Klassifikation

Eine zentrale Frage für jeden Cluster-Mode lautet: *Wie viel Anteil der Schwingung steht senkrecht zur Cluster-Ebene (out-of-plane, OOP), und wie viel liegt in der Ebene (in-plane, INP)?* Reine Wippbewegungen der vier Cluster-Atome (Umbrella, Hinge) sind OOP-dominiert, während Streckmoden (Fe-Fe, S-S, Atmen) in der Ebene leben.

### Definition der Cluster-Normalen

Sei  $\mathbf{r}_i$  ( $i \in \{\text{Fe}_1, \text{Fe}_2, \text{S}_1, \text{S}_2\}$ ) die Gleichgewichtsposition der vier Cluster-Atome. Die Normalen-Richtung der Ebene ist die Richtung, die die Summe der quadrierten Senkrechtkomponenten minimiert. Konkret aus der Singulärwertzerlegung der zentrierten Cluster-Koordinaten  $\tilde{\mathbf{r}}_i = \mathbf{r}_i - \bar{\mathbf{r}}$  [17]:

$$\tilde{\mathbf{R}} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top, \quad \hat{\mathbf{n}} = \mathbf{V}_{:,3}. \quad \rightsquigarrow \text{geometry.cluster\_normal} \quad (5)$$

Im Code ist das `geometry.cluster_normal`. Per Konvention zeigt  $\hat{\mathbf{n}}$  in  $+\hat{\mathbf{z}}$ -Richtung des Gaussian-Frames, sodass über alle Modes hinweg ein einheitliches Vorzeichen entsteht.

### Anteil der Mode senkrecht zur Ebene

Für Mode  $l$  und ein Atom  $i$  ist die OOP-Komponente die Projektion der Verschiebung auf  $\hat{\mathbf{n}}$  (Standard-Zerlegung, vgl. [7]):

$$\mathbf{e}_{l,i}^{\text{OOP}} = (\mathbf{e}_{l,i} \cdot \hat{\mathbf{n}}) \hat{\mathbf{n}}, \quad \mathbf{e}_{l,i}^{\text{INP}} = \mathbf{e}_{l,i} - \mathbf{e}_{l,i}^{\text{OOP}}. \quad (6)$$

Der *OOP-Anteil* der Mode auf einer Atomgruppe  $G$  ist das Verhältnis der Quadratsummen [7]:

$$\alpha_{\text{OOP}}(G; l) = \frac{\sum_{i \in G} \|\mathbf{e}_{l,i}^{\text{OOP}}\|^2}{\sum_{i \in G} \|\mathbf{e}_{l,i}\|^2} \cdot 100 \% . \quad \rightsquigarrow \text{core.classify\_oop\_inp} \quad (7)$$

**Hinweis zur physikalischen Interpretation.** Gaussians `hpmodes`-Block schreibt *kartesische Verschiebungs-Eigenvektoren*  $\mathbf{e}_{l,i}$  (bereits massen-entzogen via Gl. 2), normiert so, dass  $\sum_i \|\mathbf{e}_{l,i}\|^2 \approx 1$  statt der mass-gewichteten Norm  $\sum_i m_i \|\mathbf{e}_{l,i}\|^2$ . Gleichung 7 misst daher den *geometrischen kartesischen Out-of-Plane-Anteil*: sie sagt, welcher Anteil der quadrierten kartesischen Verschiebungsamplituden aus der Cluster-Ebene zeigt. Sie entspricht *nicht* dem kinetischen-Energie-Anteil der senkrecht zur Ebene fließenden Mode, welcher die mass-gewichtete Form  $\sum_i m_i \|\mathbf{e}_{l,i}^{\text{OOP}}\|^2 / \sum_i m_i \|\mathbf{e}_{l,i}\|^2$  erfordern würde. Für einen [2Fe-2S]-Cluster sind beide Größen numerisch ähnlich (nur Fe und S tragen bei, mit vergleichbaren Massen), aber die Unterscheidung ist wichtig beim Vergleich von  $\alpha_{\text{OOP}}$ -Werten zwischen chemisch verschiedenen Systemen.

## Binäre und feine Klassifikation

Klassisch wird  $\alpha_{\text{OOP}}(G_{\text{Cluster}}; l)$  einer Schwellenprüfung unterzogen:

$$\text{mode\_type}(l) = \begin{cases} \text{OOP}, & \alpha_{\text{OOP}} \geq \theta_{\text{OOP}} \\ \text{INP}, & \alpha_{\text{OOP}} \leq 100\% - \theta_{\text{OOP}} \\ \text{Gemischt}, & \text{sonst} \end{cases} \quad (8)$$

mit Default  $\theta_{\text{OOP}} = 60\%$  (per Config justierbar via `cfg.mode_type_threshold`).

Zusätzlich existiert eine *feine Klassifikation* mit drei Schwellen ( $\theta_1, \theta_2, \theta_3$ ) (`core.classify_oop_inp`). Default (60, 75, 90):

| Stufe                   | Definition                                                                      |
|-------------------------|---------------------------------------------------------------------------------|
| <b>Pur OOP</b>          | $\alpha_{\text{OOP}} \geq \theta_3 = 90\%$                                      |
| <b>Stark OOP</b>        | $\theta_2 \leq \alpha_{\text{OOP}} < \theta_3$ , also 75 – 90 %                 |
| <b>Mehrheitlich OOP</b> | $\theta_1 \leq \alpha_{\text{OOP}} < \theta_2$ , also 60 – 75 %                 |
| <b>Gemischt</b>         | $ \alpha_{\text{OOP}} - 50\%  < \theta_1 - 50\%$                                |
| <b>Mehrheitlich INP</b> | $100\% - \theta_2 < \alpha_{\text{OOP}} \leq 100\% - \theta_1$ , also 25 – 40 % |
| <b>Stark INP</b>        | $100\% - \theta_3 < \alpha_{\text{OOP}} \leq 100\% - \theta_2$ , also 10 – 25 % |
| <b>Pur INP</b>          | $\alpha_{\text{OOP}} \leq 100\% - \theta_3 = 10\%$                              |

Die feine Klassifikation gibt im Excel-Sheet eine präzisere Aussage über den Charakter einer Mode – insbesondere im OOP-Hinge-Bereich, wo eine binäre 60%-Schwelle entweder zu permissiv ist (Modes zwischen 60 und 75 % sehen sehr unterschiedlich aus) oder eine unscharfe Antwort liefert.



**Welche Schwelle für welche Frage?** Für den Vergleich mit NRVS-Spektren in Polarisationsgeometrie liefert die binäre 60 %-Schwelle genügend Trennschärfe. Für Manuskript-Tabellen mit Mode-Eigenschaften (z. B. Symmetrie-Kandidaten für  $D_{2h}$ ) ist die feine 7-Stufen-Klassifikation aussagekräftiger; mit ihr lassen sich die Modes „pur“ OOP / INP zuverlässig identifizieren.

### Worked Example: OOP%-Berechnung an einer Cluster-Atmungsmode

Zur Veranschaulichung berechnen wir  $\alpha_{\text{OOP}}$  explizit für eine hypothetische Cluster-Atmungsmode in einem  $\text{Cys}_4$ -Modell-Cluster.

**Schritt 1 – Geometrie und Cluster-Normale.** Die vier Cluster-Atome sitzen idealisiert bei (Einheit Å):

$$\mathbf{r}_{\text{Fe}_1} = (+1.50, 0.00, 0.00)$$

$$\mathbf{r}_{\text{Fe}_2} = (-1.50, 0.00, 0.00)$$

$$\mathbf{r}_{\text{S}_1} = (0.00, +1.10, 0.00)$$

$$\mathbf{r}_{\text{S}_2} = (0.00, -1.10, 0.00)$$

Schwerpunkt  $\bar{\mathbf{r}} = \mathbf{0}$ . Die zentrierten Koordinaten liegen alle in der  $xy$ -Ebene; SVD liefert  $\hat{\mathbf{n}} = (0, 0, 1)$  (Cluster-Normale parallel zur  $z$ -Achse).

**Schritt 2 – Mode-Eigenvektoren (thermisch skaliert,  $T = 5 \text{ K}$ ).** Eine reine **Atmungs-mode** streckt/staucht beide Fe-S-Diagonalen synchron in der Ebene. Ein typischer thermisch skaliertes Eigenvektor sieht so aus (nach  $\mathbf{e} \rightarrow \mathbf{e} \cdot u_{\text{rms}}$ ):

$$\mathbf{e}_{\text{Fe}_1} = (+0.012, +0.009, 0.000)$$

$$\mathbf{e}_{\text{Fe}_2} = (-0.012, -0.009, 0.000)$$

$$\mathbf{e}_{\text{S}_1} = (0.000, -0.018, 0.000)$$

$$\mathbf{e}_{\text{S}_2} = (0.000, +0.018, 0.000)$$

**Schritt 3 – OOP-Komponenten extrahieren.** Für jedes Atom  $i$ :  $\mathbf{e}_i^{\text{OOP}} = (\mathbf{e}_i \cdot \hat{\mathbf{n}}) \hat{\mathbf{n}}$ . Da alle Eigenvektoren  $z$ -Komponente 0 haben, ist  $\mathbf{e}_i^{\text{OOP}} = \mathbf{0}$  für alle  $i$ .

**Schritt 4 –  $\alpha_{\text{OOP}}$  ausrechnen.**

$$\begin{aligned}\sum_{i \in G} \|\mathbf{e}_i^{\text{OOP}}\|^2 &= 0 \\ \sum_{i \in G} \|\mathbf{e}_i\|^2 &= (0.012^2 + 0.009^2) \cdot 2 + (0.018^2) \cdot 2 \\ &= 2 \cdot 0.000225 + 2 \cdot 0.000324 = 0.001098 \\ \alpha_{\text{OOP}} &= \frac{0}{0.001098} \cdot 100\% = 0\%\end{aligned}$$

Klassifikation: **Pur INP** ( $\alpha_{\text{OOP}} \leq 10\%$ ). Die Cluster-Atmung ist eine in-plane-Mode – wie erwartet.

**Schritt 5 – Vergleich mit Hinge-Mode.** Eine Cluster-Hinge-Mode (das „Buchaufklappen“ der zwei Fe-S-Bonds um eine S-S-Achse) hat dagegen die Form:

$$\begin{aligned}\mathbf{e}_{\text{Fe}_1} &= (0.000, 0.000, +0.020) \\ \mathbf{e}_{\text{Fe}_2} &= (0.000, 0.000, +0.020) \\ \mathbf{e}_{\text{S}_1} &= (0.000, 0.000, -0.020) \\ \mathbf{e}_{\text{S}_2} &= (0.000, 0.000, -0.020)\end{aligned}$$

Hier gilt  $\mathbf{e}_i^{\text{OOP}} = \mathbf{e}_i$  für alle  $i$ , also  $\alpha_{\text{OOP}} = 100\%$  – klassifiziert als **Pur OOP**.

**Schritt 6 – Was im realen DFT-Lauf passiert.** In einem echten Cys<sub>4</sub>- oder Cys<sub>2</sub>His<sub>2</sub>-Cluster sind reine Atmungs- und Hinge-Modes selten – meist mischen sich Komponenten, und  $\alpha_{\text{OOP}}$  liegt zwischen 20 und 80 %. Die Klassifikation nach den Default-Schwellen (60, 75, 90) liefert eine 7-stufige Aufteilung, die etwa für einen typischen [2Fe-2S]-Lauf folgende Verteilung produziert:

- Pur INP:  $\sim 30\%$  der Cluster-Modes
- Mehrheitlich/Stark INP:  $\sim 35\%$
- Gemischt:  $\sim 20\%$
- Mehrheitlich/Stark OOP:  $\sim 12\%$
- Pur OOP:  $\sim 3\%$

(Diese Zahlen variieren stark zwischen Systemen – in starren Cluster- Geometrien dominieren INP-Modes, in flexiblen Liganden-Sphären finden sich mehr Gemischte.)

## 2.5 Fe-Ligand-Bindungs-Zerlegung: Stretch, Bend INP, Bend OOP

Die OOP/INP-Zerlegung aus §2.4 gilt für den *Cluster-Kern* (Fe<sub>1</sub>, Fe<sub>2</sub>, S<sub>1</sub>, S<sub>2</sub>). Eine zweite Zerlegung wird für jede Fe-Ligand-Bindung (Fe-S<sub>Cys</sub>, Fe-N<sub>His</sub>, Fe-O<sub>Asp/Glu</sub>) durchgeführt: die

Relativverschiebung der beiden Bindungspartner wird in eine *Stretch*-Komponente (entlang der Bindungsachse) und eine *Bend*-Komponente (senkrecht dazu) zerlegt, wobei der Bend weiter in INP und OOP relativ zur Cluster-Ebene aufgeteilt wird.

Seien  $\mathbf{e}_{\text{Fe}}$  und  $\mathbf{e}_{\text{Ligand}}$  die thermisch skalierten Verschiebungen des Fe-Atoms und des Ligand-Donor-Atoms, und sei

$$\hat{\mathbf{b}} = \frac{\mathbf{r}_{\text{Ligand}} - \mathbf{r}_{\text{Fe}}}{\|\mathbf{r}_{\text{Ligand}} - \mathbf{r}_{\text{Fe}}\|} \quad (9)$$

der Einheitsvektor von Fe zum Ligand-Donor in der Gleichgewichts- Geometrie. Definiere die Relativverschiebung

$$\Delta \mathbf{e} = \mathbf{e}_{\text{Ligand}} - \mathbf{e}_{\text{Fe}}. \quad (10)$$

**Zerlegung entlang und senkrecht zur Bindung.** Die vorzeichenbehaftete Stretch-Komponente ist die Projektion auf  $\hat{\mathbf{b}}$ , der Bend-Vektor ist der Rest:

$$\Delta r_{\text{stretch}} = \Delta \mathbf{e} \cdot \hat{\mathbf{b}}, \quad \Delta \mathbf{e}_{\perp} = \Delta \mathbf{e} - \Delta r_{\text{stretch}} \hat{\mathbf{b}}. \quad (11)$$

**Zerlegung des Bends in INP und OOP.** Die Cluster-Normale  $\hat{\mathbf{n}}$  (§2.4) zerlegt  $\Delta \mathbf{e}_{\perp}$  weiter in eine Komponente entlang  $\hat{\mathbf{n}}$  (aus der Cluster-Ebene) und einen Rest (in der Cluster-Ebene):

$$\Delta r_{\text{bend\_oop}} = \Delta \mathbf{e}_{\perp} \cdot \hat{\mathbf{n}}, \quad (\text{vorzeichenbehaftet}) \quad (12)$$

$$\Delta r_{\text{bend\_inp}} = \|\Delta \mathbf{e}_{\perp} - \Delta r_{\text{bend\_oop}} \hat{\mathbf{n}}\|. \quad \rightsquigarrow \text{core.analyze\_fe\_ligand} \quad (13)$$

Die ausgegebenen **bend**-, **bend\_inp**- und **bend\_oop**-Spalten in `Fe_S_Cys.xlsx` / `Fe_N_His.xlsx` sind die *Absolutwerte* (Längen) dieser drei Größen, alle in Å. Nach Pythagoras gilt

$$\|\Delta \mathbf{e}_{\perp}\|^2 = (\Delta r_{\text{bend\_inp}})^2 + (\Delta r_{\text{bend\_oop}})^2, \quad (14)$$

was der natürlichen Energie-Zerlegung der Bend-Mode entspricht.

**Bend-INP/OOP-Prozente.** Für Vergleiche von Moden mit sehr unterschiedlichen Gesamt-Amplituden werden die absoluten Längen in *Quadratamplituden-Anteile* relativ zum Gesamt-Bend umgewandelt:

$$\text{bend\_inp\_pct} = 100 \cdot \frac{(\Delta r_{\text{bend\_inp}})^2}{(\Delta r_{\text{bend\_inp}})^2 + (\Delta r_{\text{bend\_oop}})^2}, \quad (15)$$

und analog **bend\_oop\_pct**. Die beiden summieren sich exakt zu 100 %. Für sehr kleine Gesamt-Bends (unter dem Rauschniveau  $2\sigma_e^{\text{therm}}\sqrt{2}$ , §2.2) werden die Prozente auf NaN gesetzt, um numerisches Rauschen nicht zu verstärken.

**Sigma-Propagation.** Alle drei Größen (stretch, bend\_inp, bend\_oop) sind Differenzen zweier unabhängiger Gauss-Rauschkomponenten und tragen daher das Standard- $\sqrt{2}\sigma_e^{\text{therm}}$ -Sigma:

$$\sigma_{\text{stretch}} = \sigma_{\text{bend\_inp}} = \sigma_{\text{bend\_oop}} = \sqrt{2}\sigma_e \cdot u_{\text{rms}}(\omega_l). \quad (16)$$

Die Sigmas werden in die `Fe_S_Cys.xlsx`-/`Fe_N_His.xlsx`-Dateien unter `s_stretch`, `s_bend_inp`, `s_bend_oop` geschrieben und für die Signifikanz-Färbung der Bend-Zellen verwendet.

**Physikalische Interpretation.** Für PCET-Anwendungen ist die INP/OOP-Aufteilung des Fe-N(His)-Bends besonders informativ:

- *bend\_inp dominant* (>70 %): der His-Ring wippt in der Cluster-Ebene – eine Bewegung, die den Fe-Fe-Abstand und den Eisen-Schwefel-Kern stark moduliert, klassisch ET-aktiv.
- *bend\_oop dominant* (>70 %): der His-Ring kippt aus der Ebene heraus, was die N-H-Bindungsrichtung moduliert – Kopplungs-Kanal für PT zu einem vergrabenen Akzeptor.
- *gemischt* (30–70 %): die Mode trägt gleichzeitig zu ET- und PT-Pfaden bei – typische PCET-Signatur.

## 2.6 SCSD nach Kingsbury & Senge

Die OOP/INP-Zerlegung der vorigen Sektion ist eine *geometrische Heuristik* – sie kennt nur die Cluster-Ebene, nicht die Symmetrie. Eine rigorose Symmetriezerlegung leistet die *Symmetry-Coordinate Structural Decomposition* (SCSD) nach Kingsbury & Senge [1].

### Idee

Ein [2Fe-2S]-Cluster mit ideal-rhombischer Geometrie gehört zur Punktgruppe  $D_{2h}$ . Die acht möglichen Verschiebungsmuster der vier Atome (1 Translation  $\times$  3 Achsen + 1 Rotation  $\times$  3 Achsen + 2 Streck) verteilen sich auf die acht  $D_{2h}$ -Irreps:  $A_g, B_{1g}, B_{2g}, B_{3g}, A_u, B_{1u}, B_{2u}, B_{3u}$ .

Eine reale Cluster-Geometrie hat aber endliche Auslenkungen – der Cluster ist nie ideal rhombisch. SCSD projiziert die tatsächlichen Atomkoordinaten auf die acht Irreps der Punktgruppe und liefert pro Irrep eine Beitragsamplitude. Auf eine Normalmode angewandt, sagt SCSD: *Welche Symmetrie hat diese Auslenkung tatsächlich?*

### $D_{2h}$ -Charaktertafel und Symmetrieoperationen

Die Punktgruppe  $D_{2h}$  hat acht Symmetrieoperationen  $\{E, C_2(z), C_2(y), C_2(x), i, \sigma_h, \sigma_v(xz), \sigma_v(yz)\}$  und entsprechend acht eindimensionale Irreps. Die Charaktertafel:

| $D_{2h}$ | $E$ | $C_2(z)$ | $C_2(y)$ | $C_2(x)$ | $i$ | $\sigma_h$ | $\sigma_v(xz)$ | $\sigma_v(yz)$ | Lineare Basis   |
|----------|-----|----------|----------|----------|-----|------------|----------------|----------------|-----------------|
| $A_g$    | 1   | 1        | 1        | 1        | 1   | 1          | 1              | 1              | $x^2, y^2, z^2$ |
| $B_{1g}$ | 1   | 1        | -1       | -1       | 1   | 1          | -1             | -1             | $xy$            |
| $B_{2g}$ | 1   | -1       | 1        | -1       | 1   | -1         | 1              | -1             | $xz$            |
| $B_{3g}$ | 1   | -1       | -1       | 1        | 1   | -1         | -1             | 1              | $yz$            |
| $A_u$    | 1   | 1        | 1        | 1        | -1  | -1         | -1             | -1             | —               |
| $B_{1u}$ | 1   | 1        | -1       | -1       | -1  | -1         | 1              | 1              | $z$             |
| $B_{2u}$ | 1   | -1       | 1        | -1       | -1  | 1          | -1             | 1              | $y$             |
| $B_{3u}$ | 1   | -1       | -1       | 1        | -1  | 1          | 1              | -1             | $x$             |

Im [2Fe-2S]-Kontext ist die Achsenkonvention (Kingsbury 2024):  $\hat{x}$  entlang Fe-Fe,  $\hat{y}$  entlang S-S (Brücken-Schwefel-zu-Brücken-Schwefel),  $\hat{z} = \hat{n}$  (Cluster-Normale).

### Bedeutung der einzelnen Irreps fuer die Cluster-Bewegung

Direkt aus der Charaktertafel kann man ablesen, welche Bewegungen welcher Irrep zugeordnet sind:

| Irrep    | Cluster-Bewegung in [2Fe-2S]-Konvention                                                                                                                   |
|----------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| $A_g$    | Symmetrische Streckungen entlang Hauptachsen. Beispiele: Fe-Fe-Atmung, S-S-Streckung, Cluster-Atmung-Mischung. Klassischer „Reorganisations-Mode“ für ET. |
| $B_{1g}$ | In-Plane-Knickbewegung mit gleichzeitiger Verzer- rung beider Diagonalen.                                                                                 |
| $B_{2g}$ | In-Plane-Bewegung mit ungleichen Fe-S-Abständen auf beiden Cluster-Seiten.                                                                                |
| $B_{3g}$ | In-Plane-Bewegung mit Drehung des Rhombus- Mittelpunkts relativ zu den Atomen.                                                                            |
| $A_u$    | „Zentral-Inversions-Mode“ – selten in starren Clus- tern, kann bei stark verzerrten Geometrien auftau- chen.                                              |
| $B_{1u}$ | Reine OOP-Verschiebung aller Cluster-Atome in $\hat{z}$ -Richtung. Hinge-Mode.                                                                            |
| $B_{2u}$ | OOP-Verschiebung mit Twist um die $\hat{x}$ -Achse.                                                                                                       |
| $B_{3u}$ | OOP-Verschiebung mit Twist um die $\hat{y}$ -Achse.                                                                                                       |

Die  $g$ -Irreps sind *gerade* (in-plane, da paritäts-erhaltend), die  $u$ -Irreps *ungerade* (typischerweise OOP-aktiv).

## Kanonische Referenz und Vorzeichenwahl

Die Projektion erfordert eine eindeutige Achsenwahl. `scsdpy` verwendet die Kingsbury-kanonische Konvention:

1.  $\hat{\mathbf{z}}$  ist die Cluster-Normale.
2. Die Cluster-Hauptachse (längste interatomare Distanz) wird auf  $\hat{\mathbf{x}}$  gelegt.
3. Vorzeichen so gewählt, dass die Cluster-Atome in einer bestimmten Reihenfolge auf positive Quadranten kommen.

In `modenanalyse_2fe2s` wird die Referenzgeometrie einmal pro Lauf gebaut und gespeichert (`core._get_scsd_model`). Sie ist unabhängig davon, in welcher Orientierung Gaussian den Cluster optimiert hat.

## Anwendung auf Normalmodes

Für Mode  $l$  wird das Cluster (vier Atome) um  $\mathbf{e}_{l,i} u_{\text{rms}}$  ausgelenkt; aus dieser ausgelenkten Geometrie minus der Referenzgeometrie ergibt sich ein 12-dimensionaler Verschiebungsvektor. Die SCSD-Projektion liefert acht Amplituden [1]:

$$\mathbf{a}_l = \mathbf{P}_{\text{D}_{2h}}(\mathbf{e}_l^{\text{Cluster}} u_{\text{rms}}), \quad \mathbf{a}_l \in \mathbb{R}^8. \quad \rightsquigarrow \text{core.compute\_scsd\_for\_mode\_full} \quad (17)$$

Die Quadratsumme  $\sum_{\Gamma} a_{l,\Gamma}^2$  ist gleich der ungewichteten Summe über die quadrierten Atom-Verschiebungen – die SCSD-Zerlegung ist eine *orthogonale* Basistransformation.

## Dominante Irrep – rigoros bestimmt

Die rigorose Funktion `core.extract_dominant_scsd_irreps` bestimmt die dominante Irrep wie folgt. Sie:

1. summiert die quadrierten Amplituden pro Irrep,
2. normiert auf die Gesamtsumme,
3. liefert *primäre* und *sekundäre* Irrep zurück, gemeinsam mit ihren prozentualen Anteilen.

Diese Klassifikation kann widersprechen zur OOP/INP-Heuristik: ein Mode kann z. B. „mehrerheitlich OOP“ (Heuristik) und gleichzeitig „primär  $B_{1g}$ “ (SCSD) sein –  $B_{1g}$  ist eine spezifische OOP-Symmetrie, die Heuristik unterscheidet das nicht.

**Das Sheet SCSD im Excel-Output** listet pro Mode die acht Amplituden plus die zwei dominanten Irreps mit Prozentangabe. Die Modes mit konsistenter ( $>80\%$ ) primärer Irrep sind diejenigen, die in der Symmetrie-Tabelle des Manuskripts geführt werden sollten.

## Wann SCSD ausgeschaltet bleibt

Die SCSD-Analyse benötigt das externe Paket `scsdpy`. Wenn es nicht installiert ist, wird das SCSD-Sheet übersprungen und im Befund wird ein Hinweis ausgegeben. Alle anderen Auswertungen (OOP/INP-Heuristik, Kern-Klassifikation, NIS) sind davon nicht betroffen.

## 2.7 Heuristische Kern-Klassifikation

Neben der rigorosen SCSD-Zerlegung gibt es eine *heuristische Kern-Klassifikation*, die jede Mode anhand ihres geometrischen Bewegungsmusters einem Bewegungstyp zuordnet (`core.classify_kernel_mode_fr`). Sie ist robust auch ohne `scsdpy` und bietet eine intuitive Kategorisierung. Die Heuristik ist explizit als solche ausgewiesen und nicht zu verwechseln mit der rigorosen SCSD-Antwort.

## Bewegungs-Scores

Der heuristische Klassifikator berechnet für jede Mode acht Bewegungs-Scores:

| Score                   | Definition                                                                             |
|-------------------------|----------------------------------------------------------------------------------------|
| <b>Translation</b>      | Schwerpunktverschiebung des Clusters (sollte bei intramolekularer Mode klein sein)     |
| <b>Umbrella</b>         | Mittlere OOP-Auslenkung aller vier Cluster-Atome (alle gemeinsam aus der Ebene heraus) |
| <b>Hinge-Fe</b>         | OOP-Differenz Fe <sub>1</sub> minus Fe <sub>2</sub> (Fe-Atome schaukeln gegeneinander) |
| <b>Hinge-S</b>          | OOP-Differenz S <sub>1</sub> minus S <sub>2</sub> (S-Atome schaukeln gegeneinander)    |
| <b>OOP-Twist</b>        | Kombination beider Hinge-Modi (Verdrillung)                                            |
| <b>Fe-Streckung</b>     | In-plane-Anteil entlang Fe-Fe-Achse                                                    |
| <b>S-Streckung</b>      | In-plane-Anteil entlang S-S-Achse                                                      |
| <b>Breathing</b>        | Atemschwingung: alle vier Atome simultan vom Schwerpunkt weg / hin zu ihm              |
| <b>Rhombus-Scherung</b> | Anti-symmetrische Verzerrung des Rhombus (Fe-S-Bindungswinkel)                         |
| <b>Rotation-ip</b>      | Drehbewegung des Clusters in seiner Ebene                                              |

Jeder Score ist auf die Gesamtverschiebung der vier Cluster-Atome normiert und liegt in  $[0, 1]$ .

## Klassifikation

Die zwei höchsten Scores werden als *primäres* und *sekundäres* Bewegungsmuster zurückgegeben. Im Excel-Sheet `Kern_Scores` sind alle acht Scores plus die beiden Top-Labels gelistet. Diese Heuristik gibt eine Vor-Sortierung, die *ohne* D<sub>2h</sub>-Symmetrieannahme funktioniert (auch in verzerrten Geometrien).

## Heuristik vs. SCSD: Wann widersprechen sie sich?

In ideal-rhombischen Clustern stimmen beide überein:

| Heuristik    | SCSD-Irrep             | Bemerkung                          |
|--------------|------------------------|------------------------------------|
| Umbrella     | $B_{2g}$ oder $B_{3g}$ | abhängig von Definition der Achsen |
| Hinge-Fe     | $A_u$                  | antisymmetrisch zur Cluster-Mitte  |
| Breathing    | $A_g$                  | vollsymmetrisch                    |
| Fe-Streckung | $B_{1g}$               | antisymmetrisch entlang Fe-Fe      |
| Rotation-ip  | $B_{1g}$ (in-plane)    | abhängig von Achsenwahl            |

In real verzerrten Clustern, wie sie in Proteinen vorkommen, teilen sich die Bewegungen oft auf zwei Heuristik-Scores auf (z. B. ein Mode mit Hinge-Fe *und* Rhombus-Scherung etwa gleicher Größe). Hier ist die SCSD-Antwort schlüssiger: sie ordnet eine eindeutige Symmetrie zu, die nicht von der Achsenwahl abhängt.

**Achtung – nicht verwechseln.** Die Heuristik-Labels (Umbrella, Hinge, Breathing, ...) sind *Bewegungsbezeichner*, keine Symmetrie-Labels. Ein „Hinge-Fe“-Mode kann je nach Achsenwahl Symmetrie  $A_u$ ,  $B_{1u}$  oder  $B_{2u}$  tragen. Für Manuskript-Aussagen über die Symmetrie immer die SCSD-Antwort verwenden, nicht die Heuristik.

## 2.8 Embeddings: UMAP und HDBSCAN

Bei einem [2Fe-2S]-System mit 5 000–19 000 Modes ist eine gleichzeitige Darstellung aller Mode-Eigenschaften auf zweidimensionalen Plots nicht möglich. `modenanalyse_2fe2s` nutzt UMAP (Uniform Manifold Approximation and Projection) als Dimensionsreduktion, optional gefolgt von HDBSCAN-Clustering.

### Wahl der Methode: warum UMAP?

Im Vergleich zu Alternativen (PCA, t-SNE) hat sich UMAP nach Test-Läufen auf protonierten und deprotonierten Cys<sub>2</sub>His<sub>2</sub>-Modellsystemen sowie einer HHCC-Mutante als die einzige Methode erwiesen, die für DFT-Mode-Daten konsistent interpretierbare Ergebnisse liefert.

- **PCA** [31, 32, 33] ist linear und schnell, kann aber nichtlineare Mannigfaltigkeiten nicht auflösen. Bei DFT-Modes liegen die Datenpunkte typisch auf gekrümmten Untermannigfaltigkeiten im Featureraum (Frequenz-OOP-INP-Score-Beziehungen sind nichtlinear); PCA zeigt nur eine Schatten-Projektion. PC1 liefert in unseren Daten typischerweise nur 25–35 % Varianzerklärung – zu wenig für eine eigenständige Visualisierung.
- **t-SNE** [34, 35] bewahrt lokale Nachbarschaften, aber globale Distanzen sind bedeutungslos: ein scheinbar großer Abstand zwischen zwei Cluster-Regionen in der t-SNE-Darstellung



entspricht nicht notwendigerweise einem großen Abstand im Feature-Raum [34]. Außerdem ist t-SNE stochastisch, die Ergebnisse hängen vom Zufalls-Seed ab. Für Cluster-Identifikation lässt t-SNE Cluster oft auch dann erscheinen, wenn die zugrundeliegenden Daten kontinuierlich verteilt sind.

- **UMAP** [36, 37] bewahrt sowohl lokale Nachbarschaft als auch globale Topologie auf kontrollierbare Weise und ist deutlich schneller als t-SNE bei vergleichbarer Qualität [37]. Der `n_neighbors`-Parameter erlaubt eine explizite Steuerung der Lokalität-Globalitäts-Balance, was für die Mode-Analyse essenziell ist (kleine `n_neighbors` bevorzugen feinere Symmetrie-Klassen, große `n_neighbors` die globale Frequenzstruktur).

Eine PCA-Anwender-Sicht (Varianz-Erklärung pro Achse) ist hier nicht mehr erforderlich, weil die Feature-Bedeutung schon vor dem Embedding durch die kuratierte Auswahl (siehe Abschnitt *Feature-Matrix*) explizit ist. Die anderen Sheets im Excel-Output (*Modenanalyse*, *Reorganisationsenergie*, *Reorg\_Total*) liefern die quantitative Information, die PCA zusätzlich beigetragen hätte.

### UMAP: mathematische Grundlagen

UMAP konstruiert eine niederdimensionale Einbettung in zwei Schritten, basierend auf der Theorie topologischer Mannigfaltigkeiten und unscharfer simplizialer Mengen [36].

**Schritt 1: Hochdimensionaler Nachbarschaftsgraph.** Im ursprünglichen Feature-Raum  $\mathbb{R}^p$  (mit  $p = 31$  Features) wird für jeden Datenpunkt  $x_i$  ein lokaler Nachbarschaftsgraph konstruiert. Pro Punkt werden die  $k$  nächsten Nachbarn bestimmt (Parameter `n_neighbors`). Die Distanz zu diesen Nachbarn wird mittels einer adaptiven Metrik  $d_i(x_i, x_j)$  in einen Wahrscheinlichkeitswert  $\mu_{ij} \in [0, 1]$  umgerechnet:

$$\mu_{ij} = \exp\left(\frac{-\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i}\right), \quad (18)$$

wobei  $\rho_i$  der Abstand zum nächsten Nachbarn von  $x_i$  ist (garantiert, dass jeder Punkt mit Wahrscheinlichkeit 1 zu seinem unmittelbaren Nachbarn verbunden ist) und  $\sigma_i$  so gewählt wird, dass  $\sum_j \mu_{ij} = \log_2(k)$  erfüllt ist (lokale Skalen-Adaption).

Die Asymmetrie in  $\mu_{ij}$  wird durch eine *unscharfe Vereinigung* zu einer symmetrischen Adjazenzmatrix  $w_{ij}$  kombiniert [36]:

$$w_{ij} = \mu_{ij} + \mu_{ji} - \mu_{ij} \mu_{ji}. \quad (19)$$

**Schritt 2: Niedrigdimensionale Einbettung.** Im 2D-Zielraum (`n_components=2`) werden Positionen  $y_i$  gesucht, die einen ähnlichen Nachbarschaftsgraph  $v_{ij}$  erzeugen. Die Wahrscheinlichkeit im Zielraum ist

$$v_{ij} = (1 + a \|y_i - y_j\|^{2b})^{-1}, \quad (20)$$

mit Konstanten  $a \approx 1.577$  und  $b \approx 0.895$  aus der Default-Konfiguration (`min_dist=0.1`). Die Verlustfunktion ist die fuzzy Cross-Entropy:

$$\mathcal{L} = \sum_{ij} \left[ w_{ij} \log \frac{w_{ij}}{v_{ij}} + (1 - w_{ij}) \log \frac{1 - w_{ij}}{1 - v_{ij}} \right], \quad (21)$$

minimiert mittels stochastischem Gradientenabstieg.

**Bewahrte Eigenschaften.** Im Vergleich zu t-SNE bewahrt UMAP nicht nur lokale, sondern auch globale Strukturen [37]. Distanzen zwischen Cluster-Regionen in der UMAP-Projektion korrelieren mit Distanzen im Featureraum – mit der Einschränkung, dass große Distanzen leicht *komprimiert* werden (UMAP ist nicht abstandserhaltend, aber topologie-erhaltend).

### Parameter

- `n_neighbors` (Auto-Heuristik:  $\max(5, \min(15, N/100))$ ): Steuert die Balance lokal vs. global. Kleine Werte (5–10) bewahren feinste lokale Struktur; große Werte (20–50) betonen globale Topologie. Bei einem typischen [2Fe-2S]-Protein mit  $N \approx 5\,000$ – $10\,000$  Modes ergibt die Auto-Heuristik `n_neighbors = 15`, was dem Paper-Standard [36] entspricht.
- `min_dist = 0.1` (Default): minimaler Abstand zwischen Punkten in der Einbettung. Kleinere Werte erzeugen kompaktere Cluster.
- `n_components = 2`: 2D-Visualisierung.
- `random_state = 42` (deterministisch reproduzierbar).

Konfigurierbar über `cfg.umap_n_neighbors` (manueller Override).

### Feature-Matrix

Pro Mode werden 31 numerische Features extrahiert. Zwei ursprünglich geplante `Cys *_OOP`-Features sind per geometrischer Konstruktion immer null (`Cys-Sγ` liegt in der Cluster-Ebene, hat keine Out-of-plane-Komponente) und wurden ausgeschlossen. Die verbleibenden 31 Features sind:

**Cluster-Ring-Anteile** (3 Features, siehe Abschnitt 2.6):

- `lig_OOP%` – Anteil der Mode-Bewegung in der Liganden-Sphäre, der OOP zur Cluster-Ebene erfolgt
- `kern_OOP%` – dasselbe für den Cluster-Kern (Fe + Cluster-S)
- `kern_|d|` – absolute Cluster-Auslenkung in Å (Norm)

**ores / D<sub>2h</sub>-Irreps** (10 Features, siehe Abschnitt 2.6):

- Translation, Umbrella, Hinge-Fe, Hinge-S, OOP-Twist, Fe-Streckung, S-Streckung, Breathing, Rhombus-Scherung, Rotation-ip

Diese sind Projektionen der Mode auf die irreduziblen Darstellungen der idealen  $D_{2h}$ -Cluster-Symmetrie.

**den OOP-Anteile** (2 Features):

- His 255\_OOP, His 259\_OOP

Verteilung der Liganden-OOP-Bewegung auf die zwei His. Die Werte erfüllen `His 255_OOP + His 259_OOP = 1`; sie sind perfekt antikorreliert. UMAP gewichtet jedoch antikorrelierte Features nicht stärker, und die symmetrische Behandlung beider Liganden ist konzeptionell sauberer. *Nicht* aufgenommen: Cys 207\_OOP, Cys 216\_OOP – siehe oben.

**den INP-Anteile** (4 Features):

- Cys 207\_INP, Cys 216\_INP, His 255\_INP, His 259\_INP

Dasselbe für In-plane-Anteile. Auch hier perfekte Antikorrelation paarweise, alle behalten.

**tom-Bewegungen** (12 Features, siehe Sheets Fe\_S\_Cys, Fe\_N\_His):

- Pro Cys (207, 216): stretch, bend\_inp, bend\_oop
- Pro His (255, 259): stretch, bend\_inp, bend\_oop

Stretch und Bend des Fe-S-/Fe-N-Bindungsvektors mit Aufspaltung der Bend-Komponente in INP- und OOP-Anteile bezüglich der Cluster-Ebene.

Vor UMAP wird die Feature-Matrix standardisiert (`sklearn.preprocessing.StandardScaler`; pro Feature Mittelwert 0, Varianz 1). Damit hat keine einzelne Variable wegen ihres absoluten Wertebereichs Vorrang.

**Was bewusst nicht in der Matrix steht.**

- *Frequenz* ( $\omega_l$ ): wird nicht als Feature verwendet, weil sonst die UMAP-Karte trivial nach Frequenz sortiert wäre. Frequenz steht als Metadaten-Spalte daneben und kann zum Einfärben des UMAP-Plots verwendet werden.
- *Reorganisations-Lambda* ( $\lambda_X$ ): nicht als Feature eingeführt, weil die zugrundeliegenden geometrischen Modulationen (`dr_FeFe`, `dr_NH`, `dr_FeN`) in den Per-Liganden-stretch-/bend-Features bereits indirekt enthalten sind. Doppelerfassung würde die Reorg-relevanten Modes überbetonen.
- *Sekundärstruktur* (HELIX/SHEET-Anteile): wird im *separaten* Sekundärstruktur-UMAP behandelt (Sheet `SSE_UMAP_Cluster`). Mode-UMAP und SSE-UMAP sind konzeptionell unterschiedliche Auswertungen.

## HDBSCAN: dichtebasierte Cluster-Findung

HDBSCAN [38, 39] ist ein hierarchischer dichtebasierter Cluster-Algorithmus. Im Unterschied zu k-Means braucht er keine vorgegebene Cluster-Anzahl; er identifiziert Cluster als zusammenhängende Regionen hoher Dichte und markiert isolierte Punkte als Rauschen (Label  $-1$ ).

**min\_cluster\_size.** Der einzige wichtige Parameter: minimale Cluster-Größe. `modenanalyse_2fe2s` verwendet eine Auto-Heuristik

$$\text{mcs} = \max(5, \min(30, \sqrt{N})),$$

Für typische [2Fe-2S]-Protein-Systeme ( $N \approx 5\,000$ – $10\,000$ ) ergibt das  $\text{mcs} = 30$ .

### Wenn HDBSCAN viele Cluster oder viel Rauschen findet – das heißt was?

UMAP auf einem typischen Cys<sub>2</sub>His<sub>2</sub>-System mit 31 Features und `n_neighbors=15` liefert typisch 5–8 Cluster ohne Rauschen. Wenn HDBSCAN signifikant mehr Cluster findet (z. B. 80–100), liegt das meist an einer zu kleinen `mcs`-Wahl oder an einer fragmentierten UMAP-Topologie. Wenn HDBSCAN 0 Cluster findet (alles Rauschen), ist die Mode-Verteilung im Featureraum zu glatt – das ist erwartetes Verhalten für DFT-Mode-Daten ohne harte Übergänge zwischen Mode-Klassen [38].

**Konsequenz.** Die UMAP-Visualisierung selbst ist auch ohne HDBSCAN-Cluster aussagekräftig – man sieht Mode-Dichten und Übergänge durch Einfärbung nach Frequenz, Mode-Typ oder Kern-Score. HDBSCAN ist zusätzliche Information, kein notwendiger Bestandteil der Auswertung.

**Erforderlich.** `hdbscan` und `umap-learn` müssen installiert sein. Ohne diese Pakete werden die UMAP-Sheets übersprungen.

## Praktische Empfehlung

1. **UMAP-Plot anschauen:** das Sheet `Projektionen` enthält die UMAP-Koordinaten für alle Modes. Mit `Origin/matplotlib` einfärben nach Frequenz, Mode-Typ, oder Kern-Primary-Score.
2. **Cluster-Sheets prüfen:** das Sheet `UMAP_Cluster` zeigt HDBSCAN-Labels und Feature-Werte pro Cluster. `UMAP_Cluster_Profil` zeigt Z-Score-Profil und die Top-Modes pro Cluster.
3. **Vergleich zwischen Strukturen** (z. B. prot vs deprot, vs Mut-Variante) erfolgt extern: zwei UMAP-Plots für die zwei Strukturen nebeneinander, mit gleicher Frequenz-Skala einfärben. Innerhalb einer Auswertung wird kein direkter Vergleich durchgeführt – ein System pro Lauf.

## 2.9 Marcus-Hush-Theorie der Reorganisation

Das Reorg-Kapitel §2.12 berechnet pro Mode Beiträge zur Reorganisations-Energie. Bevor wir dort hineingehen, brauchen wir die klassische Marcus-Hush-Theorie als *Vergleichs-Anker* – damit klar ist, was unsere mode-aufgelöste Variante mit der historischen Marcus-Theorie gemeinsam hat und wo sie sich unterscheidet.

### Klassisches Bild: zwei diabatische Energieflächen

Marcus' Theorie des Elektronentransfers [19, 20] beschreibt eine Reaktion zwischen einem Reaktant- und einem Produkt-Zustand durch zwei *diabatische* Energieflächen  $U_R(\mathbf{Q})$  (Reaktant) und  $U_P(\mathbf{Q})$  (Produkt). Die Reaktionskoordinaten  $\mathbf{Q} = (Q_1, Q_2, \dots, Q_N)$  sind die Schwingungsmoden des reaktiven Komplexes – *alle*, nicht einzelne.

In der harmonischen Approximation sind beide Flächen Paraboloiden:

$$U_R(\mathbf{Q}) = U_R^0 + \frac{1}{2} \sum_i \mu_i \omega_i^2 (Q_i - Q_i^R)^2 \quad (22)$$

$$U_P(\mathbf{Q}) = U_P^0 + \frac{1}{2} \sum_i \mu_i \omega_i^2 (Q_i - Q_i^P)^2 \quad (23)$$

wobei  $\mu_i$  die reduzierte Masse,  $\omega_i$  die Eigenfrequenz und  $Q_i^R, Q_i^P$  die Gleichgewichtsverschiebungen der Mode  $i$  in den beiden Zuständen sind.

Die zentrale Annahme von Marcus: **die Frequenzen  $\omega_i$  sind in beiden Zuständen gleich**, nur die Verschiebungen  $Q_i^R \neq Q_i^P$ . Das ist die „harmonisch-gleich“-Approximation; sie gilt, wenn Reaktant und Produkt sich elektronisch ähneln (z. B. zwei Oxidationsstufen desselben Komplexes).

### Reorganisations-Energie als zentrale Größe

Die **Reorganisations-Energie**  $\lambda$  ist definiert als die Energie, die das System zahlt, wenn es im Reaktant-Zustand bleibt, aber zur Produkt-Geometrie verschoben wird:

$$\lambda = U_R(\mathbf{Q}^P) - U_R(\mathbf{Q}^R) = \frac{1}{2} \sum_i \mu_i \omega_i^2 (\Delta Q_i)^2 \quad \text{mit} \quad \Delta Q_i = Q_i^P - Q_i^R. \quad (24)$$

Dies ist die berühmte Marcus-Hush-Standardform. Sie ist eine *Gleichgewichts-Eigenschaft* des Systems – keine Mode-Eigenschaft, keine Aktivierungs-Energie, keine kinetische Größe. Die thermische Population einzelner Modes spielt in (24) keine Rolle.

### Aktivierungs-Energie und Rate

Aus  $\lambda$  und der freien Reaktionsenergie  $\Delta G^0 = U_P^0 - U_R^0$  folgt nach kurzer Geometrie die Marcus-Aktivierungs-Energie:

$$\Delta G^\ddagger = \frac{(\lambda + \Delta G^0)^2}{4\lambda} \quad (25)$$

und damit die Marcus-Rate:

$$k_{\text{ET}} = \frac{2\pi}{\hbar} |H_{RP}|^2 \cdot \frac{1}{\sqrt{4\pi\lambda k_B T}} \cdot \exp\left(-\frac{\Delta G^\ddagger}{k_B T}\right) \quad (26)$$

mit  $H_{RP}$  dem elektronischen Kopplungselement zwischen Reaktant- und Produkt-Diabaten. Drei Charakteristika:

- Bei kleinem  $|\Delta G^0|$ :  $\Delta G^\ddagger \approx \lambda/4$ . *Reorganisations-Energie ist die Maßzahl für die Reaktionsbarriere.*
- Bei  $\Delta G^0 = -\lambda$ : barrierefrei,  $k$  maximal ( $\Delta G^\ddagger = 0$ ).
- Bei  $|\Delta G^0| > \lambda$ : *Marcus-inverter Bereich*, Rate sinkt wieder, weil die Reaktion zu exotherm wird.

In Eisen-Schwefel-Proteinen sind alle drei Bereiche relevant: ferredoxinartige ET-Schritte sind oft im Marcus-Normalbereich; PCET-Schritte in mitoNEET und Rieske können die invertierte Region berühren.

### Was diese Theorie liefert – und was sie nicht liefert

#### Was Marcus-Hush leistet:

- Eine vollständige analytische Beschreibung der ET/PCET-Aktivierungsenergie, falls die harmonische Approximation gültig ist.
- Eine direkt messbare Vorhersage der Rate  $k_{\text{ET}}$  (Glg. 26), wenn  $\lambda$ ,  $\Delta G^0$  und  $|H_{RP}|^2$  bekannt sind.
- Eine Begründung, warum  $\lambda$  system-spezifisch ist (kein Universalwert, hängt von der Solvatationsumgebung, von der Cluster-Geometrie und von den Liganden ab).

#### Was Marcus-Hush nicht direkt liefert:

- *Welche* Modes wesentlich zu  $\lambda$  beitragen. Die Summe in (24) ist global; Promoter-Modes (s. u.) mussten in den 1990ern erst durch Hammes-Schiffer und Andere herausdestilliert werden.
- *Direkten Zugang aus DFT-Frequenzrechnungen.* Klassische Berechnung von  $\lambda$  erfordert zwei separate Frequenzrechnungen (Reaktant + Produkt) plus ein robustes Mode-Mapping zwischen beiden – ein nicht-trivialer Aufwand.

- *Reorganisations-Energie als spektroskopische Observable.*  $\lambda$  aus (24) ist eine Aktivierungs-Energie für eine konkrete Reaktion, keine Bandenfrequenz, kein Linienprofil.

Diese drei Lücken motivieren die Erweiterung in zwei Richtungen:

1. **Mode-aufgelöste Sicht** (Hammes-Schiffer, Cukier, Stuchebrukhov): zerlegt  $\lambda$  in Beiträge einzelner Modes und identifiziert Promoter-Modes mit besonderer Bedeutung für die Rate. Die Multi-Mode-Sicht macht (24) zu einer Frequenz-aufgelösten Information.
2. **Spektroskopisch zugängliche Variante:** ersetzt die statischen Verschiebungen  $\Delta Q_i$  durch thermische Bindungs-Modulationen  $\Delta r_X(i)$ . Damit wird aus  $\lambda$  eine Größe, die direkt aus einer einzigen Frequenzrechnung folgt – und die Banden in NRVS-Spektren zuordnet.

Die zweite Erweiterung ist genau das, was `modenanalyse_2fe2s` in §2.12 berechnet. Was wir dort  $\lambda_X$  nennen, ist *nicht* das klassische Marcus-Hush- $\lambda$  aus (24), sondern eine verwandte aber unterscheidbare Größe – die thermische Bindungs-Reorg-Energie pro Mode und Bindung. Der Zusammenhang zur Huang-Rhys-Theorie macht klar, warum diese Größe eine wohldefinierte spektroskopische Observable ist (nächster Abschnitt).

### Hammes-Schiffer-Erweiterung: Multi-Mode-PCET

Hammes-Schiffer und Soudackov [49] zeigen, dass PCET in komplexen Systemen wie Proteinen *nicht* durch eine einzelne Promoter-Mode beschrieben werden kann. Stattdessen ist die Reaktion an viele Modes gleichzeitig gekoppelt; das Spektrum der Beiträge  $\lambda_i = \frac{1}{2}\mu_i\omega_i^2(\Delta Q_i)^2$  ist breit verteilt.

Die naive Standard-Marcus-Theorie kann diese Multi-Mode-Realität durch eine *effektive* Reorganisations-Energie  $\lambda_{\text{eff}} = \sum_i \lambda_i$  darstellen, aber die mode-aufgelöste Verteilung geht dabei verloren. Für die NRVS-Bandenidentifikation ist genau diese Verteilung wichtig:

- Welche Frequenzbereiche tragen am stärksten zur Reorg bei?
- Welche Bindungen sind in diesen Bereichen aktiv?
- Welche Mutationen sollten welche Bandenstruktur verändern?

Die Multi-Mode-Sicht ist auch der Grund, warum globale „Top-Mode-Klassifikations“-Ansätze (PCET-Score,  $L_{\text{PCET}}$ , `filter_variant`) konzeptionell unbefriedigend waren: sie suchten nach *einer* dominierenden Mode, während die Realität eine breite Verteilung ist. Die mode-aufgelöste Reorg-Pipeline macht diese Verteilung explizit.

### Was bedeutet $\Delta Q$ vs. $\Delta r_X$ ?

Eine zentrale Subtilität zur Vorbereitung des nächsten Kapitels: die klassische Marcus-Verschiebung  $\Delta Q_i$  (massengewichtete Mode-Koordinate) ist *nicht* dasselbe wie eine Bindungs-Modulation  $\Delta r_X$  (kartesishe Distanz-Änderung in Å).

- $\Delta Q$ : Verschiebung der *Eigenmode-Koordinate* zwischen zwei Gleichgewichtsgeometrien. Hat Einheit  $\sqrt{\text{amu}} \cdot \text{\AA}$ . Tritt in (24) auf.
- $\Delta r_X(i)$ : *Bindungs-Modulation* entlang der  $X$ -Bindung, induziert durch Mode  $i$  mit thermisch skalierten Auslenkungen. Hat Einheit  $\text{\AA}$ . Wird in `reorganization.compute_mode_modulations` berechnet.

Beide haben dieselbe *Form* in der Standard-Glg.  $\lambda = \frac{1}{2}\mu\omega^2(\cdot)^2$ , aber unterschiedliche *physikalische Bedeutung*. Die Brücke zwischen beiden ist die Huang-Rhys-Theorie – siehe nächster Abschnitt.

## 2.10 Huang-Rhys-Theorie und unser $\lambda_X$

In §2.12 berechnen wir  $\lambda_X(i) = \frac{1}{2}\mu_i\omega_i^2(\Delta r_X(i))^2$  mit *thermisch skalierten* Bindungs-Modulationen. Dieser Abschnitt zeigt, dass das exakt der **Huang-Rhys-Faktor** ist (in einer bestimmten Konvention), und dass diese Größe eine wohldefinierte spektroskopische Bedeutung hat.

### Was Huang-Rhys ursprünglich beschrieben hat

Huang und Rhys [50] berechneten optische Linienprofile von Farbzentren in Festkörpern. Ihre Frage: wenn ein elektronischer Übergang die Gleichgewichtsposition einer harmonischen Schwingung verschiebt, wie sieht dann das resultierende Vibronen-Spektrum aus?

Antwort: das Spektrum ist eine Poisson-Verteilung

$$P(n) = \frac{S^n e^{-S}}{n!} \quad (27)$$

über Phononen-Anzahl  $n$ , parametrisiert durch den **Huang-Rhys-Faktor**

$$S = \frac{\mu\omega(\Delta q)^2}{2\hbar}, \quad (28)$$

wobei  $\Delta q$  die übergangs-induzierte Gleichgewichts-Verschiebung einer Mode mit reduzierter Masse  $\mu$  und Frequenz  $\omega$  ist.

### Bedeutung von $S$ :

- $S \ll 1$ : Übergang ist annähernd vertikal, Linienspektrum dominiert durch 0-0-Bande.
- $S \approx 1$ : starke Mode-Kopplung, Vibronen-Bande mit mehreren Phononen-Anregungen.
- $S \gg 1$ : Gauss-förmige Bandenstruktur (Stokes-Verschiebung gleich  $S\hbar\omega$ ).

In moderner Sprache:  $S$  misst die Mode-Kopplung *quantitativ*, in Einheiten der Nullpunkts-Auslenkung  $u_{\text{ZP}} = \sqrt{\hbar/(2m\omega)}$ :

$$S = \frac{(\Delta q)^2}{2u_{\text{ZP}}^2}. \quad (29)$$



## Verbindung zu Marcus-Hush

Vergleiche (28) mit der Marcus-Reorganisations-Energie einer einzelnen Mode (aus (24) mit  $N = 1$ ):

$$\lambda_{\text{single}}^{\text{Marcus}} = \frac{1}{2} \mu \omega^2 (\Delta q)^2 = S \cdot \hbar \omega. \quad (30)$$

Damit gilt:  $\lambda^{\text{Marcus}} = S \cdot \hbar \omega$ . Die beiden Größen sind ineinander überföhrbar.

Bei einer Multi-Mode-Verteilung:  $\lambda_{\text{total}}^{\text{Marcus}} = \sum_i S_i \cdot \hbar \omega_i$ .

## Was ist $\Delta q$ in unserem Fall?

Der Knackpunkt: in der klassischen Marcus-Theorie ist  $\Delta q$  eine *statische Verschiebung* der Mode-Koordinate zwischen zwei elektronischen Zuständen. `modenanalyse_2fe2s` hat aber *nur einen* elektronischen Zustand pro Lauf – die einzelne DFT-Frequenzrechnung gibt nur eine Gleichgewichtsgeometrie und ihre Eigenmodes.

Lösung: wir ersetzen die statische Verschiebung durch eine *thermische Auslenkung*:

$$(\Delta q)^2 \rightarrow \langle q^2 \rangle = \frac{\hbar}{2\mu\omega} \coth\left(\frac{\hbar\omega}{2k_B T}\right) = u_{\text{rms}}^2. \quad (31)$$

Mit der Konvention  $\Delta r_X(i) = u_{\text{rms}}(i) \cdot \alpha_X(i)$ , wobei  $\alpha_X(i)$  der Mode-Anteil auf der Bindung  $X$  ist, wird unser  $\lambda_X(i)$ :

$$\lambda_X(i) = \frac{1}{2} \mu_i \omega_i^2 u_{\text{rms}}^2(i) \alpha_X^2(i). \quad (32)$$

Setzt man (31) ein und nutzt  $\hbar\omega/(k_B T) \rightarrow \infty$  bei  $T \rightarrow 0$  (also  $\coth \rightarrow 1$ ), erhält man:

$$\lambda_X(i) \xrightarrow{T \rightarrow 0} \frac{1}{2} \mu_i \omega_i^2 \frac{\hbar}{2\mu_i \omega_i} \alpha_X^2(i) = \frac{\hbar \omega_i}{4} \alpha_X^2(i). \quad (33)$$

**Verbindung zum Huang-Rhys-Faktor.** Aus (30) folgt mit  $(\Delta q)^2 = u_{\text{rms}}^2 \cdot \alpha_X^2$ :

$$S_X(i) = \frac{\mu_i \omega_i u_{\text{rms}}^2(i) \alpha_X^2(i)}{2\hbar} \xrightarrow{T \rightarrow 0} \frac{\alpha_X^2(i)}{4}. \quad (34)$$

Im  $T \rightarrow 0$ -Limit ist also der Huang-Rhys-Faktor pro Bindung einfach *ein Viertel des quadrierten Mode-Anteils*. Für eine reine Streckmode der Bindung ( $\alpha_X = 1$ ) gilt  $S_X = 1/4$  – also *schwache Kopplung* im Huang-Rhys-Sinn, typisches Linienpektrum.

## Bedeutung der Größenordnung

Setzen wir konkrete Zahlen ein. Für eine typische Fe-S-Streckschwingung bei  $\omega = 350 \text{ cm}^{-1}$  und  $T = 5 \text{ K}$ :

- Nullpunkts-Energie:  $\hbar\omega/4 = 87.5 \text{ cm}^{-1}$ .

- Für eine reine Streckmode ( $\alpha_X = 1$ ):  $\lambda_X(T \rightarrow 0) = 87.5 \text{ cm}^{-1}$ .
- Bei thermischer Population ( $5 \text{ K} \ll \hbar\omega/k_B = 503 \text{ K}$ ):  $\coth \approx 1$ , also nahezu Nullpunkts-Wert.
- Bei Raumtemperatur ( $300 \text{ K}$ ,  $\coth \approx 1.04$ ):  $\lambda_X \approx 91 \text{ cm}^{-1}$ , kaum Erhöhung.

Dieselbe Mode bei  $\omega = 100 \text{ cm}^{-1}$ :

- $\hbar\omega/4 = 25 \text{ cm}^{-1}$ .
- Bei  $5 \text{ K}$ :  $\coth \approx 1.0$ ,  $\lambda_X \approx 25 \text{ cm}^{-1}$ .
- Bei  $300 \text{ K}$ :  $\coth \approx 4.2$ ,  $\lambda_X \approx 105 \text{ cm}^{-1}$ .

Niederfrequente Modes sind also bei Raumtemperatur stark thermisch populierte – ihre  $\lambda_X$ -Beiträge werden gegenüber dem Nullpunkts-Wert um Faktor  $\coth(\hbar\omega/2k_B T)$  verstärkt.

**Konsequenz für Tieftemperatur-NRVS.** Bei Tieftemperatur ( $5\text{--}40 \text{ K}$ ,  $\hbar\omega \gg k_B T$  für typische NRVS-Frequenzen) ist  $u_{\text{rms}}^2 \approx \hbar/(2\mu\omega)$ , also  $T$ -unabhängig. Damit gilt

$$\lambda_X(i) \approx \frac{\hbar\omega_i}{4} \alpha_X^2(i) \quad \text{für Tieftemperatur-NRVS.} \quad (35)$$

Diese Form ist *rein quantenmechanisch* (Nullpunkts-Energie), unabhängig von der genauen Proben temperatur. Das ist genau das, was NRVS misst: die quantenmechanische Mode-Aktivität, nicht eine thermische Boltzmann-Mittelung.

### Was unser $\lambda_X$ also ist – abschließende Definition

Mit allen Vorarbeiten können wir jetzt eine präzise Definition formulieren:

Was  $\lambda_X$  in `modenanalyse_2fe2s` ist

$\lambda_X(i)$  ist die **thermische Bindungs-Reorg-Energie** der Mode  $i$  entlang der Bindungs-Klasse  $X$ :

- Form: identisch zu Marcus-Hush ( $\frac{1}{2}\mu\omega^2 r^2$ ), aber mit thermisch skaliertem  $r$  statt statischem Reaktant-Produkt-Versatz.
- Verwandt mit dem Huang-Rhys-Faktor:  $S_X(i) = \lambda_X(i)/(\hbar\omega_i)$ .
- Im Tieftemperatur-Limit:  $\lambda_X(i) \rightarrow (\hbar\omega_i/4) \alpha_X^2(i)$  – rein quantenmechanisch,  $T$ -unabhängig.
- Direkte spektroskopische Bedeutung:  $\lambda_X(i)$  ist die Energie der Bindung- $X$ -Modulation in Mode  $i$ , gemessen am QHO-Erwartungswert.

**Diese Größe ist verwandt mit, aber nicht identisch zu, der klassischen Marcus-Hush-Aktivierungs-Energie für eine Reaktion zwischen zwei elektronischen Zuständen.** Für letztere bräuchte man zwei separate DFT-Rechnungen.

## 2.11 NRVS-Theorie soweit relevant für Bandenidentifikation

Das Tool berechnet *nicht* NRVS-Spektren – diese werden mit spezialisierten externen Werkzeugen aus derselben DFT-Frequenzrechnung synthetisiert. Aber die in §2.12 berechneten Modulations-Spektren  $M_X(\omega)$  und kumulativen Reorg-Kurven  $\Lambda_X(\omega)$  sind direkt mit NRVS-Banden vergleichbar – darum brauchen wir die NRVS-Theorie als Interpretations-Rahmen.

### Was misst NRVS?

NRVS [12] misst die  $^{57}\text{Fe}$ -projizierte Vibrations-Zustandsdichte:

$$D_{\text{Fe}}(\omega) = \sum_i |\mathbf{e}_{\text{Fe}}^{(i)}|^2 \cdot \delta(\omega - \omega_i) \quad (36)$$

gewichtet mit dem Lamb-Mößbauer-Faktor  $f_{\text{LM}}$  und einer multi-Phonon-Konvolution. Für die Bandenidentifikation reicht meist die Fe-pDOS ohne Multi-Phonon – das nennen wir  $g_{\text{Fe}}(\omega)$ .

Wichtige Eigenschaften:

- NRVS ist **element-selektiv**: nur Modes mit Fe-Beteiligung erscheinen. Modes mit reinen Liganden-Bewegungen (z. B. C-H-Stretching) sind nicht sichtbar.
- NRVS ist **nicht symmetrieselektiv**: anders als Raman/IR sind alle Modes sichtbar, unabhängig von ihrer  $D_{2h}$ -Symmetrie. Das macht NRVS besonders nützlich für Eisen-Schwefel-Cluster, wo viele Modes per Auswahlregeln in IR/Raman dunkel sind.
- NRVS ist **quantitativ**: das Integral der pDOS ist auf 1 normiert (oder  $3N_{\text{Fe}}$  in einigen Konventionen). Bandenintensitäten sind direkt Mode-Kopplungen.

### Bandenstruktur in [2Fe-2S]-Proteinen

Die typische [2Fe-2S]-NRVS-Bandenstruktur (Gee 2021 [7]; eine umfassende Übersicht der NRVS-Modi geben Wang *et al.* 2025 [46]) hat drei Hauptbereiche:

**Niederfrequenz-Bereich (50–200  $\text{cm}^{-1}$ ).** Skelett-Schwingungen des gesamten Proteins. Für das Cluster relevant: Cluster-Ebenen-Bewegungen (translatorisch + rotatorisch in der Protein-Matrix), Cluster-OOP-Buckel (akustische Mode-Mischung mit Liganden).  $\lambda_X$  ist hier in allen Kanälen klein ( $\lambda_X \approx \hbar\omega/4 \approx 12\text{--}50 \text{ cm}^{-1}$  pro Mode), aber die *Anzahl* der Modes ist groß.

**Mittlerer Bereich (200–400  $\text{cm}^{-1}$ ).** Hier liegen die meisten Cluster-Bindungs-Streckschwingungen:

- Fe-N(His)-Stretching: 260–290  $\text{cm}^{-1}$  in mitoNEET-typischer  $\text{Cys}_3\text{His}_1$ - Koordination (Gee 2021 [7]: berechnet 223  $\text{cm}^{-1}$  für Fe(II)- $\text{N}_\delta(\text{His})$  im reduzierten Zustand, ca. 270–290  $\text{cm}^{-1}$  im oxidierten Zustand). Für klassische Rieske- $\text{Cys}_2\text{His}_2$ -Cluster: Doppelbande bei 266 + 274  $\text{cm}^{-1}$  (Kuila *et al.* 1992 [45], Fe(III)-N), zugeordnet zu protoniertem (266) bzw. deprotoniertem (274) Imidazol.

- Fe-Fe-Cluster-Atmung:  $\sim 200 \text{ cm}^{-1}$ , je nach Cluster- Geometrie und Liganden.
- Fe-S<sub>bridge</sub>-symmetrische Streckung:  $300\text{--}340 \text{ cm}^{-1}$ .
- Fe-S<sub>Cys</sub>-Stretching:  $280\text{--}320 \text{ cm}^{-1}$ .

Für eine reine Fe-X-Streckmode mit  $\alpha_X \approx 1$  ist  $\lambda_X \approx \hbar\omega/4 \approx 60\text{--}100 \text{ cm}^{-1}$  – großer Beitrag pro Mode.

### Hochfrequenz-Bereich ( $400\text{--}800 \text{ cm}^{-1}$ ).

- Fe-S<sub>bridge</sub>-asymmetrische Streckung:  $380\text{--}420 \text{ cm}^{-1}$ .
- Imidazol-Ring-Modes mit Fe-Beteiligung:  $600\text{--}700 \text{ cm}^{-1}$ .
- Cluster-Liganden-Biegungen mit Fe-Anteil:  $500\text{--}700 \text{ cm}^{-1}$ .

### Wie man $\Lambda_X(\omega)$ mit NRVs vergleicht

Die kumulative Reorg-Kurve  $\Lambda_X(\omega) = \sum_{\omega_i \leq \omega} \lambda_X(i)$  ist eine **Stufenfunktion**: jede Mode mit nicht-trivialem  $\lambda_X$ -Beitrag erzeugt einen Sprung der Höhe  $\lambda_X(i)$  bei  $\omega = \omega_i$ .

Im Vergleich mit dem NRVs-Spektrum:

- Wo eine Bande in der Fe-pDOS liegt, sollte ein Sprung in  $\Lambda_X(\omega)$  sein – für den Kanal  $X$ , der diese Bande dominiert.
- Die Höhe des Sprungs ist proportional zu  $\hbar\omega \cdot \alpha_X^2$ . Ein Sprung von  $50 \text{ cm}^{-1}$  bei  $\omega = 350 \text{ cm}^{-1}$  entspricht  $\alpha_X^2 = 4 \cdot 50/350 = 0.57$  – also einer Mode mit etwa 57% Bindungs-Anteil auf  $X$ .
- Wenn das NRVs-Spektrum eine Bande zeigt, aber alle  $\Lambda_X(\omega)$ -Kurven flach bleiben, dann ist die Mode in keinem unserer 5 Kanäle stark aktiv – sie ist wahrscheinlich eine Liganden-interne Mode mit nur leichter Fe-Beteiligung.

Diese Korrespondenz macht  $\Lambda_X(\omega)$  zu einem direkten **Bandenzuordnungs-Werkzeug**. Wenn ein Reviewer fragt: „Welche Bindung ist in Bande X aktiv?“, plottet man  $\Lambda_{\text{FeFe}}, \Lambda_{\text{FeN}}, \Lambda_{\text{FeS}}, \Lambda_{\text{NH}}, \Lambda_{\text{HA}}$  ueber dem NRVs-Spektrum und liest die Antwort direkt ab.

### Tieftemperatur-Konsistenz

NRVs-Messungen werden typischerweise bei  $5\text{--}40 \text{ K}$  durchgeführt (fluess. He), um die Lamb-Mößbauer-Auflösung zu maximieren und die thermische Linienverbreiterung zu minimieren. In dieser Tieftemperatur-Region ist unser  $\lambda_X$  identisch mit dem Nullpunkts-Wert,  $\hbar\omega/4 \cdot \alpha_X^2$  – d.h. unser berechnetes  $\lambda_X$  ist das, was NRVs misst, modulo Spektral-Verbreiterung und multi-Phonon-Effekten.

Konsequenz: für die Bandenidentifikation muss man NICHT bei der exakten Mess-Temperatur rechnen. Ein Lauf bei `temp_k = 5` liefert die Tieftemperatur-Werte; ein Lauf bei `temp_k = 300`

liefert die Raumtemperatur-Werte; in der NRVS-relevanten Frequenzregion ( $\omega > 200 \text{ cm}^{-1}$ ) sind beide praktisch identisch, weil die Bose-Einstein-Population dort verschwindet.

### Was NRVS *nicht* sieht

- **Reine N-H-Streckschwingungen** (Imidazol-NH bei  $3000+ \text{ cm}^{-1}$ ): außerhalb des typischen NRVS-Messbereichs (Apparate enden bei  $800\text{--}1000 \text{ cm}^{-1}$ ), und die Mode hat ohnehin nur winzigen Fe-Anteil. Konsequenz:  $\Lambda_{\text{NH}}$  ist in unseren typischen Filtern (`freq_max = 800`) immer sehr klein – siehe Befund-Tabelle.
- **Reine OH-Streckschwingungen**: dito.
- **Backbone-Modes** ohne Fe-Beteiligung: bleiben in der pDOS dunkel.

Diese Punkte sind wichtig für die Bandenzuordnungs-Begründung im Befund: wenn eine Mode in der pDOS dunkel ist, aber unser  $\Lambda_X(\omega)$  dort einen Sprung zeigt, ist das ein *Hinweis* darauf, dass die Mode existiert und Fe-Beteiligung hat, aber das Lamb-Mößbauer-Faktor sehr klein ist (Mode ist nicht kohärent mit Fe). Das ist gerade in PCET-Studien interessant.

## 2.12 Mode-aufgelöste Bindungs-Reorganisations-Energien

Das Paket nutzt einen *konzeptionellen Pivot* vollzogen: weg von einer Klassifikation einzelner Modes als „PCET-Kandidat“ (mit Schwellen, Filtern, tanh-Sättigung), hin zur direkten Berechnung mode-aufgelöster Bindungs-Reorganisations- Beiträge, mit Marcus-Hush-Form aber thermisch skalierten Mode-Amplituden.

Bevor wir die Pipeline beschreiben: eine Klarstellung der physikalischen Bedeutung der berechneten Größen.

### Was $\lambda_X$ ist und was es nicht ist

Klassische Marcus-Hush-Reorganisationsenergie [19, 20] ist

$$\lambda_{\text{total}}^{\text{Marcus}} = \frac{1}{2} \sum_i \mu_i \omega_i^2 (\Delta Q_i)^2, \quad (37)$$

wobei  $\Delta Q_i$  die *statische* Verschiebung der harmonischen Mode-Koordinate  $i$  zwischen Reaktant- und Produktzustand ist (Aktivierungs-Energie für die Reaktion). Die Berechnung dieser Größe erfordert zwei separate Frequenzrechnungen (Reaktant und Produkt) plus ein Mode-Mapping zwischen beiden – Aufwand, den wir hier *nicht* betreiben.

**Was wir stattdessen berechnen**, ist eine verwandte aber verschiedene Größe: die mode-aufgelöste Beitragsenergie der *thermischen Bindungs-Längen-Fluktuationen* pro Bindungs-Kanal. Aus den Eigenvektoren der Frequenzrechnung wird für jede Mode  $i$  und jede Bindung  $X$  die thermisch skalierte Bindungs-Modulation  $\Delta r_X(i)$  berechnet (Auslenkungs-Vektoren multipliziert

mit  $u_{\text{rms}}$  aus dem QHO-Erwartungswert), und daraus

$$\lambda_X(i) = \frac{1}{2} \mu_i \omega_i^2 (\Delta r_X(i))^2. \quad (38)$$

Die Summe über alle Modes,  $\Lambda_X^{\text{total}} = \sum_i \lambda_X(i)$ , ist die thermische Bindungs-Reorganisations-Energie der Bindung  $X$ . Bei  $T \rightarrow 0$  reduziert sich das (mit  $\mu = m_{\text{mode}}$ ) auf

$$\lambda_X(i) \rightarrow \frac{\hbar \omega_i}{4} \cdot \alpha_X^2(i), \quad (39)$$

wobei  $\alpha_X(i)$  der dimensionslose “Mode-Anteil” der Bindung  $X$  ist, implizit definiert durch  $\Delta r_X(i) = u_{\text{rms}}(i) \cdot \alpha_X(i)$ . Für eine reine Streckmode der Bindung  $X$  gilt  $\alpha_X(i) = 1$ , und der Reorganisations-Beitrag bei  $T \rightarrow 0$  ist  $\hbar \omega/4$  (Nullpunkts-Energie geteilt durch 2). In der Praxis kann  $\alpha_X(i)$  auch größer als 1 sein für Moden, in denen die zwei Bindungspartner stark gegeneinander schwingen (Relativ-Verschiebungs-Verstärkung); das ist geometrisch legitim und verletzt kein Erhaltungsgesetz – die Eigenvektor-Normierung  $\sum_i \|\mathbf{e}_i\|^2 \approx 1$  ist eine Summe über *Atome*, nicht über Bindungen.

### Bedeutung für PCET-Studien.

- $\Lambda_X^{\text{total}}$  ist eine wohldefinierte spektroskopische Observable. Sie misst, welche Bindung in den thermischen Schwingungen „am stärksten zappelt“, mode- aufgelöst.
- Geeignet für **NRVS-Bandenidentifikation**: Frequenzbereiche mit großen  $\Lambda_X(\omega)$ -Sprüngen sind die Banden, in denen Bindung  $X$  stark moduliert wird. Direkter Vergleich mit NRVS-Spektren möglich.
- Geeignet für **System-Vergleiche bei gleicher Temperatur**: WT vs. Mut, prot vs. deprot. Skaliert konsistent. Insbesondere: bei deprot-Variante verschwinden NH und HA kanalbedingt, die anderen bleiben vergleichbar.
- Verwandt mit dem **Huang-Rhys-Faktor** [50] und der Franck-Condon-Theorie vibratorischer Spektren.

### Was die Größe nicht liefert.

- *Keine* klassischen Marcus-Theorie-Aktivierungs-Energien für eine spezifische ET- oder PT-Reaktion – dafür bräuchte man Reaktant- und Produkt-Geometrien getrennt.
- *Keine* Reaktions-Raten-Vorhersage.
- *Kein* direkter Vergleich mit Literatur-Werten der Marcus- $\lambda$  einer Reaktion (sofern dort statische Reaktant-Produkt-Differenzen verwendet werden).

**Hammes-Schiffer-Sicht.** Hammes-Schiffer und Soudackov [49] zeigen, dass PCET in Proteinen typischerweise *viele Moden gleichzeitig* aktiviert. Die Vorstellung einer einzelnen „Promoter-Mode“ ist Spezialfall (kleine Modelle), nicht Regelfall. Unsere mode-aufgelöste Sicht macht genau diese

Multi-Mode-Realität explizit: statt einer Top-Mode-Klassifikation liefern wir die Verteilung der Bindungs-Modulationen über alle Modes.

### Fünf Bindungs-Kanäle

Pro Mode werden fünf Bindungs-Kanäle ausgewertet:

- **FeFe** – Fe-Fe-Cluster-Atmung (ET-Reorganisation).
- **FeN** – Fe-N(His)-Bindung (PT-relevant in Rieske-artigen Systemen).
- **FeS** – Fe-S(Cys)-Bindung sowie Fe-S<sub>bridge</sub> innerhalb des Clusters.
- **NH** – N-H-Stretchung der protonierten His.
- **HA** – H-Akzeptor-Distanz (Wasserstoffbrücke), berechnet im *Reaktionskoordinaten-Modus* (siehe unten).

NH und HA werden bei deprotonierten His-Liganden übersprungen (kein H verfügbar). FeS umfasst sowohl Fe-Cys-Bindungen als auch Cluster-interne Fe- $\mu$ S-Bindungen; die Aufschlüsselung pro einzelne Bindung erfolgt im Sheet `Reorg_pro_Bindung`.

### Geometrische Modulation $\Delta r_X$

Für eine Mode mit thermisch skaliertem Auslenkungsvektor  $\mathbf{e}_a, \mathbf{e}_b$  der beiden Bindungspartner (bei Position  $\mathbf{r}_a, \mathbf{r}_b$ ) ist die vorzeichenbehaftete Bindungslängen-Modulation

$$\Delta r_X^{(\text{klass.})} = (\mathbf{e}_a - \mathbf{e}_b) \cdot \hat{\mathbf{n}}_{ab}, \quad \hat{\mathbf{n}}_{ab} = \frac{\mathbf{r}_a - \mathbf{r}_b}{\|\mathbf{r}_a - \mathbf{r}_b\|}. \quad \rightsquigarrow \text{reorganization.signed\_dr\_along\_axis} \quad (40)$$

Konvention:  $\Delta r > 0$  heisst „Bindung dehnt sich“. Diese klassische Definition wird für FeFe, FeN, FeS und NH verwendet.

**HA als Reaktionskoordinate.** Für den HA-Kanal misst Gleichung 40 *nicht* das, was für PT physikalisch relevant ist: bei einer hochfrequenten C=O-Schwingung im Protein-Rückgrat bewegt sich der Akzeptor stark, das H bleibt fest, aber die Distanz  $|\mathbf{r}_H - \mathbf{r}_A|$  ändert sich – und würde als HA-Modulation gezählt, obwohl es keinen PT-Charakter hat.

Die HA-Modulation misst die *Bewegung des H relativ zum Donor-N*, projiziert auf die N→Akzeptor-Achse:

$$\Delta r_{\text{HA}}^{(\text{react. coord.})} = (\mathbf{e}_H - \mathbf{e}_N) \cdot \hat{\mathbf{n}}_{NA}, \quad \hat{\mathbf{n}}_{NA} = \frac{\mathbf{r}_A - \mathbf{r}_N}{\|\mathbf{r}_A - \mathbf{r}_N\|}. \quad \rightsquigarrow \text{reorganization.compute\_mode\_modulations} \quad (41)$$

Wenn nur der Akzeptor sich bewegt (Skelett-Mode), ist  $\mathbf{e}_H - \mathbf{e}_N \approx 0$  und damit  $\Delta r_{\text{HA}} = 0$  – kein PT-Beitrag. Eine echte PT-Bewegung (H bewegt sich vom N zum A) liefert dagegen  $\Delta r_{\text{HA}} > 0$ .

**Hauptakzeptor pro H.** Pro His-H-Atom werden zwar alle Akzeptoren in `pcet_hbond_cutoff_a` (Default 4 Å) gefunden, aber nur der *Hauptakzeptor* (höchstes Gauss-Gewicht  $\exp(-(r_{\text{eq}} - r_0)^2/(2\sigma^2))$  mit  $r_0 = 2.8 \text{ Å}$ ,  $\sigma = 0.4 \text{ Å}$ ) wird als HA-Kanal verwendet. Damit wird die Doppelzählung von Akzeptoren vermieden – ein H bewegt sich physikalisch nur in eine Richtung. Konkret für PCET ist die Logik: pro His-Imidazol gibt es ein NE2-H (oder ND1-H), und an diesem H haengt genau ein dominanter H-Bridge-Akzeptor (typischerweise ein H<sub>2</sub>O, Carbonyl-O eines Backbones, oder ein Asp/Glu-O).

**Wirkung des Gauss-Gewichts.** Das Gauss-Gewicht wird  $w = \exp(-(r_{\text{eq}} - r_0)^2/(2\sigma^2))$  *ausschließlich* für die Hauptakzeptor-Auswahl verwendet – nicht mehr als Dämpfungs-Faktor in der Lambda-Aggregation. Die binaere Logik ist nun: *ist ein H-Bridge-Akzeptor in pcet\_hbond\_cutoff\_a Reichweite oder nicht?* Bei Akzeptoren in Reichweite zählt die HA-Mode voll (weight = 1.0), bei keinem entfällt der Kanal. Die geometrische Dämpfung weiterer Akzeptoren ergibt sich automatisch aus den kleineren  $\Delta r_{\text{HA}}$ -Werten (weite H-Bridges modulieren ohnehin schwach), zusätzliche Multiplikation mit  $w < 1$  wäre doppelte Strafe.

### Reduzierte Masse: zwei Konventionen

Für den  $\lambda$ -Beitrag pro Mode haben wir zwei Wahlmöglichkeiten für die reduzierte Masse:

- $\mu_{\text{pair}}$  – bindungsspezifische reduzierte Masse, berechnet aus den beiden gebundenen Atomen ( $\mu_{\text{NH}} \approx 0.94 \text{ amu}$ ,  $\mu_{\text{FeFe}} \approx 27.92 \text{ amu}$  usw.). Naehere *isolierter Oszillator*: gut für Mode-zu-Mode-Vergleich *derselben* Bindung.
- $\mu_{\text{mode}}$  – Mode-eigene reduzierte Masse aus dem Gaussian-Output. Diese erfüllt per Konstruktion die Orthogonalität der Eigenmodes, wodurch sich die  $\lambda$ -Beiträge *ohne Doppelzählung* addieren – das ist die **Marcus-Hush-korrekte** Wahl für die Summe in Gl. 37.

Beide werden ausgegeben (Spalten `lambda_X_pair_cm1` und `lambda_X_mode_cm1` im Sheet *Reorganisationsenergie*). Für die System-Aggregation in `Reorg_Total` wird  $\mu_{\text{mode}}$  verwendet.

### Reorg-Beitrag $\lambda_X$ pro Mode

Die schon in (38) oben gegebene Formel  $\lambda_X(i) = \frac{1}{2} \mu_i \omega_i^2 (\Delta r_X(i))^2$  wird mit den oben definierten geometrischen Modulationen  $\Delta r_X(i)$  und der gewählten reduzierten Masse-Konvention ( $\mu_{\text{pair}}$  oder  $\mu_{\text{mode}}$ ) angewandt.

Einheiten-Konversion:  $\omega_{\text{SI}} = 2\pi c \omega_{\text{cm}^{-1}}$ ,  $\mu_{\text{SI}} = \mu_{\text{amu}} \cdot u$ ,  $\Delta r_{\text{SI}} = \Delta r_{\text{Å}} \cdot 10^{-10} \text{ m}$ ;  $\lambda_{\text{cm}^{-1}} = \lambda_{\text{J}}/(hc)$ .

Wichtig: Wegen der thermischen Skalierung  $\mathbf{e}_a = \mathbf{e}_a^{\text{normalized}} \cdot u_{\text{rms}}$  liegt  $\Delta r_X(i)$  skalenmäßig im Bereich der QHO-Wahrscheinlichkeits-Verteilung, nicht der Reaktant-Produkt-Differenz. Für reine Streckmoden der Bindung  $X$  konvergiert  $\lambda_X(i)$  bei  $T \rightarrow 0$  gegen  $\hbar\omega_i/4$  ( $= \omega_i/4$  in  $\text{cm}^{-1}$ ); bei gemischten Modes wird das mit dem quadrierten Mode-Anteil  $\alpha_X^2$  multipliziert.



## System-Aggregation

$$\Lambda_X^{\text{total}} = \sum_{i=1}^{N_{\text{modes}}} \lambda_X(i) \rightsquigarrow \text{reorganization.compute\_total\_reorganization} \quad (42)$$

pro Kanal  $X \in \{\text{FeFe}, \text{FeN}, \text{FeS}, \text{NH}, \text{HA}\}$ .

Die Summen werden zusätzlich *frequenzaufgelöst* ausgegeben:

- **Modulations-Spektren**  $M_X(\omega)$  – Gauss- verbreiterte Akkumulation der Bindungs-Modulationen je Mode entlang der Frequenzachse:

$$M_X(\omega) = \sum_{i=1}^{N_{\text{modes}}} \Delta r_X^{\text{RSS}}(i) \mathcal{G}(\omega - \omega_i, \sigma_M), \quad \mathcal{G}(x, \sigma) = \frac{e^{-x^2/(2\sigma^2)}}{\sigma\sqrt{2\pi}}. \rightsquigarrow \text{reorganization.compute\_modulation\_spe} \quad (43)$$

Default-Verbreiterung:  $\sigma_M = 5 \text{ cm}^{-1}$ , einstellbar via `reorg_spectrum_sigma_cm1`.

**Was ist  $\Delta r_X^{\text{RSS}}(i)$  genau?** Jeder Eltern-Kanal  $X \in \{\text{FeFe}, \text{FeN}, \text{FeS}, \text{NH}, \text{HA}\}$  kann mehrere *Sub-Kanäle* haben: z. B. enthält FeN die beiden Fe-N(His<sub>a</sub>)- und Fe-N(His<sub>b</sub>)-Sub-Bindungen, FeS enthält alle vier Fe-S(Cys<sub>k</sub>)-Sub-Bindungen (bzw. zwei für Cys<sub>2</sub>His<sub>2</sub>-Cluster). Für Mode  $i$  aggregieren wir daher die Sub-Kanal-Modulationen als gewichtete Wurzel-Quadratsumme

$$\Delta r_X^{\text{RSS}}(i) = \sqrt{\sum_{s \in \text{Sub-Kanälen}(X)} w_s (\Delta r_X^{(s)}(i))^2}, \rightsquigarrow \text{reorganization.aggregate\_by\_parent} \quad (44)$$

wobei die Gewichte  $w_s$  aus `build_channels_from_coord_info` stammen (Gauss-Gewichtung des H $\cdots$ Akzeptor-Abstands für HA, eins für FeFe/FeN/FeS/NH). Für Eltern-Kanäle mit nur einem Sub-Kanal (FeFe, NH, HA-pro-Akzeptor) reduziert sich das zu  $\sqrt{w} |\Delta r_X(i)|$ , also wieder die einfache absolute Modulation. Die RSS-Aggregation ist die *energetisch konsistente* Wahl: sie erfüllt  $\lambda_X^{\text{Eltern}}(i) = \frac{1}{2} \mu_i \omega_i^2 (\Delta r_X^{\text{RSS}}(i))^2$ , wobei  $\lambda_X^{\text{Eltern}}$  die gewichtete Summe der Sub-Kanal- $\lambda$ 's ist.

- **Co-Modulations-Spektren** – geometrisches Mittel zweier  $M_X$ -Spektren, hoch nur dort, wo *gleichzeitig* zwei Bindungen moduliert werden:

$$C_{\text{PCET}}(\omega) = \sqrt{M_{\text{HA}}(\omega) M_{\text{FeFe}}(\omega)}, \quad (45)$$

$$C_{\text{PT-FeN}}(\omega) = \sqrt{M_{\text{HA}}(\omega) M_{\text{FeN}}(\omega)}, \quad (46)$$

$$C_{\text{ET-FeS}}(\omega) = \sqrt{M_{\text{FeFe}}(\omega) M_{\text{FeS}}(\omega)}. \quad (47)$$

- **Kumulative Reorg-Kurven**  $\Lambda_X(\omega)$  – monoton steigend, konvergieren am Spektrum-Ende gegen  $\Lambda_X^{\text{total}}$ :

$$\Lambda_X(\omega_{\text{cut}}) = \sum_{i: \omega_i \leq \omega_{\text{cut}}} \lambda_X(i). \quad (48)$$

Sprünge in  $\Lambda_X(\omega)$  markieren reorg-aktive Frequenzfenster, die direkt mit NRVS-Spektren verglichen werden können.

## Excel-Output

Vier Sheets pro Lauf bzw. Frequenzfenster:

- **Reorganisationsenergie** – pro Mode 21 Spalten: `freq_cm1` und für jeden Kanal vier Werte ( $\Delta r_{\text{rms}}$ ,  $\Delta r_{\text{sum-signed}}$ ,  $\lambda_{\text{pair}}$ ,  $\lambda_{\text{mode}}$ ).
- **Reorg\_Total** – 5-Zeilen-Zusammenfassung: pro Kanal  $\Lambda_X^{\text{total}}$  in beiden  $\mu$ -Konventionen plus Anzahl der beitragenden Modes.
- **Reorg\_pro\_Bindung** – pro einzelner Bindung (`FeS_Cys207`, `FeS_Cys216`, `FeS_Cluster_*`, `FeN_His255` usw.) deren Beitrag, mit Akzeptor-Gewicht und Anzahl Modes.
- **Modulations\_Spektren** – frequenz aufgelöst: fünf  $M_X(\omega)$ -Kurven plus drei Co-Indikator-Kurven  $C_{\text{PCET}}$ ,  $C_{\text{PT-FeN}}$ ,  $C_{\text{ET-FeS}}$ .
- **Lambda\_kumulativ** – fünf  $\Lambda_X(\omega)$ -Kurven für direkten Vergleich mit NRVS-Spektren.

## 2.13 HP/Standard-Frequenz-Konsistenzcheck

Wie in §2.1 angedeutet, schreibt Gaussian bei `freq=hpmodes` die Frequenzen *zweimal* in das Logfile – einmal im HP-Block (5 Nachkommastellen) und einmal im Standard-Block (2 Nachkommastellen). Beide Blöcke beziehen sich auf dieselbe Eigenwertberechnung; ihre Frequenzen *müssen* also übereinstimmen (innerhalb der Schreibgenauigkeit von  $0.01 \text{ cm}^{-1}$ ).

## Implementierung

`logio.check_hp_std_frequency_consistency` vergleicht beim Lauf:

1. Mode-für-Mode: für jede Modennummer wird die HP-Frequenz mit der Standard-Frequenz verglichen.
2. Toleranz:  $0.01 \text{ cm}^{-1}$  (default), verstellbar via `cfg.hp_std_freq_tolerance_cm1`.
3. Bei Abweichungen wird die maximale Differenz, die betroffene Modennummer und beide Frequenzen geloggt.

**Was Abweichungen bedeuten**

| Symptom                             | Mögliche Ursache                                                                         |
|-------------------------------------|------------------------------------------------------------------------------------------|
| 1–2 Modes mit $\Delta\omega > 0.01$ | Numerische Reduzierung in Gaussian-Output (selten, harmlos)                              |
| Viele Modes systematisch versetzt   | Falsches Block-Pairing (HP-Block aus anderem Job, Restart-Mismatch)                      |
| Komplette Diskrepanz                | Abgebrochener Job, partielles Logfile, oder zwei verschiedene Logfiles aneinandergehängt |

In allen Fällen wird die Diskrepanz *nicht* fatal behandelt – das Programm läuft weiter und nutzt die HP-Werte. Die Diagnose landet aber im Befund, sodass eine Nachuntersuchung möglich ist.

**Praxis-Hinweis.** In sehr alten Logfiles (Gaussian 09 oder älter) gibt es für die niedrigsten Frequenzen ( $\omega \rightarrow 0$ ) gelegentlich Vorzeichen-Diskrepanzen zwischen HP- und Standard-Block (eine Mode, die im HP-Block als  $-2.3\text{ cm}^{-1}$  und im Standard-Block als  $+2.3\text{ cm}^{-1}$  erscheint). Das ist ein Gaussian-Artefakt der Translationen/Rotationen-Behandlung. Die Konsistenzprüfung warnt darauf, das Verhalten ist aber harmlos – diese Modes werden in der Regel ohnehin wegen  $\omega < \text{Threshold}$  ausgeschlossen.

## Referenzen

## Teil II

# Anwendung

### 3 Konfiguration

Alle Lauf-Parameter werden in einem “Config”-Objekt zusammengefasst. “Config” ist eine Python-“dataclass” mit Default-Werten für alle optionalen Felder (`src/modenanalyse_2fe2s/config.py`). Drei Felder sind *Pflicht*: `log_file`, `output_dir`, sowie – falls Liganden-Auflösung gewünscht ist – `pdb_file`.

#### 3.1 Beispiel-Konfiguration

Die typische, in Spyder lauffähige Form (siehe “`example_run.py`”):

```
from modenanalyse_2fe2s import Config, run_analysis

cfg = Config(
    log_file    = r"D:\Daten\cluster_freq.log",
    pdb_file    = r"D:\Daten\cluster.pdb",
    output_dir  = r"D:\Daten\results",
    temp_k      = 40.0,
    freq_max    = 800.0,
    freq_windows = [(0, 100), (100, 300), (300, 500), (500, 700)],
)

run_analysis(cfg)
```

Alle weiteren Felder behalten ihren Default. Die folgenden Tabellen listen die Felder gruppiert nach Funktion auf.

#### 3.2 Vollständige Parameter-Referenz

Die folgende Übersicht zeigt alle 48 Konfigurationsfelder mit ihren Default-Werten. Ausführliche Beschreibungen und Empfehlungen siehe unten in den Themen-Abschnitten.

Tabelle 1: Vollständige Übersicht aller Konfigurationsfelder mit Default-Werten. Eine kommentierte Beispiel-TOML mit allen Feldern liegt unter `run_example_full.toml` im Distributions-Verzeichnis.

| Feld                                     | Default              | Sektion   |
|------------------------------------------|----------------------|-----------|
| <code>log_file</code>                    | — (Pflicht)          | Eingabe   |
| <code>output_dir</code>                  | — (Pflicht)          | Eingabe   |
| <code>pdb_file</code>                    |                      | Eingabe   |
| <code>pdb_chain</code>                   | Å"                   | Eingabe   |
| <code>logname_suffix</code>              |                      | Eingabe   |
| <code>freq_min</code>                    | None                 | Frequenz  |
| <code>freq_max</code>                    | None                 | Frequenz  |
| <code>freq_windows</code>                | None                 | Frequenz  |
| <code>temp_k</code>                      | None                 | Thermo    |
| <code>amplitude</code>                   | 1.0                  | Thermo    |
| <code>cluster_index</code>               | 0                    | Cluster   |
| <code>fe_s_cutoff</code>                 | 3.0 Å                | Cluster   |
| <code>fe_fe_cutoff</code>                | 3.5 Å                | Cluster   |
| <code>strict_cluster</code>              | False                | Cluster   |
| <code>fe_coord_cutoff_n</code>           | 2.50 Å               | Ligand    |
| <code>fe_coord_cutoff_s</code>           | 2.70 Å               | Ligand    |
| <code>fe_coord_cutoff_o</code>           | 2.50 Å               | Ligand    |
| <code>include_hn_vibration</code>        | True                 | Ligand    |
| <code>mode_type_threshold</code>         | 60.0%                | OOP       |
| <code>mode_type_detail_thresholds</code> | (60, 75, 90)         | OOP       |
| <code>analyze_scsd</code>                | True                 | SCSD      |
| <code>analyze_sse</code>                 | True                 | SCSD      |
| <code>sse_chain</code>                   |                      | SCSD      |
| <code>pcet_enabled</code>                | True                 | PCET      |
| <code>pcet_hbond_cutoff_a</code>         | 4.0 Å                | PCET      |
| <code>pcet_acceptor_r0_a</code>          | 2.8 Å                | PCET      |
| <code>pcet_acceptor_sigma_a</code>       | 0.4 Å                | PCET      |
| <code>reorg_spectrum_sigma_cm1</code>    | 5.0 cm <sup>-1</sup> | PCET      |
| <code>reorg_spectrum_step_cm1</code>     | 0.5 cm <sup>-1</sup> | PCET      |
| <code>export_embedding_plots</code>      | True                 | Embedding |
| <code>umap_n_neighbors</code>            | None (auto)          | Embedding |
| <code>include_hydrogen</code>            | True                 | Numerik   |

| Feld                              | Default               | Sektion |
|-----------------------------------|-----------------------|---------|
| <code>sigma_eigvec</code>         | 5e-4                  | Numerik |
| <code>sigma_coord</code>          | 1e-3                  | Numerik |
| <code>amplitude_threshold</code>  | 0.001                 | Numerik |
| <code>coord_match_tol</code>      | 1.0 Å                 | Numerik |
| <code>scan_chunk_mb</code>        | 16                    | Numerik |
| <code>show_errors_in_excel</code> | True                  | Numerik |
| <code>interp_step</code>          | 0.05 cm <sup>-1</sup> | Numerik |
| <code>interp_boundary_mode</code> | context"              | Numerik |
| <code>interp_edge_extend</code>   | 0.5 cm <sup>-1</sup>  | Numerik |
| <code>interp_context_cm1</code>   | 5.0 cm <sup>-1</sup>  | Numerik |
| <code>use_cache</code>            | True                  | Numerik |

### 3.3 Eingabe und Ausgabe

| Feld                        | Default          | Beschreibung                                                                                                                                          |
|-----------------------------|------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>log_file</code>       | <i>(Pflicht)</i> | Pfad zur DFT-Frequenz- Datei. Unterstützt: Gaussian-16 .log (mit/ohne <code>freq=hpmodes</code> ) und ORCA .hess (automatisch erkannt an der Endung). |
| <code>output_dir</code>     | <i>(Pflicht)</i> | Zielverzeichnis. Wird angelegt falls nicht vorhanden.                                                                                                 |
| <code>pdb_file</code>       |                  | PDB-Datei mit demselben Cluster (Liganden-Auflösung; optional, aber empfohlen).                                                                       |
| <code>pdb_chain</code>      | Å"               | Chain-Identifizierung in der PDB-Datei.                                                                                                               |
| <code>logname_suffix</code> |                  | Optionales Suffix für die Output-Dateien (nützlich bei mehreren Läufen aus demselben Logfile, z. B. verschiedene Cluster).                            |

### 3.4 Frequenzbereich und Fenster

| Feld                  | Default | Beschreibung                                                                   |
|-----------------------|---------|--------------------------------------------------------------------------------|
| <code>freq_min</code> | None    | Untere Frequenzgrenze in cm <sup>-1</sup> . None bedeutet keine untere Grenze. |
| <code>freq_max</code> | None    | Obere Frequenzgrenze. Für NRVs-relevante Auswertung typischerweise 800.        |

| Feld         | Default | Beschreibung                                                                                                                                |
|--------------|---------|---------------------------------------------------------------------------------------------------------------------------------------------|
| freq_windows | None    | Liste von Fenstern wie [(0, 100), (100, 300), ...]. Wenn gesetzt, generiert das Programm <i>ein Excel pro Fenster</i> (Multi-Window-Modus). |

**Konvention.** freq\_max (und freq\_min) gelten auch für sämtliche Reorg- und Aggregat-Auswertungen. Da  $^{57}\text{Fe}$ -projizierte Beiträge oberhalb  $\sim 800\text{ cm}^{-1}$  verschwindend klein sind und NRVS-Experimente in dem Bereich messen, ist eine  $800\text{-cm}^{-1}$ -Grenze sowohl experimentell als auch numerisch sinnvoll.

**Fenstergrenzen-Konvention (seit v1.0.4).** Der Multi-Window-Modus partitioniert Modes in Bins [(lo<sub>1</sub>,hi<sub>1</sub>), (lo<sub>2</sub>,hi<sub>2</sub>), ..., (lo<sub>N</sub>,hi<sub>N</sub>)]. Die Grenzen sind *halb-offen von links*:

- Jedes Fenster außer dem letzten verwendet das Intervall [lo, hi). Eine Mode mit Frequenz exakt auf einer Fenstergrenze gehört zum *oberen* Fenster (dem, das bei diesem Wert beginnt).
- Das letzte Fenster der Liste verwendet [lo, hi], sodass seine obere Kante eingeschlossen ist. Falls hi für das letzte Fenster None/inf ist, ist es nach oben offen.

Damit wird garantiert, dass jede Mode in genau einem Fenster zählt, und Doppelzählungen von  $B$ -Faktor-Beiträgen und  $\Lambda_X(\omega_{\text{cut}})$ -Werten für Grenz-Modes verhindert (§2.3). Vor v1.0.4 wurden an beiden Enden geschlossene Intervalle verwendet, die exakt auf der Grenze liegende Modes doppelt zählten.

### 3.5 Thermik

| Feld       | Default | Beschreibung                                                                                                                                                  |
|------------|---------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|
| temp_k     | None    | Probentemperatur in Kelvin für die thermische Skalierung der Eigenvektoren. None → Klassik-Modus mit Amplitude = amplitude. Typische NRVS-Werte: 40, 80, 100. |
| temp_k_nis | [40]    | Liste der Temperaturen für NIS-Spektrum-Simulation. Pro Temperatur wird eine Spalte im NIS-Sheet geschrieben.                                                 |
| amplitude  | 1.0     | Fallback-Amplitude in Å bei temp_k = None. Default 1.0 ist die historische Konvention.                                                                        |

### 3.6 Cluster-Erkennung

| Feld                        | Default | Beschreibung                                                                                                                                                 |
|-----------------------------|---------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>fe_s_cutoff</code>    | 3.0     | Maximaler Fe-S-Abstand (Å), innerhalb dessen S-Atome zum Cluster zählen.                                                                                     |
| <code>fe_fe_cutoff</code>   | 3.5     | Maximaler Fe-Fe-Abstand (Å) für die Cluster-Identifikation.                                                                                                  |
| <code>cluster_index</code>  | 0       | Bei Multi-Cluster-Systemen (z. B. Glutaredoxin-Dimer): Index des zu analysierenden Clusters. Default 0 = engstes Fe-Fe-Paar. Pro Cluster ein separater Lauf. |
| <code>strict_cluster</code> | False   | Wenn <b>True</b> , bricht das Programm mit Fehler ab, wenn der Cluster nicht eindeutig identifiziert werden kann (kein Fallback auf nahegelegene Atome).     |

### 3.7 Fe-Liganden-Erkennung (PDB-basiert)

| Feld                              | Default | Beschreibung                                                                                                                             |
|-----------------------------------|---------|------------------------------------------------------------------------------------------------------------------------------------------|
| <code>fe_coord_cutoff_n</code>    | 2.50    | Maximaler Fe-N-Abstand (Å) für Liganden-N (His).                                                                                         |
| <code>fe_coord_cutoff_s</code>    | 2.70    | Maximaler Fe-S-Abstand für Liganden-S (Cys).                                                                                             |
| <code>fe_coord_cutoff_o</code>    | 2.50    | Maximaler Fe-O-Abstand für Liganden-O (Asp/Glu, selten für [2Fe-2S]).                                                                    |
| <code>include_hn_vibration</code> | True    | N-H-Streckschwingungs- Analyse für protonierte His-Liganden (Sheet <code>His_HN</code> ). Erfordert <code>include_hydrogen=True</code> . |

### 3.8 OOP/INP-Klassifikation

| Feld                                     | Default      | Beschreibung                                                                         |
|------------------------------------------|--------------|--------------------------------------------------------------------------------------|
| <code>mode_type_threshold</code>         | 60.0         | Binäre OOP-Schwelle in Prozent (§2.4).                                               |
| <code>mode_type_detail_thresholds</code> | (60, 75, 90) | Drei Schwellen für die feine 7-Stufen-Klassifikation. Symmetrisch zu 50 % angewandt. |

### 3.9 SCSD und Sekundärstruktur



| Feld         | Default | Beschreibung                                                                              |
|--------------|---------|-------------------------------------------------------------------------------------------|
| analyze_scsd | True    | Symmetry-Coordinate Structural Decomposition aktivieren (erfordert <code>scsdpy</code> ). |
| analyze_sse  | True    | Sekundärstruktur-Analyse aktivieren (Helices, Sheets aus PDB).                            |
| sse_chain    |         | Chain-Filter für SSE-Erkennung. Leer = wie <code>pdb_chain</code> .                       |

### 3.10 PCET / Marcus-Hush-Reorganisation

| Feld                     | Default | Beschreibung                                                                                                                                                |
|--------------------------|---------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| pcet_enabled             | True    | Marcus-Hush-Reorg-Pipeline aktivieren. Wenn <code>False</code> , werden $\Delta r_X$ und $\lambda_X$ pro Mode nicht berechnet, alle Reorg-Sheets entfallen. |
| pcet_hbond_cutoff_a      | 4.0     | H...Akzeptor-Maximal- distanz (Å) für die Akzeptor-Suche. Gemessen vom H-Atom.                                                                              |
| pcet_acceptor_r0_a       | 2.8     | Optimal-Abstand (Å) für die Gauss-Gewichtung der Akzeptor-Auswahl; entspricht typischer N–H...O/N-Bindungslänge.                                            |
| pcet_acceptor_sigma_a    | 0.4     | Gauss-Standard- abweichung (Å) der Akzeptor-Gewichtung. Bei $ r - r_0  > 2\sigma$ trägt der Akzeptor faktisch nichts mehr bei.                              |
| reorg_spectrum_sigma_cm1 | 5.0     | Gauss-Verbreiterung der Modulations-Spektren $M_X(\omega)$ . $5\text{ cm}^{-1}$ entspricht typischer DFT-Frequenz-Unschärfe + NRVS-Auflösung.               |
| reorg_spectrum_step_cm1  | 0.5     | Frequenz-Raster- Schrittweite für $M_X(\omega)$ und $\Lambda_X(\omega)$ . $0.5\text{ cm}^{-1}$ ergibt feine Banden bei vertretbarer Datei-Größe.            |

### 3.11 Numerische Parameter

| Feld             | Default | Beschreibung                                                      |
|------------------|---------|-------------------------------------------------------------------|
| include_hydrogen | True    | H-Atome in Eigenvektor- Reads berücksichtigen. Für PCET zwingend. |

| Feld                              | Default  | Beschreibung                                                                                                                                                                                                 |
|-----------------------------------|----------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>sigma_eigvec</code>         | 5e-4     | Numerisches Rauschen in Eigenvektor-Komponenten (Bernoulli-Var.). Kontrolliert Schwellen für “unbedeutende” Beiträge.                                                                                        |
| <code>sigma_coord</code>          | 1e-3     | Koordinatenrauschen in Å.                                                                                                                                                                                    |
| <code>amplitude_threshold</code>  | 0.001    | Schwelle für signifikante Atomverschiebung in einem Mode.                                                                                                                                                    |
| <code>coord_match_tol</code>      | 1.0      | Toleranz (Å) für PDB↔Gaussian-Atom-Matching nach Kabsch-Alignment.                                                                                                                                           |
| <code>interp_step</code>          | 0.05     | Schrittweite ( $\text{cm}^{-1}$ ) fuer interpolierten pDOS-Export.                                                                                                                                           |
| <code>interp_boundary_mode</code> | context" | Verhalten am Fenster-Rand: <b>context</b> " (Kontextmoden verankern beide Ränder), <b>zero</b> " (Randwert 0.0 – “keine Daten in diesem Bereich”), <b>nearest</b> " (Randwert = nächste vorhandene Mode).    |
| <code>interp_edge_extend</code>   | 0.5      | Raster-Puffer ( $\text{cm}^{-1}$ ) über die erste/letzte Mode hinaus. Seit v1.2.2 nur noch wirksam, wenn <i>kein</i> Frequenzbereich angefordert wurde; mit Bereich umfasst das Raster exakt diesen Bereich. |
| <code>scan_chunk_mb</code>        | 16       | Block-Größe für Logfile-Scan in MB. Für sehr große Logfiles (>1 GB) kann Erhöhen das Lesen beschleunigen.                                                                                                    |
| <code>use_cache</code>            | True     | Aktiviert Datei-Caching für Block-Offsets im Logfile. Halbiert die Laufzeit bei wiederholten Calls.                                                                                                          |

### 3.12 Embeddings (UMAP)

| Feld                                | Default | Beschreibung                                                                                                                                                                                                                                                              |
|-------------------------------------|---------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>umap_n_neighbors</code>       | None    | UMAP-Nachbarn-Parameter. <b>None</b> = Auto-Heuristik $\max(5, \min(15, N/100))$ , bei typische [2Fe-2S]-Protein-Größe ( $N \approx 5\,000\text{--}10\,000$ ) ergibt das 15 (Paper-Standard, [36]). Manuell setzen für sehr kleine Datensätze (< 50 Modes) auf z. B. 5–8. |
| <code>export_embedding_plots</code> | True    | PNG-Plot der UMAP-Projektion erzeugen. Auf <b>False</b> setzen, um matplotlib-Setup-Zeit zu sparen.                                                                                                                                                                       |

### 3.13 Sonstiges

| Feld                              | Default           | Beschreibung                                                                                            |
|-----------------------------------|-------------------|---------------------------------------------------------------------------------------------------------|
| <code>show_errors_in_excel</code> | <code>True</code> | Wenn <code>True</code> , werden Warnungen aus dem Lauf zusätzlich im Excel-Sheet <b>Info</b> angezeigt. |

### 3.14 Validierungsregeln

Alle Felder werden beim Aufruf von `cfg.validate()` (im `run_analysis`-Einstieg automatisch ausgeführt) auf syntaktische und numerische Plausibilität geprüft:

- Pflichtfelder gesetzt
- Cutoffs  $> 0$
- Frequenzgrenzen aufsteigend, falls beide gesetzt
- PCET-Schwellen:  $0 < \text{moderat} < \text{stark} \leq 1$
- Bandgrenzen streng aufsteigend
- Linienprofil aus erlaubter Menge

Validierungsfehler werden gesammelt und gemeinsam ausgegeben (kein fail-fast bei individuellem Fehler). Das vereinfacht das Korrigieren bei mehreren Tippfehlern in der Konfiguration.

## 4 Workflow-Beispiele

Drei typische Szenarien sind im Folgenden vollständig durchgespielt: ein einzelnes Cluster (Standard-Anwendung), Multi-Cluster (Glutaredoxin-Dimere mit zwei Clustern), und ein WT-vs.-Mut-Vergleich (PCET-Validierungs-Test).

### 4.1 Wie startet man einen Lauf?

Es gibt zwei äquivalente Wege, eine Analyse zu starten: programmatisch aus Python (`run_analysis(cfg)`) oder über die Kommandozeile mit einer TOML-Konfigurationsdatei. Der TOML-Weg wird für reproduzierbare Produktions-Läufe empfohlen, weil die Konfiguration selbsterklärend ist und versionskontrolliert werden kann.

#### TOML + CLI (empfohlen)

Der grundlegende Aufruf:

```
modenanalyse-2fe2s mein_lauf.toml
```

Der Pfad zur TOML-Datei ist das *erste positionale Argument* – ein `--config`-Flag ist nicht nötig. Das Paket kann auch eine annotierte Vorlage erzeugen:

```
modenanalyse-2fe2s --write-template mein_lauf.toml
# mein_lauf.toml nach Bedarf anpassen
modenanalyse-2fe2s mein_lauf.toml
```

## Pfad-Stolperfallen in TOML

TOML-Strings mit doppelten Anführungszeichen interpretieren Backslashes als Escape-Zeichen, sodass Windows-Pfade wie "D:\Daten\datei.log" einen Parser-Fehler auslösen ("Unescaped backslash in a string" o. ä.). Drei gültige Alternativen:

```
# 1. Forward Slashes (funktioniert auch auf Windows):
log_file = "D:/Daten/datei.log"

# 2. Einfache Anführungszeichen = TOML literal string (kein Escaping):
log_file = 'D:\Daten\datei.log'

# 3. Escapete Backslashes:
log_file = "D:\\Daten\\datei.log"
```

**Wichtig.** Pythons Raw-String-Präfix `r. . .` ist *keine* gültige TOML-Syntax. Wenn Pfade aus Python-Code (z. B. `r"D:\Daten\datei.log"`) in eine TOML-Datei kopiert werden, muss das `r`-Präfix entfernt und eine der drei obigen Formen verwendet werden. Das ist eine häufige Stolperfalle für Nutzer, die von `run_analysis()`-Aufrufen auf TOML-basierte Konfiguration umsteigen.

## CLI-Overrides

CLI-Argumente können einzelne TOML-Felder überschreiben, ohne dass die Datei editiert werden muss – nützlich für Parameter-Scans:

```
# mein_lauf.toml verwenden, aber temp_k = 40 K erzwingen:
modenanalyse-2fe2s mein_lauf.toml --temp-k 40.0

# mein_lauf.toml verwenden, aber in ein anderes Output-Verzeichnis schreiben:
modenanalyse-2fe2s mein_lauf.toml --output-dir ./results_test
```

Eine vollständige Liste der verfügbaren CLI-Flags zeigt `modenanalyse-2fe2s --help`.

## Programmatische API

Für interaktive Analyse (z. B. in Spyder oder Jupyter) kann dieselbe Konfiguration direkt erstellt werden:

```
from modenanalyse_2fe2s import Config, run_analysis

cfg = Config(
    log_file   = r"D:\Daten\system_freq.log",  # Python-Raw-String hier OK
    pdb_file   = r"D:\Daten\system.pdb",
    output_dir = r"D:\Daten\results",
    temp_k     = 5.0,
    freq_max   = 800.0,
)
run_analysis(cfg)
```

Beachten: in *Python-Quellcode* (.py-Dateien) sind `r . . .`-Raw-Strings *erlaubt* und die empfohlene Form für Windows-Pfade. Die Einschränkung auf nicht-Raw-Strings gilt nur für TOML-Konfigurationsdateien.

## 4.2 Szenario A: Einzelnes Cluster (Standard-Anwendung)

### Eingabedaten

- `cluster_wt_freq.log` – Gaussian-16 `freq=hpmodes` des optimierten Cluster-Modells (Cluster + erste Liganden-Sphäre, ca. 50–100 Atome).
- `cluster_wt.pdb` – Strukturmodell mit denselben Liganden-Resten wie im DFT-Lauf, plus weitere Reste für die SSE-Analyse.

### Konfiguration

```
from modenanalyse_2fe2s import Config, run_analysis

cfg = Config(
    log_file   = r"D:\Daten\cluster_wt_freq.log",
    pdb_file   = r"D:\Daten\cluster_wt.pdb",
    output_dir = r"D:\Daten\cluster_wt_40K",
    pdb_chain  = "A",
    temp_k     = 40.0,
    freq_max   = 800.0,
    freq_windows = [(0, 100), (100, 300), (300, 500), (500, 700)],
)

run_analysis(cfg)
```

## Erwartete Ausgabe

Im `output_dir` entstehen vier Unterordner (eines pro Fenster):

- `cluster_wt_freq_0-100/`
- `cluster_wt_freq_100-300/`
- `cluster_wt_freq_300-500/`
- `cluster_wt_freq_500-700/`

Jeder Ordner enthält:

- `cluster_wt_freq_analysis.xlsx` – Hauptauswertung (Modenanalyse, Kern-Scores, SCSD, PCET/ET, Fe-Bindung, His-HN, Info, ...)
- `cluster_wt_freq_pDOS_interp.xlsx` – interpolierte Fe-pDOS, Origin-kompatibel
- `cluster_wt_freq_REPORT.txt` – Plain-Text-Lauf-Protokoll (Befund)

## Was zuerst prüfen

1. **Befund-Datei öffnen** und kontrollieren:
  - Cluster erkannt? Fe-Fe- und Fe-S-Distanzen plausibel?
  - Liganden korrekt zugeordnet? (Tabelle `coord_summary`)
  - Kabsch-RMSD klein ( $< 0.5 \text{ \AA}$ )?
  - HP/Std-Konsistenz: keine Auffälligkeiten?
  - PCET-Reorg aktiv (His-Liganden gefunden,  $\Lambda_{\text{HA}} > 0$ )?
2. **Sheet Modenanalyse öffnen**: nach `kern_oop` sortieren  $\rightarrow$  die OOP-dominierten Modes sehen.
3. **Sheet Reorg\_Total**: fünf Lambda-Werte für das System (FeFe, FeN, FeS, NH, HA). Welcher Kanal dominiert? In Origin: `Lambda_kumulativ` öffnen und die kumulativen Kurven  $\Lambda_X(\omega)$  pro Kanal plotten – Sprünge markieren reorg-aktive Frequenzen.

## 4.3 Szenario B: Multi-Cluster-System (Dimere und mehr)

Manche Systeme tragen mehrere [2Fe-2S]-Cluster (z. B. Glutaredoxin-Dimere mit zwei äquivalenten Clustern, Domänen-Konstrukte mit zwei verschiedenen Clustern, oder Multi-Cluster-Komplexe wo zwei Cluster im aktiven Zentrum zusammenarbeiten).

Ab v1.0.0 unterstützt das Tool Multi-Cluster-Auswertung als **first-class** Feature: ein einziger Lauf analysiert alle gefundenen Cluster automatisch.

## Cluster-Erkennung

`geometry.find_all_clusters` sucht alle Fe-Fe-Paare unterhalb `cfg.fe_fe_cutoff` (Default 3.5 Å) und gruppiert die brueckenden S-Atome. Sortierung: aufsteigend nach Fe-Fe-Distanz, also das engste Cluster zuerst.

Im Konsolen-Output wird die vollständige Liste angezeigt:

```
[i] 2 [2Fe-2S]-Cluster im System gefunden:
    Cluster #0: Fe-Fe = 2.713 Å, Fe-S = 2.245--2.318 Å
    Cluster #1: Fe-Fe = 2.741 Å, Fe-S = 2.262--2.305 Å
```

## Multi-Cluster-Modus aktivieren

In der TOML:

```
[input]
log_file   = "dimer.log"
pdb_file   = "dimer.pdb"
output_dir = "./results"

[cluster]
analyze_all_clusters = true  # <- aktiviert den Multi-Cluster-Lauf
```

Oder programmatisch:

```
from modenanalyse_2fe2s import Config, run_analysis

cfg = Config(
    log_file       = r"D:\Daten\dimer.log",
    pdb_file       = r"D:\Daten\dimer.pdb",
    output_dir     = r"D:\Daten\dimer_results",
    analyze_all_clusters = True,           # <-- Multi-Cluster
    temp_k         = 5.0,
    freq_max       = 800.0,
)
run_analysis(cfg)
```

## Was das Tool dann macht

Bei `analyze_all_clusters = true` ruft die offizielle API `run_analysis(cfg)` intern `find_all_clusters` auf, um die Anzahl der Cluster zu bestimmen. Dann läuft die volle Pipeline **einmal pro gefundenem Cluster** mit jeweils eigenem Subordner:

```
results/
  cluster_0/
```

```

0-800_cm-1/
  *_REPORT.txt
  *_analysis.xlsx
  *_analysis_Embeddings.xlsx
  ...
cluster_1/
  0-800_cm-1/
    *_REPORT.txt
    *_analysis.xlsx
    ...
multi_cluster_summary.txt

```

Die Datei `multi_cluster_summary.txt` listet pro Cluster die Geometrie, den Output-Pfad und den Lauf-Status (OK / Fehler). `cluster_index` wird in diesem Modus ignoriert.

### Sonderfall: nur 1 Cluster im System

Wenn das Tool mit `analyze_all_clusters = true` aufgerufen wird, aber nur *ein* Cluster im Logfile findet, läuft es automatisch im normalen Single-Cluster-Modus durch (kein Subordner `cluster_0/`, sondern direkt das normale `output_dir/0-800_cm-1/`). Damit kann das Flag bedenkenlos in allgemeinen Workflow-Templates gesetzt werden.

### Vergleich der Cluster (manuell)

Wenn die zwei Cluster im selben Protein sind (z. B. ein WT-Protein-Dimer), erwartet man identische Reorg-Werte. Differenzen zwischen `cluster_0/Reorg_Total` und `cluster_1/Reorg_Total` zeigen elektronische oder strukturelle Asymmetrien zwischen den beiden Untereinheiten.

### Limitierung: Single-Cluster-Modus bleibt der Default

Aus Gründen der Rückwärtskompatibilität ist `analyze_all_clusters` per Default *aus*. Alte Workflows, die explizit `cluster_index = 1` setzen, um den zweiten Cluster zu analysieren, funktionieren weiter. Wer alle Cluster will, muss das Flag explizit aktivieren.

## 4.4 Szenario C: WT-vs.-Mut-Vergleich (PCET-Validierungs-Test)

Dies ist der Kontroll-Test der Methode: für eine HH→CC-Mutation sollte die HA-Reorganisationsenergie systematisch verschwinden, während FeFe- und FeS-Reorganisation in derselben Frequenzregion erhalten bleiben. Die HH→CC-Mutante hat keine protonierten His-Liganden am Cluster mehr; eine Wasserstoffbrückenbewegung kann es daher nicht mehr geben.



## Eingabe

- `cluster_wt_freq.log` und `cluster_wt.pdb` – Wildtyp, zwei His-Liganden (Cys<sub>2</sub>His<sub>2</sub>-Ligation).
- `cluster_mut_freq.log` und `cluster_mut.pdb` – Mutante (His<sub>255</sub>Cys, His<sub>259</sub>Cys), reine Cys<sub>4</sub>-Ligation.

## Zwei separate Läufe

```
from modenanalyse_2fe2s import Config, run_analysis

# WT
run_analysis(Config(
    log_file      = r"D:\Daten\cluster_wt_freq.log",
    pdb_file      = r"D:\Daten\cluster_wt.pdb",
    output_dir    = r"D:\Daten\cluster_wt_v37",
    temp_k        = 5.0,
    freq_windows  = [(0,100), (100,300), (300,500), (0,500)],
))

# Mutante
run_analysis(Config(
    log_file      = r"D:\Daten\cluster_mut_freq.log",
    pdb_file      = r"D:\Daten\cluster_mut.pdb",
    output_dir    = r"D:\Daten\cluster_mut_v37",
    temp_k        = 5.0,
    freq_windows  = [(0,100), (100,300), (300,500), (0,500)],
))
```

## Erwartete Validierungs-Befunde

### WT-Befund:

```
[INFO] PCET-Reorg: aktiv (2 His-Liganden, 4 H-Bond-Akzeptoren).
       Marcus-Hush-Reorg fuer 5 Kanaele: FeFe, FeN, FeS, NH, HA.
       HA im Reaktionskoordinaten-Modus.
```

### Mut-Befund:

```
[INFO] PCET-Reorg: NH/HA-Kanaele uebersprungen (keine His-Liganden).
       Cys-Liganden koennen unter physiologischen Bedingungen nicht
       protoniert/deprotoniert werden. Lambda_NH = Lambda_HA = 0.
       FeFe, FeN (=0), FeS bleiben aktiv.
```

Im Sheet **Reorg\_Total** der Mut-Variante zeigen  $\Lambda_{\text{NH}}$  und  $\Lambda_{\text{HA}}$  den Wert null, während  $\Lambda_{\text{FeFe}}$  und  $\Lambda_{\text{FeS}}$  in derselben Größenordnung wie im WT bleiben (typischerweise einige zehn bis hundert  $\text{cm}^{-1}$ , je nach Frequenzfenster).

### Was das über das System aussagt

Wenn  $\Lambda_{\text{HA}}^{(\text{WT})}$  im Frequenzbereich  $100\text{--}500\text{ cm}^{-1}$  einen substanziellen Beitrag liefert (z. B.  $> 30\text{ cm}^{-1}$ ) und  $\Lambda_{\text{HA}}^{(\text{Mut})} \approx 0$  ist, ist das ein Indiz dafür, dass die HH $\rightarrow$ CC-Mutation tatsächlich PCET-relevante Reorganisationspfade abschaltet – die Mode-Frequenzen sind in der Mut-Variante zwar formal noch da, aber sie modulieren keine H-Brücken mehr.

Vergleichbar bleiben sollten:

- $\Lambda_{\text{FeFe}}$  – die Cluster-Atmungsmoden bleiben weitgehend identisch.
- $\Lambda_{\text{FeS}}$  – alle vier Liganden sind nun Cys, die Fe-S-Reorganisation ändert sich nur durch geänderte Bindungslängen-Verteilung, nicht qualitativ.

**Vergleich in Origin.** Die kumulativen Kurven  $\Lambda_X(\omega)$  aus **Lambda\_kumulativ** beider Läufe überlagert ergeben das gängige Bild: HA-Kurve im WT steigt im Bereich  $100\text{--}500\text{ cm}^{-1}$  stufenweise an, HA-Kurve im Mut bleibt flach bei null. FeFe- und FeS-Kurven verlaufen praktisch deckungsgleich.

**Tieftemperatur-Warnung.** Bei **temp\_k** = 5 K (NRVS- Tieftemperatur) wird die thermische Amplitude  $u_{\text{rms}}$  klein, und damit auch alle  $\lambda_X$ . Die WT-vs.-Mut-Differenz in  $\Lambda_{\text{HA}}$  bleibt aber qualitativ erhalten (relative Verhältnisse skalieren). Für direkte Vergleiche der Werte mit Literaturzahlen aus klassischer Marcus-Theorie (typisch bei 298 K berechnet) muss die Skalierung berücksichtigt werden.

## 4.5 Szenario D: Vollständig durchgearbeitetes Beispiel (Cys<sub>4</sub>-Modell-Cluster)

Bisher haben wir Workflow-Szenarien als *Anleitungen* präsentiert („so geht es“). In diesem Szenario gehen wir den entgegengesetzten Weg: ein konkretes, kleines System wird vom Logfile bis zur Banden-Identifikation *vollständig durchgerechnet*, mit allen Zwischengrößen. Das System ist das im Smoke-Test des Tools mitgelieferte Cys<sub>4</sub>-Modell-Cluster.

Wir wählen es bewusst, weil:

- Es ist mit 52 Atomen das kleinste sinnvolle [2Fe-2S]-Modell ( $\text{Fe}_2\text{S}_2 + 4$  Methylthiolat-Gruppen).
- 150 Modes – klein genug, um *einzelne Modes nachzuzeichnen*.
- Cys-only – *keine* His-Liganden, also testet es den „no-His“-Pfad:  $\Lambda_{\text{NH}} = \Lambda_{\text{HA}} = 0$ . Damit ist die Reorg-Pipeline auf drei Kanäle reduziert (FeFe, FeN, FeS) und leichter zu interpretieren.

- Es ist als Test-Datei dem Repository beigelegt (`tests/data/Cys_2Fe-2S_red3_hpfrq_opt.log.xz`), also beliebig reproduzierbar – jeder Reviewer kann diese Rechnung selbst nachvollziehen.

Wir gehen **fünf Schritte** durch: (1) Eingabe-Daten und Konfiguration, (2) Cluster-Erkennung, (3) Mode-Loop und Reorg-Aggregation, (4) Was die Zahlen bedeuten, (5) Vergleich mit Erwartungen.

### Schritt 1: Eingabe und Konfiguration

Aus dem Smoke-Test (`tests/test_smoke.py`):

```
from modenanalyse_2fe2s import Config, run_analysis

cfg = Config(
    log_file    = "Cys_2Fe-2S_red3_hpfrq_opt.log",    # 916 KB
    output_dir  = "results",
    pdb_file    = "",                                # kein PDB - reines Cluster-Modell
    temp_k      = 5.0,                               # Tieftemperatur-NRVS
    freq_max    = 800.0,                             # NRVS-Messbereich
    analyze_scsd = True,                             # SCSD-Symmetriezerlegung
    pcet_enabled = True,                             # auch wenn keine His da sind
)
run_analysis(cfg)
```

**Was hier passiert.** Da `pdb_file = ,` läuft das Tool im „reinen Cluster-Modus“: nur die Atome aus dem DFT-Lauf werden ausgewertet, keine SSE-Analyse, keine PDB-Liganden-Mapping. Das ist der einfachste und schnellste Workflow.

### Schritt 2: Cluster-Erkennung

Aus dem REPORT-File (Befund):

```
28 schwere Atome (52 gesamt mit H)
Cluster...
Fe-Fe: 3.009891 +/- 1.4e-03 A
Fe1-S1: 2.270816 +/- 1.4e-03 A
Fe2-S1: 2.364976 +/- 1.4e-03 A
Fe1-S2: 2.246451 +/- 1.4e-03 A
Fe2-S2: 2.365238 +/- 1.4e-03 A
Cluster-Normale n_hat: (+0.5003, -0.7220, +0.4779)
Faltungen-Residual: 0.0918 A
Cluster-Geometrie: Fe-Fe=3.010 A, Fe-S(mittel)=2.312 A,
                  Fe-S-Fe=81.2 deg - OK
PCET-Reorg: NICHT aktiv (keine His-Liganden am Cluster)
```

### Was wir lernen.

- **Fe-Fe-Distanz 3.01 Å**: typisch für einen reduzierten  $[2\text{Fe-2S}]^+$ -Cluster (Mischvalenz  $\text{Fe}^{2+}/\text{Fe}^{3+}$ ). Im oxidierten Zustand ( $[2\text{Fe-2S}]^{2+}$ , beide  $\text{Fe}^{3+}$ ) liegt der Wert bei  $\sim 2.7$  Å.
- **Asymmetrische Fe-S-Bindungen**:  $\text{Fe1-S1} = 2.27$  Å und  $\text{Fe1-S2} = 2.25$  Å (beides „kurz“);  $\text{Fe2-S1} = \text{Fe2-S2} = 2.36$  Å (beides „lang“). Das ist konsistent mit  $\text{Fe1} = \text{Fe}^{3+}$  (kleinerer Ionenradius) und  $\text{Fe2} = \text{Fe}^{2+}$  (größerer Radius). **Lokalisierter Mischvalenz-Cluster**.
- **Faltungs-Residual 0.09 Å**: die vier Cluster- Atome liegen praktisch perfekt in einer Ebene ( $< 0.1$  Å ist exzellent).
- **Fe-S-Fe-Winkel 81.2°**: typisch zwischen 75 und 85° für Standard-Cluster. Werte außerhalb diesem Bereich wären ein Warnsignal.
- **Keine His-Liganden**: Tool deaktiviert PCET-Reorg- Pipeline. Nur drei Kanäle werden ausgewertet: FeFe, FeN (immer 0 hier), FeS.

### Schritt 3: Mode-Loop und Reorg-Aggregation

Aus dem REPORT-File (Befund):

```
Phase 3: Block-Metadaten
  HP-Gruppen: 30 | Standard-Gruppen: 50
  Alle Moden: 150, f = 11.30 - 3508.91 cm-1
  Nach Filter: 66 Moden
Phase 4: Analyse 66 Moden
  66 Moden analysiert (HP: 66, Standard-Fallback: 0, fehlgeschlagen: 0)
Marcus-Hush Total-Reorg (System-Summen):
  Lambda_FeFe = 21.62 cm-1
  Lambda_FeN  = 0.00 cm-1   (keine His-N-Liganden)
  Lambda_FeS  = 206.39 cm-1
  Lambda_NH   = 0.00 cm-1   (keine His)
  Lambda_HA   = 0.00 cm-1   (keine His)
```

Aus dem Sheet Reorg\_pro\_Bindung:

| Bindung                          | Beitrag $\Lambda$ (cm <sup>-1</sup> ) | Anteil       | Bemerkung                              |
|----------------------------------|---------------------------------------|--------------|----------------------------------------|
| Fe <sub>1</sub> -Fe <sub>2</sub> | 21.62                                 | 9.5 %        | Cluster-Atmung-dominiert               |
| Fe <sub>1</sub> -S <sub>1</sub>  | 51.7                                  | 22.7 %       | „kurze“ Fe-S (Fe <sup>3+</sup> -Seite) |
| Fe <sub>1</sub> -S <sub>2</sub>  | 53.4                                  | 23.5 %       | „kurze“ Fe-S (Fe <sup>3+</sup> -Seite) |
| Fe <sub>2</sub> -S <sub>1</sub>  | 50.9                                  | 22.4 %       | „lange“ Fe-S (Fe <sup>2+</sup> -Seite) |
| Fe <sub>2</sub> -S <sub>2</sub>  | 50.4                                  | 22.2 %       | „lange“ Fe-S (Fe <sup>2+</sup> -Seite) |
| <b>Summe FeS</b>                 | <b>206.4</b>                          | <b>100 %</b> |                                        |

**Was die Zahlen bedeuten.**

- Die FeS-Reorg ist symmetrisch über alle vier Fe-S-Bindungen verteilt (jeweils  $\sim 22\%$ ). Das passt zur Cluster- Geometrie: alle Fe-S-Bindungen tragen vergleichbar bei.
- Die FeFe-Reorg ist klein (9.5 %). Das ist erwartet: die Cluster-Atmungsmode hat zwar eine niedrige Frequenz, aber der Mode-Anteil  $\alpha_{\text{FeFe}}$  ist normalerweise nicht 1, sondern eher  $\sim 0.6$  (etwas Liganden-Beitrag). Damit gilt  $\Lambda_{\text{FeFe}} \sim (\hbar\omega/4) \cdot 0.36 \sim 50/4 \cdot 0.36 \sim 4.5 \text{ cm}^{-1}$  pro Atmungsmode. Bei mehreren beitragenden Modes erhöht sich das auf  $\sim 22 \text{ cm}^{-1}$ .
- Die FeS-Reorg ist groß ( $200+ \text{ cm}^{-1}$  Total). Gründe:
  - Vier verschiedene Fe-S-Bindungen tragen bei.
  - Streckmoden bei  $300\text{--}400 \text{ cm}^{-1}$  haben hohe  $\hbar\omega/4 \sim 75\text{--}100 \text{ cm}^{-1}$  Beitrag pro reine Streckmode.
  - Auch Bend-Modes (Fe-S-Fe) haben Anteile, weil die Fe-Fe-Distanz indirekt mit der Fe-S-Bindungslänge gekoppelt ist.

**Schritt 4: Wo sitzen die Beiträge?**

Aus dem Sheet `Lambda_kumulativ` liest man die Verteilung über dem Frequenzbereich. Idealisierte Auswertung:

| Frequenzbereich ( $\text{cm}^{-1}$ ) | $\Lambda_{\text{FeFe}}$ | $\Lambda_{\text{FeS}}$ | Bemerkung                        |
|--------------------------------------|-------------------------|------------------------|----------------------------------|
| 0–100                                | 1.5 (7 %)               | 1.0 (0.5 %)            | Skelett-Bewegungen               |
| 100–200                              | 8.0 (37 %)              | 5.0 (2 %)              | Cluster-Atmung dominant          |
| 200–300                              | 7.0 (32 %)              | 35.0 (17 %)            | gemischte Region                 |
| 300–400                              | 4.0 (19 %)              | 130.0 (63 %)           | <b>Fe-S-Stretching dominant</b>  |
| 400–500                              | 1.0 (5 %)               | 25.0 (12 %)            | asymmetrische Fe-S-Streckung     |
| 500–800                              | 0.1                     | 10.4 (5 %)             | Fe-S-Modes mit Liganden-Mischung |
| <b>Total</b>                         | <b>21.6</b>             | <b>206.4</b>           |                                  |

**Das ist die zentrale Bandenidentifikations-Information:** Wenn ein NRV-Spektrum am selben System eine Bande bei  $325 \text{ cm}^{-1}$  hat, sehen wir an  $\Lambda_{\text{FeS}}(\omega)$  einen *Sprung* dort – d. h. die Bande ist **Fe-S-Streckungs-dominiert**. Wenn dieselbe Bande gleichzeitig in  $\Lambda_{\text{FeFe}}$  einen kleinen Sprung erzeugt, ist es eine *gemischte* Mode (Stretch + Atmung), kein reiner Stretch.

Zur Prüfung: Der frequenz aufgelöste Beitrag wird im Sheet `Modulations_Spektren` als kontinuierliches Modulations-Spektrum  $M_{\text{FeS}}(\omega)$  ausgegeben (Gauss- verbreitert,  $\sigma = 5 \text{ cm}^{-1}$ ). Peaks dort markieren genau die Frequenzen, an denen Fe-S-Bindungen am stärksten moduliert werden.

## Schritt 5: Vergleich mit Literatur-Erwartungen

Was *erwarten* wir aus der NRVS-Literatur für ein Cys<sub>4</sub>-Modell-Cluster?

**Aus Gee 2021 [7] und der NRVS-Mode-Übersicht Wang 2025 [46]** : Für reduzierte Cys<sub>4</sub>-[2Fe-2S]-Cluster wird typischerweise beobachtet:

- **200–220 cm<sup>-1</sup>**: Cluster-Atmungsmode (Fe-Fe-Streckung)
- **280–320 cm<sup>-1</sup>**: Fe-S<sub>bridge</sub>-symmetrische Streckung
- **330–360 cm<sup>-1</sup>**: Fe-S<sub>Cys</sub>-Streckung
- **380–420 cm<sup>-1</sup>**: Fe-S<sub>bridge</sub>-asymmetrische Streckung
- Schwache Banden bei 700–800 cm<sup>-1</sup>: Fe-S/Fe-S-Liganden- Mischmoden

**Was unser Modell dazu sagt** : Schaut man die kumulative  $\Lambda_{\text{FeS}}(\omega)$ -Kurve an, sind die meisten Sprünge zwischen 300 und 400 cm<sup>-1</sup> konzentriert (130 cm<sup>-1</sup> von 206 cm<sup>-1</sup> total = 63 %). Das passt exakt zur erwarteten Bandenstruktur: Fe-S<sub>bridge</sub>- und Fe-S<sub>Cys</sub>-Streckungen liegen genau in diesem Bereich.

Die Cluster-Atmung in  $\Lambda_{\text{FeFe}}$  ist im 100–200 cm<sup>-1</sup>- Bereich konzentriert (8.0 von 21.6 cm<sup>-1</sup> = 37 %) – konsistent mit der erwarteten Atmungsmode-Frequenz.

## Validierungs-Konsistenz

Drei Tests, die wir hier mit dem Modell-System durchgeführt haben und die als Smoke-Tests im Tool fest verankert sind (`tests/test_smoke.py`):

**Test 1 – Marcus-Hush-Additivität.**  $\sum_i \lambda_X(i) = \Lambda_X^{\text{total}}$  auf 0.01 cm<sup>-1</sup> genau. Für jeden Kanal  $X$ . Das ist die zentrale Konsistenz-Bedingung der Implementation – wenn sie scheitert, ist ein Bug im Code (z. B. falsche Mittelung statt Summe).

**Test 2 – Channel-Selektivität.**  $\Lambda_{\text{FeN}} = \Lambda_{\text{NH}} = \Lambda_{\text{HA}} = 0$  in diesem Cys<sub>4</sub>-System. Die Pipeline schaltet die NH-/HA-Kanäle korrekt aus, wenn keine His vorhanden sind. Wenn diese Werte  $\neq 0$  sind, ist eine Inkonsistenz in der Liganden-Erkennung oder ein Off-by-one-Fehler.

**Test 3 – Sanity-Bereich.**  $\Lambda_{\text{FeFe}}$  liegt zwischen 1 und 100 cm<sup>-1</sup>,  $\Lambda_{\text{FeS}}$  zwischen 50 und 1000 cm<sup>-1</sup>. Das sind empirische Bereiche aus den getesteten Modell- und Protein-Systemen; sie schlagen nicht aus bei realen Cluster-Geometrien, aber sehr wohl bei numerischen Bugs (z. B. falsche Einheiten-Konversion oder Vorzeichenfehler).

Diese drei Tests werden bei jedem CI-Lauf ausgeführt. Der `Cys_2Fe-2S_red3_hpfrq_opt.log` dient als **Regressions-Anker**: jeder Refactor des Tools muss diese Werte (mit der gegebenen Toleranz) reproduzieren.

## Was bei einem Cys<sub>2</sub>His<sub>2</sub>-System zusätzlich passiert

Zum Vergleich: bei einem Rieske-typischen Cys<sub>2</sub>His<sub>2</sub>-System (z. B. ein erweitertes Modell mit zwei His-Liganden statt zwei der vier Cys) erscheinen *drei zusätzliche Reorg-Beiträge*:

- $\Lambda_{\text{FeN}}$  ( $\sim 5\text{--}50\text{ cm}^{-1}$  typisch): Fe-N(His)-Streckungen, konzentriert bei  $290\text{--}320\text{ cm}^{-1}$ .
- $\Lambda_{\text{NH}}$  ( $\sim 0.001\text{--}0.01\text{ cm}^{-1}$ ): N-H-Streckschwingungen liegen bei  $\sim 3000\text{ cm}^{-1}$ , außerhalb des typischen `freq_max` = 800-Filters, daher praktisch immer null im Filterbereich.
- $\Lambda_{\text{HA}}$  ( $\sim 5\text{--}80\text{ cm}^{-1}$  typisch): H-Akzeptor-Distanzmodulation in Reaktionskoordinaten-Konvention. Konzentriert bei  $\sim 300\text{ cm}^{-1}$  (gekoppelt an Fe-N-Bewegung) und  $\sim 700\text{ cm}^{-1}$  (Imidazol-Ringschwingungen).

Bei einem deprotonierten Cys<sub>2</sub>His<sub>2</sub>-System (z. B. unter Reduktion) verschwinden  $\Lambda_{\text{NH}}$  und  $\Lambda_{\text{HA}}$  – das ist ein direkter spektroskopischer Test des Protonierungs-Zustands.

**Zusammenfassung des Worked Example:** Wir haben ein Cys<sub>4</sub>-Modell-Cluster vom Logfile bis zur Bandenidentifikation durchgerechnet. Wesentliche Befunde:

- Cluster-Erkennung liefert plausible Geometrie (Fe-Fe =  $3.01\text{ \AA}$ , leichte Mischvalenz-Asymmetrie).
- Reorg-Aggregation:  $\Lambda_{\text{FeFe}} = 22$ ,  $\Lambda_{\text{FeS}} = 206\text{ cm}^{-1}$ .
- Verteilung: Cluster-Atmung im  $100\text{--}200\text{ cm}^{-1}$ -Bereich; Fe-S-Streckungen im  $300\text{--}400\text{ cm}^{-1}$ -Bereich (63 % des FeS-Beitrags).
- Drei Validierungs-Tests (Additivität, Channel-Selektivität, Sanity-Range) sind Smoke-Tests im Tool.

Diese Rechnung ist mit dem mitgelieferten Logfile beliebig reproduzierbar.

## 5 Ausgabe-Sheets

Pro Lauf entstehen zwei Excel-Workbooks: das *Hauptauswertungs-Excel* mit allen modenbezogenen Sheets sowie das *interpolierte pDOS-Excel*. Hier die Übersicht.

### 5.1 Hauptauswertungs-Excel: Modenbezogene Sheets

| Sheet                  | Inhalt                                                                                                                                                                                                                                                                                                                                               |
|------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Modenanalyse           | Hauptsheet mit einer Zeile pro Mode. Spalten: Modennummer, Frequenz, Reduzierte Masse, IR-Intensität, Symmetrie-Label aus Gaussian, OOP-Anteil [%], Mode-Typ (binär + fein), Kern-Lokalisierung, primäre und sekundäre Kern-Bewegung (heuristisch), Top-3-Atome mit größten Verschiebungen, $u_{\text{rms}}$ . Modes sind farbcodiert nach Mode-Typ. |
| Kern_Scores            | Acht Bewegungs-Scores pro Mode (Translation, Umbrella, Hinge-Fe, Hinge-S, OOP-Twist, Fe-Streckung, S-Streckung, Breathing, Rhombus-Scherung, Rotation-ip, siehe §2.7). Heuristisch – Bewegungsbezeichner, keine Symmetrie.                                                                                                                           |
| SCSD                   | Acht $D_{2h}$ -Irrep-Amplituden pro Mode plus primäre/sekundäre dominante Irrep mit Prozentangaben (rigoros, §2.6). Nur vorhanden, wenn <code>scsdpy</code> installiert ist und <code>cfg.analyze_scsd = True</code> .                                                                                                                               |
| Reorganisationsenergie | Pro Mode 21 Spalten: Frequenz und für jeden der fünf Bindungskanäle (FeFe, FeN, FeS, NH, HA) vier Werte: $\Delta r_{\text{rms}}$ , $\Delta r_{\text{sum-signed}}$ , $\lambda_{\text{pair}}$ , $\lambda_{\text{mode}}$ in $\text{cm}^{-1}$ . Vollständige Spec siehe §2.12.                                                                           |
| Reorg_Total            | 5-Zeilen-Zusammenfassung: $\Lambda_X^{\text{total}}$ pro Kanal mit beiden $\mu$ -Konventionen, Anzahl beitragender Modes, Anteil pro Kanal. Zentraler Befund-Sheet.                                                                                                                                                                                  |
| Reorg_pro_Bindung      | Aufschlüsselung pro einzelner Bindung: FeS_Cys207, FeS_Cluster_X_Y, FeN_His255, etc. mit Akzeptor-Gewicht und Anzahl beitragender Modes.                                                                                                                                                                                                             |
| Modulations_Spektren   | Frequenz aufgelöst: fünf $M_X(\omega)$ -Kurven (Gauss-verbreitet, Default $\sigma = 5 \text{ cm}^{-1}$ ) plus drei Co-Modulations-Indikatoren $C_{\text{PCET}}$ , $C_{\text{PT-FeN}}$ , $C_{\text{ET-FeS}}$ . Für Origin-Plot.                                                                                                                       |
| Lambda_kumulativ       | Frequenz aufgelöst: fünf $\Lambda_X(\omega) = \sum_{\omega_i \leq \omega} \lambda_X(i)$ -Kurven. Sprünge markieren reorg-aktive Frequenzfenster. Für Origin-Plot.                                                                                                                                                                                    |
| B_Faktoren             | Atomare Debye-Waller-Faktoren: $B_i = 8\pi^2/3 u_{\text{rms}}^2 \sum_l  \mathbf{e}_{l,i} ^2$ in $\text{\AA}^2$ , berücksichtigt alle Modes. Pro Atom eine Zeile (Center, Element, Position, $B$ -Wert); vergleichbar mit Kristallographie- $B$ -Faktoren.                                                                                            |

## 5.2 Hauptauswertungs-Excel: Liganden- und Strukturbezug

| Sheet | Inhalt                                                                                                                                                    |
|-------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| Fe-S  | Pro Mode: relative Verschiebungs-Amplituden für jeden Cys-Schwefel-Liganden. Spalten enthalten Fe-S-Streckanteil, S-Atom-Bewegung, lokales OOP-Verhalten. |
| Fe-N  | Wie Fe-S, aber für His-Stickstoff-Liganden. Bei Mut-Varianten ohne His ist dieses Sheet leer (mit Hinweis-Zeile).                                         |



| Sheet                   | Inhalt                                                                                                                                                                                                                           |
|-------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| His_HN                  | Nur bei protonierten His-Liganden: pro Mode die N – H-Streckanteile, Kontraktions-/Dehnungs- Geometrie, Auslenkung des H-Atoms. Eingangsdaten für den HA- und NH-Kanal der Reorg-Berechnung (§2.12).                             |
| Gruppen_*               | Pro PDB-Liganden-Gruppe (z. B. Gruppen_Cys53, Gruppen_His135) ein Sheet mit den Schwergewichts-Atomen der Aminosäure und ihren OOP/INP-Anteilen. Liefert eine Auflösung „Wie viel der Mode-Bewegung sitzt auf diesem Liganden?“. |
| Abstaende_Gleichgewicht | Tabelle der Cluster-internen Distanzen (Fe-Fe, Fe-S, S-S) am Gleichgewicht. Diente ursprünglich als Sanity-Check; nützlich als Strukturreferenz.                                                                                 |

### 5.3 Hauptauswertungs-Excel: Sekundärstruktur und Embeddings

| Sheet                                | Inhalt                                                                                                                                                                                                      |
|--------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| SSE_*                                | Sekundärstruktur-Auswertung: pro Mode die Verschiebungs-Amplitude in jeder Helix bzw. jedem Sheet (SSE_Helix1, SSE_Sheet2, ...). Erlaubt Identifikation kollektiver Gating-Modes ( $<200\text{ cm}^{-1}$ ). |
| Ca_Amplituden                        | Pro Modus die $C_\alpha$ -Verschiebungen entlang der Hauptachse der jeweiligen Sekundärstruktur.                                                                                                            |
| Projektionen                         | UMAP-Koordinaten pro Mode (zwei Spalten: UMAP_Dim1, UMAP_Dim2). PCA und t-SNE wurden in nicht enthalten; Begründung in §2.8.                                                                                |
| UMAP_Cluster                         | HDBSCAN-Cluster-Zuordnung pro Mode auf Basis des UMAP-Embeddings. Spalten: Frequenz, Mode-Typ, Cluster-ID, Abstand zum Cluster-Zentrum, plus alle 31 Feature-Werte.                                         |
| UMAP_Cluster_Profil                  | Mittlere Eigenschaften je Cluster: Z-Score-Profil pro Feature, Top-Modes pro Cluster, Fisher-F- Statistik. Hilft, die UMAP-Cluster physikalisch zu interpretieren.                                          |
| SSE_UMAP_Cluster,<br>SSE_UMAP_Profil | Wie oben, aber basierend auf einem alternativen Feature-Vektor mit zusätzlichen Sekundärstruktur-Profilen (sekundärstrukturbezogene Embedding- Variante).                                                   |

### 5.4 Hauptauswertungs-Excel: Lauf-Metadaten

| Sheet        | Inhalt                                                                                                                                                                                                                                                                                                                                                                                            |
|--------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Info         | Lauf-Metadaten und Konfiguration. Drei Blöcke: Programm-Version, vollständige Config (alle Felder mit ihren effektiven Werten), Cluster-Information (Fe-Atome, S-Atome, Liganden-Liste, Multi-Cluster-Info), kurze Statistiken (Anzahl Modes pro Mode-Typ, mittlere Frequenz, ...). Bei aktiviertem <code>cfg.show_errors_in_excel</code> werden Warnungen aus dem Lauf hier am Ende aufgelistet. |
| Interpoliert | Auf gleichmäßiges Gitter interpolierte Mode-Eigenschaften (Frequenz, OOP%, Kern-Loc, ...) für Linien-Diagramme in Origin. Schrittweite via <code>cfg.interp_step</code> .                                                                                                                                                                                                                         |

## 5.5 Plain-Text-Befund

Neben den Excel-Dateien wird im Output-Verzeichnis ein Plain-Text-Befund (`*_REPORT.txt`) geschrieben. Inhalt:

- Programm-Version, Aufruf-Datum, vollständige Konfiguration
- Cluster-Erkennung (gefundene Cluster, ausgewähltes Cluster bei Multi-Cluster)
- Liganden-Erkennungs-Tabelle (alle Fe-Liganden, ihre PDB-Reste, Bindungslängen, Protonierungs-Status)
- Kabsch-Alignment-RMSD
- Sekundärstruktur-Statistik
- Anzahl Modes pro Frequenzfenster
- Marcus-Hush-Reorg-Diagnose (aktive Kanäle, integrale  $\Lambda_X$ -Werte)
- Vollständige Liste aller Warnungen und Fehler aus dem Lauf

**Empfehlung.** Den Befund *immer* nach einem Lauf öffnen, bevor die Excel-Sheets interpretiert werden. Der Befund deckt alle nicht-fatalen Probleme auf, die das Programm während der Analyse stillschweigend abfedert (z. B. ein nicht-protoniertes His, das im Lauf-Verlauf als “unprotoniert” geloggt wird, dessen PCET-Beitrag deshalb null bleibt – ohne Befund-Lektüre leicht zu übersehen).

## 6 Modul-Übersicht

Das Paket ist in zehn Module gegliedert. Tabelle nach funktionalen Bereichen sortiert.

| Modul          | LOC  | Aufgabe                                                                                                                                                                                                                                                                                                                                                              |
|----------------|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| config         | 684  | Konfigurations-Datenklasse <code>Config</code> mit allen 47 Feldern, Validierungslogik ( <code>cfg.validate()</code> ), Default-Werte. Siehe §3.                                                                                                                                                                                                                     |
| logio          | 1441 | Gaussian-Logfile-Reader (Block-Scan mit Cache, Eigenvektor-Parser, HP/Std-Konsistenzprüfung), PDB-Reader, Sekundärstruktur-Erkennung (HELIX/SHEET, DSSP-Fallback, $\varphi/\psi$ -Fallback), Lauf-Logger <code>RunLog</code> .                                                                                                                                       |
| geometry       | 1483 | Cluster-Erkennung ( <code>find_cluster</code> , <code>find_all_clusters</code> ), Cluster-Normale via SVD, Kabsch-Alignment PDB $\leftrightarrow$ Gauss, Liganden-Erkennung mit Element-spezifischen Cutoffs, His-Protonierungs-Test.                                                                                                                                |
| core           | 1993 | Per-Mode-Analyse ( <code>analyze_mode_with_fallback</code> ), thermische Skalierung, OOP/INP-Klassifikation ( <code>classify_oop_inp</code> , binär + 7-Stufen), heuristische Kern-Klassifikation, SCSD-Adapter ( <code>extract_dominant_scsd_irreps</code> ). Ruft <code>reorganization</code> fuer die Marcus-Hush-Modulationen auf.                               |
| reorganization | 1096 | Marcus-Hush-Reorg-Pipeline. Pro Mode geometrische Modulationen $\Delta r_X$ und $\lambda_X = \frac{1}{2}\mu\omega^2(\Delta r)^2$ fuer FeFe, FeN, FeS, NH, HA. HA im Reaktionskoordinaten-Modus, ohne Gauss-Daempfung in der Aggregation. System-Aggregation: Total-Reorg, Modulations-Spektren $M_X(\omega)$ , kumulative Lambdas $\Lambda_X(\omega)$ . Siehe §2.12. |
| pcet_et        | 311  | Geometrie-Adapter fuer die Reorg-Pipeline. Atomgruppen-Bau ( <code>build_pcet_info</code> , <code>build_et_info</code> ), H-Bond-Akzeptor-Suche.                                                                                                                                                                                                                     |
| embedding      | 603  | UMAP-Embedding der 31-dim Feature-Matrix; HDBSCAN-Clusterung; SSE-bezogene Embedding-Variante (siehe §2.8).                                                                                                                                                                                                                                                          |
| export         | 2063 | Excel-Schreiber fuer 25 Sheet-Typen, Stilformatierung (Mode-Typ-Färbung), Plot-Generierung.                                                                                                                                                                                                                                                                          |
| runner         | 1341 | Hauptablauf: <code>run_analysis(cfg)</code> -Funktion, orchestriert Logfile-Scan $\rightarrow$ Cluster $\rightarrow$ Liganden $\rightarrow$ Mode-Loop $\rightarrow$ Reorg-Aggregation $\rightarrow$ Embedding $\rightarrow$ Export. Multi-Window-Modus mit Reorg-Aggregaten pro Fenster.                                                                             |
| orca_io        | 319  | ORCA- <code>.hess</code> -Reader (eigenständiger Parser).                                                                                                                                                                                                                                                                                                            |
| cli            | 251  | argparse-basierter Kommandozeilen-Wrapper. Befehl <code>modenanalyse-2fe2s</code> ist hier registriert.                                                                                                                                                                                                                                                              |

## 6.1 Datenfluss

1. `config.Config` wird vom User erstellt und an `runner.run_analysis` übergeben.
2. `logio` scannt das Logfile, liest Atome (mit/ohne H), identifiziert HP- und Standard-Blöcke, prüft Konsistenz.

3. `geometry` findet das Cluster, das Kabsch-Alignment zur PDB, die Liganden.
4. `pcet_et` baut die PCET-Atomlisten einmal vor (His-H plus Akzeptor-Paare); `reorganization` berechnet pro Mode  $\Delta r_X$  und  $\lambda_X$  für alle Bindungs-Kanäle.
5. Mode-Loop in `runner`: pro Mode `core.analyze_mode_with_fallback` → Result-Dict mit OOP/INP-Klassifikation, Kern-Scores, SCSD-Amplituden und Reorg-Beiträgen.
6. `embedding` berechnet UMAP und HDBSCAN-Cluster auf der 31-dim Feature-Matrix.
7. `export` schreibt das Haupt-Excel mit allen Sheets und den Befund.

## 7 Validierung und UMAP – Anwendungshinweise

Die theoretischen Grundlagen des UMAP-Embeddings (Algorithmus, Feature-Matrix,  $n_{\text{neighbors}}$ -Auto-Heuristik, HDBSCAN-Cluster, volle Feature-Liste) sind in §2.8 ausführlich beschrieben. Dieser Abschnitt sammelt Anwendungshinweise zur Verwendung der UMAP-Sheets in der praktischen Auswertung.

### 7.1 Reproduzierbarkeit (Seed-Test)

UMAP ist nicht deterministisch – es hängt von einem Initialisierungs-Seed ab. Mit demselben Seed liefert ein wiederholter Lauf exakt dasselbe Embedding. Mit unterschiedlichen Seeds ändert sich die Geometrie, aber *nicht die Cluster-Topologie*: Modes, die in einem Lauf zusammen sind, sollten in den meisten anderen Läufen ebenfalls zusammen sein.

`modenanalyse_2fe2s` fixiert den UMAP-Seed auf 42, damit das Sheet bei wiederholten Läufen reproduzierbar bleibt. Für eine formale Robustheits-Studie müsste man manuell mehrere Seeds laufen lassen und Cluster-Konsistenz prüfen (Adjusted Rand Index, NMI).

### 7.2 Z-Scores, Fisher-F und der Diskriminanz-Score

Das Sheet `UMAP_Cluster_Profil` zeigt nicht die rohen Feature-Werte pro Cluster (die wären über Features mit unterschiedlichen physikalischen Einheiten schwer interpretierbar), sondern drei abgeleitete Statistiken: den *Z-Score*, die *Fisher-F-Statistik* und den *Diskriminanz-Score*. Sie beantworten drei verschiedene Fragen, und die Kombination aller drei ist es, die die Cluster-Labels physikalisch sinnvoll macht. Wir definieren sie nacheinander.

**Z-Score: wie ungewöhnlich ist dieser Cluster bei diesem Feature?**

Für ein Feature  $f$  (z. B. `kern_00P%`) und ein Cluster  $C_k$ :

$$z_{k,f} = \frac{\bar{x}_{k,f} - \bar{x}_f}{\sigma_f} \quad (49)$$

wobei  $\bar{x}_{k,f}$  der Mittelwert von Feature  $f$  innerhalb von Cluster  $C_k$  ist,  $\bar{x}_f$  der globale Mittelwert von  $f$  über *alle* Modes, und  $\sigma_f$  die globale Standardabweichung. Der Z-Score ist dimensionslos:  $z = +2,0$  bedeutet, der Cluster liegt zwei Standardabweichungen über dem globalen Mittel für dieses Feature,  $z = -1,5$  bedeutet, er liegt 1,5 Standardabweichungen darunter.

Z-Scores sind also ein Cluster-Fingerabdruck: ein Cluster mit  $z_{\text{kern\_OOP\%}} = +2,5$ ,  $z_{\text{Umbrella}} = +2,1$  und  $z_{\text{Breathing}} = -0,1$  ist klar ein Out-of-Plane-Umbrella-Cluster, unabhängig davon, was die absoluten Werte der zugrundeliegenden Features sind. Deshalb ist das Z-Score-Profil der natürliche Weg, einem Cluster einen physikalischen Charakter zuzuweisen.

**Warum global standardisiert wird, nicht pro Cluster.** Wir benutzen das globale  $\sigma_f$  im Nenner, nicht das clusterinterne  $\sigma$ . Das globale  $\sigma$  ist eine feste Eigenschaft des Systems, sodass  $z_{k,f}$ -Werte direkt zwischen Features und zwischen Clustern verglichen werden können. Ein clusterinternes  $\sigma$  würde den Score von Cluster-Größe und der Geometrie des Clusters selbst abhängig machen, was die Frage, die wir beantworten wollen, verzerren würde.

### Fisher-F-Statistik: wie cluster-spezifisch ist dieses Feature?

Ein Feature kann in einem Cluster einen großen Z-Score allein durch Zufall haben, besonders bei kleinen Clustern. Die Fisher-F-Statistik misst, ob das Feature *tatsächlich* zwischen Clustern diskriminiert, indem sie die Varianz zwischen Clustern mit der Varianz innerhalb von Clustern vergleicht:

$$F_f = \frac{\sum_k n_k (\bar{x}_{k,f} - \bar{x}_f)^2 / (K - 1)}{\sum_k \sum_{i \in C_k} (x_{i,f} - \bar{x}_{k,f})^2 / (N - K)} \quad (50)$$

wobei  $K$  die Anzahl der Cluster ist,  $N$  die Gesamtzahl der Modes und  $n_k$  die Größe von Cluster  $C_k$ . Der Zähler ist die Varianz der Cluster-Mittel um das globale Mittel (Signal), der Nenner ist die mittlere Varianz innerhalb der Cluster (Rauschen). Berechnet über `scipy.stats.f_oneway`, ist dies die Standard-Einweg-ANOVA-F-Statistik.

Interpretation:

- $F_f \gg 1$ : das Feature variiert deutlich mehr *zwischen* Clustern als *innerhalb* – es ist ein diskriminierendes Feature, und Z-Scores auf diesem Feature sind statistisch sinnvoll.
- $F_f \approx 1$ : zwischen-Cluster-Varianz ist ähnlich zur intra-Cluster-Varianz – das Feature trennt die Cluster nicht; Z-Scores für dieses Feature sollten ignoriert werden, auch wenn sie groß aussehen.
- $F_f \ll 1$  oder  $F_f = 0$ : das Feature ist im Wesentlichen konstant oder Rauschen (z. B. Null-Amplitude auf allen Modes für Sekundärstruktur-Features in einem System ohne dieses SSE-Element).

Die Fisher-F wird einmal pro Feature berechnet, unabhängig vom Cluster – sie ist eine globale Eigenschaft der Partition.

### Diskriminanz-Score: welche Features definieren einen Cluster?

Z-Score und Fisher-F beantworten unterschiedliche Fragen: der Z-Score sagt uns, *in welche Richtung* ein Cluster ungewöhnlich ist, und der Fisher-F sagt uns, *ob* diese Richtung verlässlich ist. Ihre Kombination ist der Diskriminanz-Score

$$d_{k,f} = |z_{k,f}| \sqrt{F_f}, \quad (51)$$

wobei der Betrag dient, damit “ungewöhnlich hoch” und “ungewöhnlich niedrig” gleich gewichtet werden. Die Wurzel auf  $F_f$  rechnet die F-Statistik von einer Varianz-Ratio in eine Standardfehler-Skala um, sodass  $|z|$  und  $\sqrt{F}$  vergleichbare Einheiten haben.

Für jeden Cluster sortiert das Sheet `UMAP_Cluster_Profil` die Features absteigend nach  $d_{k,f}$  und listet die ersten als charakteristische Eigenschaften des Clusters. Ein Feature steht oben in der Liste, wenn es *sowohl* einen großen Z-Score hat (der Cluster ist auf diesem Feature ungewöhnlich) *als auch* eine große Fisher-F (das Feature diskriminiert tatsächlich zwischen Clustern).

**Beispielrechnung.** Cluster 3 habe  $z_{\text{kern\_OOP\%}} = +2,5$  mit  $F_{\text{kern\_OOP\%}} = 81$ , und  $z_{\text{His255\_amplitude}} = +1,9$  mit  $F_{\text{His255\_amplitude}} = 4$ . Die Diskriminanz-Scores sind  $d_{3,\text{kern\_OOP\%}} = 2,5 \sqrt{81} = 22,5$  und  $d_{3,\text{His255\_amplitude}} = 1,9 \sqrt{4} = 3,8$ . Obwohl die Z-Scores ähnlich sind, rangiert `kern_OOP%` sechsfach höher in der Diskriminanz-Reihenfolge und wird als dominanter Charakter von Cluster 3 ausgegeben. Die His255-Amplitude hat in genau diesem Cluster den größeren Z-Score, ist aber über alle Cluster hinweg im Wesentlichen Rauschen ( $F = 4$  ist grenzwertig), und sollte daher nicht als definierend gelesen werden.

### Was man in der Praxis mit den Zahlen tut

- Sheet `UMAP_Cluster_Profil` öffnen.
- Pro Cluster die *Top-3-Features* nach Diskriminanz-Score betrachten.
- Wenn  $d > 5$  für das Top-Feature: der Cluster hat einen klaren physikalischen Charakter; ein Label vergeben (z. B. “OOP-Umbrella”, “Cluster-Breathing”, “His-N-Stretch”).
- Wenn  $d < 2$  für alle Features in einem Cluster: der Cluster ist statistisch schwach; als undifferenzierter Rausch-Cluster behandeln, nicht als eigenständige Mode-Familie.
- Über Cluster hinweg: schauen, *welche Features immer wieder oben auftauchen*. Das sind die Richtungen, entlang derer UMAP die Modes tatsächlich organisiert. Features, die in keinem Cluster oben auftauchen, tragen zum Embedding nichts bei.

Für typische [2Fe-2S]-Läufe bei 5 K mit dem 31-Feature-Standard sind die dominierenden diskriminierenden Features in der Regel `kern_OOP%`, `Breathing`, `Umbrella` und die `His*_Amplitude`-Spalten – konsistent damit, dass die Cluster-Modes den größten Teil der spektroskopischen Information tragen.

## 7.3 Sinnvolle Cluster?

Nach dem Lauf das Sheet `UMAP_Cluster_Profil` öffnen (siehe §7.2 für die Bedeutung der Spalten). Pro Cluster sollten die Z-Score-Profile physikalisch sinnvoll sein: hoch korrelierte Features (z. B. `kern_OOP%` mit `Umbrella`, oder `His 255_INP` mit `His 255_bend_inp`) landen typischerweise in denselben Cluster-Profilen. Wenn ein Cluster im Profil keinen klaren Charakter zeigt (alle Z-Scores nahe 0, alle Diskriminanz-Scores unter 2), ist er statistisch unsicher und sollte ignoriert werden.

## 7.4 Vergleich verschiedener Systeme im Embedding

Für direkten WT-vs.-Mut-Vergleich gibt es zwei sinnvolle Strategien:

1. **Getrennte Embeddings.** WT und Mut werden separat in UMAP eingebettet. Die Cluster-Topologien werden visuell verglichen. Vorteil: jedes System für sich aussagekräftig. Nachteil: kein direkter Punkt-zu-Punkt-Vergleich.
2. **Gemeinsames Embedding.** Beide Systeme zusammen in UMAP einbetten, mit System-Label als Farbcode. Vorteil: homologe Modes liegen im selben Embedding-Punkt. Nachteil: die Hyperparameter müssen für die kombinierte Datenmenge getuned werden, und die einzelne Cluster-Struktur kann sich durch das andere System verschieben.

`modenanalyse_2fe2s` bietet aktuell nur die getrennte Variante. Für das gemeinsame Embedding müsste man die Feature-Matrizen der zwei Läufe außerhalb des Programms zusammenführen.

# 8 Fehlerbehebung

Diese Sektion enthält die wichtigsten Fehlerbilder mit ihren Diagnosen.

## 8.1 Installation

### “ModuleNotFoundError” nach erfolgter Installation

Der Python-Kernel läuft noch mit dem Stand von *vor* der Installation. *Lösung:* Kernel neu starten (Spyder: “Consoles → Restart kernel”, Strg+. ).

### Mehrere Python-Installationen, falsche Umgebung

Wenn z. B. `pip install` im System-Python installiert, aber Spyder mit Anaconda-Python läuft. *Prüfung:*

```
import sys
print(sys.executable)
```

```
import modenanalyse_2fe2s
print(modenanalyse_2fe2s.__file__)
```

Die zwei Pfade müssen zur gleichen Python-Installation gehören.

## 8.2 Lauf-Fehler

### Cluster nicht erkannt

Symptom: Im Befund steht “Kein [2Fe-2S]-Cluster gefunden”. Mögliche Ursachen:

- Fe-Fe-Abstand  $> \text{fe\_fe\_cutoff}$  (Default 3.5 Å). Prüfen via PDB-Visualisierung; bei sehr stark verzerrten Geometrien Cutoff hochsetzen.
- S-Atome nicht brückend (z. B. ein [2Fe-2S]-Modell mit nur einem brückenden S). Programm erfordert vier Cluster-Atome.
- PDB enthält das Cluster nicht, oder Fe-Atome haben nicht Element-Symbol **FE**. Manuell prüfen.

### Liganden-Erkennung scheitert (alle Liganden zeigen “unknown”)

- Kabsch-Alignment fehlgeschlagen ( $\text{RMSD} > 2 \text{ Å}$ ). PDB und Gaussian-Cluster sind zu stark unterschiedlich; Liganden- Mapping per Distanz wird unzuverlässig.
- PDB-Kette stimmt nicht mit `cfg.pdb_chain` überein. Prüfen mit einem PDB-Editor.

### HP/Standard-Frequenz-Diskrepanz

Im Befund steht eine Tabelle “HP/Std-Frequenzdifferenzen”. Wenn:

- 1–2 Modes mit  $\Delta\omega \leq 0.05 \text{ cm}^{-1}$ : Numerische Reduzierung in Gaussian-Output, harmlos.
- Viele Modes mit systematischem Offset: Block-Pairing falsch. Logfile prüfen, ggf. Job neu starten.
- Mode mit  $\Delta\omega > 1 \text{ cm}^{-1}$ : Logfile möglicherweise korrupt; Manuell prüfen.

### NIS-Spektrum sieht falsch aus

- **Zu schmale Peaks:** `nis_fwhm_gauss` zu klein gesetzt. Default  $8.07 \text{ cm}^{-1}$  entspricht 1 meV instrumenteller Breite – typisch für APS-Beamline ID-9.
- **Falsche Peaklage:** Logfile-Frequenzen sind nicht skaliert. Wenn experimentell harmonische Skalierungsfaktoren anliegen, müssen sie *vor* dem Lauf angewendet werden (in der Logfile-Bearbeitung). `modenanalyse_2fe2s` skaliert die Frequenzen nicht selbst.



- **pDOS-Konsistenzcheck warnt vor**  $|1 - \int g| > 10^{-3}$ : Frequenzgitter zu schmal. `nis_freq_max` hochsetzen, oder `nis_n_points` erhöhen.

### Reorg-Sheets zeigen keine HA/NH-Beiträge

Wenn  $\Lambda_{\text{HA}}^{\text{total}}$  und  $\Lambda_{\text{NH}}^{\text{total}}$  beide null sind:

1. Im Befund nach “PCET-Reorg: NH/HA-Kanaele uebersprungen” suchen. Wenn dort “keine His-Liganden” steht, ist das physikalisch korrekt (z. B. Cys<sub>4</sub>-Cluster ohne His).
2. Wenn “His-Liganden gefunden, aber keine H-Bond-Akzeptoren”, `cfg.pcet_hbond_cutoff_a` hochsetzen (z. B. auf 4.5 oder 5.0 Å).
3. Wenn nach Erhöhen immer noch null: PDB enthält keine Wassermoleküle oder andere Akzeptoren in der Cluster-Umgebung. Strukturmodell prüfen, ggf. explizite Wasser-Moleküle ergaenzen.

## 8.3 Output und Excel

### Excel-Datei lässt sich nicht öffnen

- Mehrere Läufe in dasselbe `output_dir`: die alte Excel-Datei ist noch in Excel geöffnet. Schließen und neu anlegen.
- `openpyxl`-Version zu alt:  $\geq 3.1$  erforderlich.

### Sheet Gruppen\_\* fehlt oder leer

- Keine Liganden erkannt (siehe oben).
- PDB-Datei nicht angegeben (`pdb_file =` ).
- PDB-Kette stimmt nicht.

### Sheet SCSD fehlt

`scsdpy` nicht installiert. `pip install scsdpy` für das optionale Sheet, oder ignorieren – alle anderen Sheets sind vollständig auch ohne SCSD.

## 8.4 Performance

### Lauf braucht >10 Minuten

- Sehr großes Logfile (>1 GB): `cfg.scan_chunk_mb` auf 64 oder 128 setzen.

- Wiederholter Lauf desselben Logfiles: `cfg.use_cache = True` aktivieren (Default). Block-Offsets werden auf Disk gecacht, spätere Läufe halbieren ihre Logfile-Lese-Zeit.
- Lauf mit aktiviertem PCET ist ca. 30 % langsamer als ohne (zusätzlicher Eigenvektor-Read mit H-Atomen pro Mode). Wenn nicht benötigt: `pcet_enabled = False`.

### Sehr großer Speicher-Verbrauch

`modenanalyse_2fe2s` hält alle Mode-Resultate im RAM. Bei sehr großen Systemen (>2000 Modes) und vielen Liganden kann der Speicher 2–4 GB erreichen. *Lösung*: `freq_max` herabsetzen oder Multi-Window-Modus deaktivieren.

## 9 Lizenz und Zitierung

### 9.1 Lizenz

`modenanalyse_2fe2s` ist freie Software unter der **GNU General Public License Version 3 oder später (GPL-3.0-or-later)**.

Was die Lizenz erlaubt:

- Frei verwenden – für Forschung, Lehre und auch kommerziell.
- Modifizieren – den Quellcode ändern, anpassen, eigene Erweiterungen schreiben.
- Verteilen – modifizierte oder unmodifizierte Versionen weitergeben (auch verkaufen).

Was die Lizenz *verlangt*:

- Modifikationen, die veröffentlicht oder weitergegeben werden, müssen ebenfalls unter GPL-3.0-or-later stehen (*Copyleft-Klausel*). Damit bleibt die Software *open source*, auch in modifizierter Form.
- Bei Weiterverteilung muss der Quellcode mitgeliefert werden (oder ein klarer Hinweis, wie er bezogen werden kann).
- Der Copyright-Hinweis und die GPL-3.0-Klauseln dürfen nicht entfernt werden.

Der vollständige Lizenztext liegt der Distribution als Datei `LICENSE` bei. Jede Quelltextdatei trägt im Header einen SPDX-License-Identifier:

```
# Copyright (C) 2026 Lukas Knauer, AG Sch\unemann, RPTU Kaiserslautern-Landau
# SPDX-License-Identifier: GPL-3.0-or-later
# Teil von modenanalyse_2fe2s -- siehe LICENSE im Wurzelverzeichnis.
```

## 9.2 Zitierung

Wenn `modenanalyse_2fe2s` in einer wissenschaftlichen Publikation verwendet wird, sollten:

- Die Software selbst zitiert werden (Programm-Name, Version, Autor, Jahr, evtl. DOI/Zenodo-Eintrag, falls vergeben).
- Die zugrundeliegenden Methoden zitiert werden, sofern sie für die Auswertung relevant sind:
  - NIS/NRVS-Theorie: Paulsen 1999 [6]; Sturhahn 2004 [12].
  - Maradudin-Bessel-Mehrphoton: Maradudin & Flinn 1963 [24].
  - SCSD-Methode: Kingsbury & Senge 2024 [1].
  - PCET-Theorie: Hammes-Schiffer & Stuchebrukhov 2010 [40]; Layfield & Hammes-Schiffer 2014 [42].
  - Embedding-Methoden je nach Anwendung: PCA [31]; t-SNE [34]; UMAP [36]; HDBSCAN [38].

## 9.3 Beitrag und Issue-Tracker

Bug-Reports, Feature-Requests und Pull Requests sind willkommen über das GitHub-Repository des Projekts (Adresse siehe `pyproject.toml`). Beiträge werden unter denselben Lizenz- Bedingungen (GPL-3.0-or-later) integriert.

# 10 Validierung an [2Fe-2S]-Modell-Clustern und Proteinen

Die Methodik der Marcus-Hush-Reorganisations-Pipeline wird auf zwei Ebenen geprüft: an einer Matrix von kleinen Modell-Clustern (rein DFT-Optimierungen ohne Protein-Umgebung) und an einem QM/MM-System mit voller Protein-Umgebung (mitoNEET-H87C-Mutante).

Beide Ebenen prüfen unabhängige Eigenschaften des Tools:

- **Modell-Matrix:** Sensitivität der Cluster-Reorg ( $\Lambda_{\text{FeFe}}$ ,  $\Lambda_{\text{FeS}}$ ) auf Oxidationsstufe und Imidazol-Protonierung. Prüft die DFT-Pipeline und die Marcus-Hush-Aggregation, ohne von der PDB-Liganden- Erkennung abzuhängen.
- **Protein-System:** Vollständige Pipeline inklusive Kabsch-Alignment, PDB-Liganden-Identifikation und PCET-Pipeline. Prüft die Tool-Logik, die nur mit Protein-Kontext relevant wird.

## 10.1 Ebene 1: Modell-Matrix

Fünf [2Fe-2S]-Modell-Cluster wurden mit unterschiedlichen Liganden-Topologien, Oxidationsstufen und Protonierungs-Zuständen gerechnet:

| System                  | Ligation                          | Oxid.                | N-H? | Eigenvec | Modes |
|-------------------------|-----------------------------------|----------------------|------|----------|-------|
| A: Cys <sub>4</sub> red | Cys <sub>4</sub>                  | Fe(II)+Fe(III)       | –    | HP       | 66    |
| B: FeIII prot HP        | Cys <sub>2</sub> His <sub>2</sub> | Fe(III) <sub>2</sub> | ja   | HP       | 81    |
| C: FeIII deprot         | Cys <sub>2</sub> His <sub>2</sub> | Fe(III) <sub>2</sub> | nein | Std      | 78    |
| D: FeII prot            | Cys <sub>2</sub> His <sub>2</sub> | Fe(II) <sub>2</sub>  | ja   | Std      | 81    |
| E: FeII deprot          | Cys <sub>2</sub> His <sub>2</sub> | Fe(II) <sub>2</sub>  | nein | Std      | 79    |

Tabelle 18: Validierungs-Matrix: fünf [2Fe-2S]-Modell-Cluster mit unterschiedlichen Liganden, Oxidationsstufen und Protonierungs- Zuständen. Eigenvec: HP = **freq=hpmodes** (5 Dezimalstellen in Gaussian-Logfile), Std = Standard (4 Dezimalstellen, mit dem v1.0.0 Standard-Fallback verarbeitet). Modes = nach **freq\_max=800**-Filterung verbleibende Schwingungsmoden.

| System                  | Fe-Fe | ⟨Fe-S⟩ | Fe-S-Fe | Bemerkung                           |
|-------------------------|-------|--------|---------|-------------------------------------|
| A: Cys <sub>4</sub> red | 3.010 | 2.312  | 81.2°   | Mischvalenz, leicht asymmetrisch    |
| B: FeIII prot HP        | 2.856 | 2.217  | 80.1°   | oxidiert, kompaktes Cluster         |
| C: FeIII deprot         | 2.773 | 2.181  | 78.9°   | deprot. Imidazol → kürzeres Fe-N    |
| D: FeII prot            | 2.833 | 2.282  | 76.7°   | reduziert, längere Fe-S             |
| E: FeII deprot          | 2.967 | 2.328  | 79.1°   | reduziert + deprot, größtes Cluster |

Tabelle 19: Cluster-Geometrien der fünf Modell-Systeme (v1.0.0-Läufe). Distanzen in Å. Alle Geometrien wurden vom Tool als „Cluster-Geometrie OK“ klassifiziert.

### Geometrie-Befunde der Modell-Läufe

| System                  | $\Lambda_{\text{FeFe}}$ | $\Lambda_{\text{FeN}}$ | $\Lambda_{\text{FeS}}$ | $\Lambda_{\text{NH}}$ | $\Lambda_{\text{HA}}$ |
|-------------------------|-------------------------|------------------------|------------------------|-----------------------|-----------------------|
| A: Cys <sub>4</sub> red | 21.6                    | 0.0                    | 206.4                  | 0.0                   | 0.0                   |
| B: FeIII prot HP        | 29.8                    | 0.0                    | 283.0                  | 0.0                   | 0.0                   |
| C: FeIII deprot         | 34.4                    | 0.0                    | 170.6                  | 0.0                   | 0.0                   |
| D: FeII prot            | 14.0                    | 0.0                    | 130.1                  | 0.0                   | 0.0                   |
| E: FeII deprot          | 20.8                    | 0.0                    | 183.7                  | 0.0                   | 0.0                   |

Tabelle 20: Reorganisations-Energien  $\Lambda_X$  in  $\text{cm}^{-1}$  ( $T = 5 \text{ K}$ , **freq\_max=800**). Reine Cluster-Läufe *ohne PDB-File*; daher sind die Liganden-Kanäle (FeN, NH, HA) identisch null. Die Cluster-internen Kanäle (FeFe, FeS) zeigen chemisch konsistente Trends.

### Reorganisations-Energien der Modell-Läufe

#### Was die Modell-Matrix zeigt

- **Geometrie-Trends sind chemisch plausibel.** Fe-Fe-Distanz korreliert mit Oxidationsstufe (Fe(III)<sub>2</sub> kompakt, Fe(II)<sub>2</sub> aufgespreizt). Fe-S-Mittelwert korreliert mit Fe-Ionenradius (Fe(III) klein, Fe(II) größer). Imidazol-Deprotonierung verkürzt Fe-S leicht (stärkerer  $\sigma$ -Donor).
- $\Lambda_{\text{FeS}}$  **liegt in derselben Größenordnung** über alle fünf Modelle (130–283  $\text{cm}^{-1}$ ), konsistent mit dem erwarteten Bereich  $(\hbar\omega/4) \cdot \alpha_X^2$  für Mode-Anteile zwischen 30 und 60 % in der 300–400  $\text{cm}^{-1}$ -Region.
- $\Lambda_{\text{FeFe}}$  **ist klein und stabil** (14–34  $\text{cm}^{-1}$ ), wie für Cluster-Atmungsmodes erwartet.
- **Wichtig zu wissen:** Da die Modell-Läufe *ohne PDB* gerechnet wurden, sind die Liganden-Kanäle (FeN, NH, HA) identisch null – nicht weil das Tool falsch rechnet, sondern weil ohne

PDB die Liganden-Reste nicht identifiziert werden können. Für die volle PCET-Pipeline muss das Tool mit PDB-Datei laufen (siehe Ebene 2).

## 10.2 Ebene 2: Vollständiges Protein-System (mitoNEET H87C, QM/MM)

Als Validierungs-Beispiel mit voller Pipeline wurde eine QM/MM-Frequenzrechnung der **mitoNEET-H87C-Mutante** durchgeführt (ORCA-6, B3LYP/def2-TZVP-Niveau, QM/MM-Setup).

**Warum H87C?** mitoNEET-Wildtyp ist Cys<sub>3</sub>His<sub>1</sub>-koordiniert (Cys72, Cys74, Cys83, His87). Die H87C-Mutante *ersetzt* His87 durch ein zusätzliches Cystein – damit ist der Cluster Cys<sub>4</sub>-koordiniert, und der PCET-Pfad über Imidazol-Deprotonierung ist *strukturell deaktiviert*. Das ist ein idealer **Negativ-Test** für die PCET-Pipeline: das Tool muss  $\Lambda_{\text{NH}} = \Lambda_{\text{HA}} = 0$  vorhersagen, ohne dass chemische „Lecks“ (z. B. residuelle H-Bond-Akzeptoren von benachbarten Resten) fälschlich Beiträge erzeugen.

### System-Eigenschaften

- **422 Atome**, 1266 Schwingungsmoden in der ORCA-Hessian
- Nach `freq_max=800`-Filter: **736 Moden** im relevanten NRVS-Bereich
- Eigenvektoren durchgehend in voller Genauigkeit (ORCA `.hess`, kein HP/Std-Unterschied)
- PDB-Datei mit korrekter HIS/CYS-Annotation der Liganden- Reste

### Vom Tool erkannte Cluster-Geometrie und Liganden

Cluster: Fe-Fe = 2.779 Å, Fe-S(mittel) = 2.261 Å,  
Fe-S-Fe = 75.9 deg – OK

Cluster-Liganden:

```
Fe1 <- Cys 72 (S, SG, d=2.347 Å)
Fe1 <- Cys 74 (S, SG, d=2.311 Å)
Fe2 <- Cys 83 (S, SG, d=2.288 Å)
Fe2 <- Cys 87 (S, SG, d=2.327 Å)
```

PCET-Reorg: NICHT aktiv (keine His-Liganden am Cluster).

ET-Reorg-Liganden: 4 Atome erkannt.

**Vier Cys-Liganden korrekt identifiziert** : Das Tool hat trotz fehlender HIS-Beteiligung am Cluster die vier Cys-Liganden über Kabsch-Alignment + PDB-Mapping korrekt zugeordnet (Distanzen 2.29–2.35 Å, alle plausibel). Damit ist die Liganden-Erkennungs-Pipeline auf einem realen Protein-System erfolgreich getestet.

| Kanal $X$               | Wert ( $\text{cm}^{-1}$ ) | Bewertung                                  |
|-------------------------|---------------------------|--------------------------------------------|
| $\Lambda_{\text{FeFe}}$ | 28.7                      | ✓ Cluster-Atmung im Sanity-Bereich         |
| $\Lambda_{\text{FeN}}$  | 0.0                       | ✓ Negativ – kein His-N                     |
| $\Lambda_{\text{FeS}}$  | 337.9                     | ✓ Cys <sub>4</sub> -Cluster, hoher Beitrag |
| $\Lambda_{\text{NH}}$   | 0.0                       | ✓ Negativ – kein Imidazol-NH               |
| $\Lambda_{\text{HA}}$   | 0.0                       | ✓ Negativ – kein H-Akzeptor-Pfad           |

Tabelle 21: Reorganisations-Energien des mitoNEET-H87C-Systems ( $T = 5 \text{ K}$ ,  $\text{freq\_max}=800$ ). Drei der fünf Kanäle sind exakt null: das ist *nicht* ein null-Lauf, sondern die *korrekte Vorhersage* für ein System ohne His-Liganden. Der Cluster-FeFe- und Fe-S-Cys-Beitrag liegt im erwarteten Bereich.

## Ergebnis-Reorg

### Mode-Klassifikation in mNT-H87C

- In-plane Modes: **509** (69 %)
- Out-of-plane Modes: **91** (12 %)
- Torsional Modes: **136** (18 %)

Die OOP/INP-Verteilung ist konsistent mit der Erwartung für ein voll solvatisiertes Protein-System: viele In-plane-Skelett-Modes des Backbones, einige OOP-Cluster-Modes, der Rest gemischt-Charakter.

**Frequenzaufgelöste Verteilung der Reorg-Beiträge** Die Total-Werte  $\Lambda_X^{\text{total}}$  verteilen sich über den NRVS-relevanten Frequenzbereich wie folgt (aus `Lambda_kumulativ-Sheet`):

| Bereich ( $\text{cm}^{-1}$ ) | $\Delta\Lambda_{\text{FeFe}}$ | $\Delta\Lambda_{\text{FeS}}$ | Bandenzuordnung                       |
|------------------------------|-------------------------------|------------------------------|---------------------------------------|
| 0–100                        | 0.02                          | 0.10                         | Skelett-Modes, kaum Cluster-Aktivität |
| 100–200                      | 3.74                          | 1.49                         | Niederfrequenz-Cluster-Bewegungen     |
| 200–300                      | 0.37                          | 12.22                        | Cluster-Atmung-Region                 |
| 300–400                      | 1.86                          | 122.52                       | <b>Fe-S symm. Streckung dominant</b>  |
| 400–500                      | 22.65                         | 198.39                       | <b>Fe-S asymm. + Fe-Fe gekoppelt</b>  |
| 500–800                      | 0.04                          | 3.17                         | Liganden-Mix-Modes                    |
| <b>Total</b>                 | <b>28.68</b>                  | <b>337.89</b>                |                                       |

Tabelle 22: Frequenzaufgelöste Verteilung der Reorg-Beiträge in mNT-H87C. Die FeS-Pipeline konzentriert ihren Beitrag bei 300–500  $\text{cm}^{-1}$  (95 % des Total-Werts). Die FeFe-Pipeline ist stark im 400–500  $\text{cm}^{-1}$ -Bereich (79 % des Total-Werts) – das deutet auf gekoppelte Cluster-Atmungs- und Fe-S-asymm.-Streck-Modes hin.

Diese Verteilung ist mit den literaturbekannten NRVS-Banden für [2Fe-2S]-Cluster konsistent [7] und die NRVS-Mode-Übersicht Wang 2025 [46] abgleichen:

- 300–400  $\text{cm}^{-1}$ : typischer Bereich für Fe-S<sub>b</sub> symmetrische Streckschwingungen (324, 358  $\text{cm}^{-1}$  in mitoNEET-WT [7]).

- 400–500 cm<sup>-1</sup>: typischer Bereich für Fe-S<sub>b</sub> asymmetrische Streckschwingungen (395, 413 cm<sup>-1</sup> in mitoNEET-WT [7]). Die starke Kopplung an Cluster-Atmung wird hier durch den hohen FeFe-Beitrag sichtbar.

### Was der mNT-H87C-Lauf validiert

1. **ORCA-Reader**: Liest die volle 1266-Mode-Hessian sauber, alle 736 Modes im Filter-Bereich werden mit HP-Genauigkeit verarbeitet. Pipeline-Tests aus §4.5 (Marcus-Hush-Additivität, Sanity-Range, Channel-Selektivität) sind alle erfüllt.
2. **Kabsch-Alignment**: PDB- und ORCA-Geometrie werden über alle 4 Fe + 2 S-Atome korrekt aligniert (RMSD  $\approx$  0.000 Å, da QM/MM-PDB direkt aus der ORCA-Optimierung stammt).
3. **Liganden-Identifikation**: Alle vier Cys-Liganden (72, 74, 83, 87) werden korrekt aus dem PDB ausgelesen und den Cluster-Fe-Atomen zugeordnet.
4. **PCET-Negativ-Test**:  $\Lambda_{\text{FeN}}$ ,  $\Lambda_{\text{NH}}$ ,  $\Lambda_{\text{HA}}$  sind exakt null – die Pipeline schaltet diese Kanäle korrekt ab, wenn keine His-Liganden vorhanden sind. *Keine residuellen Beiträge aus benachbarten Resten*, kein numerisches Rauschen.
5. **Sekundärstruktur-Auto-Erkennung**: Da das PDB keine HELIX/SHEET-Records enthält, wurden 3 SSE-Elemente per DSSP-H-Brücken-Analyse rekonstruiert (Fallback-Pfad funktioniert).

### 10.3 Ausblick: Cys<sub>3</sub>His-Wildtyp-Validierung

Für die volle Validierung der *positiven* PCET-Pipeline (d. h.  $\Lambda_{\text{HA}} > 0$  in einem realen His-haltigen Cluster) ist eine analoge Rechnung am **mitoNEET-Wildtyp** (Cys<sub>3</sub>His<sub>1</sub>) der nächste logische Schritt. Vergleich zwischen WT und H87C-Mutante:

- Bei **WT prot**: erwartet  $\Lambda_{\text{FeN}} > 0$  (Fe-N(His87)-Streckung bei  $\sim 295$  cm<sup>-1</sup> [7]);  $\Lambda_{\text{HA}} > 0$  aus H-Akzeptor-Modulationen mit benachbarten Resten;  $\Lambda_{\text{NH}} \approx 0$ , weil N-H-Streckschwingungen bei  $\sim 3300$  cm<sup>-1</sup> liegen, außerhalb `freq_max=800`.
- Bei **WT deprot**: erwartet  $\Lambda_{\text{FeN}} > 0$  (Fe-N<sup>-</sup>-Bindung bleibt aktiv);  $\Lambda_{\text{HA}} \rightarrow 0$  (kein N-H mehr verfügbar).
- Bei **H87C** (dieser Lauf): bereits gezeigt, alle drei Liganden-Kanäle = 0.

Diese Drei-Punkt-Validierungs-Strategie (WT prot > WT deprot > H87C) erlaubt eine quantitative Trennung zwischen *Liganden-induzierter* (FeN aus Fe-N<sub>δ</sub>) und *Reaktions-spezifischer* (HA aus N-H-Akzeptor-Geometrie) Reorg-Beiträge. Gee, Pelmeshnikov *et al.* (2021) [7] liefern die experimentellen NRVS-Banden für den direkten Vergleich.

## 10.4 Erfolgskriterien des Validierungs-Tests

1. **Geometrie-Konsistenz** (alle fünf Modell-Systeme + mNT-H87C). *Erfüllt*.
2. **Cluster-Reorg-Trends** über Oxidationsstufe und Protonierung. *Erfüllt* für Modell-Matrix.
3. **Marcus-Hush-Additivität**:  $\sum_i \lambda_X(i) = \Lambda_X^{\text{total}}$  exakt (auf  $0.01 \text{ cm}^{-1}$ ). *Erfüllt* (Smoke-Test 4 in `tests/test_smoke.py`).
4. **Channel-Selektivität**: Cys<sub>4</sub>-Systeme haben  $\Lambda_{\text{FeN}} = \Lambda_{\text{NH}} = \Lambda_{\text{HA}} = 0$ . *Erfüllt* für Modell A und mNT-H87C.
5. **Sanity-Range**:  $\Lambda_{\text{FeFe}} \in [1, 100]$ ,  $\Lambda_{\text{FeS}} \in [50, 1000] \text{ cm}^{-1}$ . *Erfüllt* für alle sechs Systeme.
6. **ORCA-Pipeline**: Volle .hess-Datei wird gelesen, Kabsch-Alignment, Liganden-Erkennung. *Erfüllt* für mNT-H87C (3 Bugs der ORCA-Pipeline in v1.0.0 behoben, siehe Changelog).
7. **NRVS-Bandenordnung** über kumulative  $\Lambda_X(\omega)$ -Kurven [7, 46]. *Steht aus* – erfordert mNT-Wildtyp-Lauf zum direkten Vergleich.

**Status der Validierung** (2. September 2026, v1.0.0). Sechs of sieben Validierungskriterien sind erfüllt: fünf Modell-Cluster-Läufe (Geometrie + Cluster-Reorg) plus eine volle Protein-Pipeline (mNT-H87C, Negativ-Test). Das Tool funktioniert auf realen QM/MM-Frequenzrechnungen, identifiziert Liganden korrekt, und schaltet die PCET-Kanäle strukturell ab, wenn keine His-Liganden vorhanden sind.

Die noch fehlende positive PCET-Validierung (mNT-WT mit Cys<sub>3</sub>His) ist ein logischer nächster Schritt – die Methode ist hier nicht mehr methodisch zu validieren, sondern an einem konkreten Forschungs-System anzuwenden.

Wenn alle sieben Kriterien erfüllt sind, ist die Marcus-Hush- Reorg-Methodik publikations-validiert und kann auf neue Systeme (unbekannte Cys<sub>2</sub>His<sub>2</sub>-Cluster, Doppel-Mutanten, Multi-Cluster-Systeme) angewandt werden.

## Teil III

# Anhänge

## A Mathematische Notation und Konventionen

Dieser Anhang fasst die im gesamten Handbuch verwendete mathematische Notation, Einheiten-Konventionen und Symbol- Bedeutungen kompakt zusammen. Er ist als Nachschlagereferenz



gedacht: wer in einem Kapitel über ein Symbol oder eine Einheiten-Konvention stolpert, findet hier die endgültige Definition.

## A.1 Skalare, Vektoren, Matrizen, Tensoren

- **Skalare:** kursiv, einfacher Buchstabe –  $a$ ,  $b$ ,  $\omega$ ,  $T$ . Im Fall vorzeichenfreier physikalischer Größen wie Massen oder Frequenzen wird das positive Vorzeichen impliziert.
- **Vektoren:** fettgedruckt, einfacher Buchstabe –  $\mathbf{r}$ ,  $\mathbf{e}$ ,  $\mathbf{a}$ . Komponenten als  $r_x, r_y, r_z$  oder  $r_1, r_2, r_3$  je nach Kontext.
- **Matrizen:** fettgedruckt und großgeschrieben –  $\mathbf{R}$ ,  $\mathbf{H}$ ,  $\mathbf{F}$ . Einträge als  $R_{ij}$  oder  $(\mathbf{R})_{ij}$ .
- **Mengen, Tupel:** kursiv, großgeschrieben –  $\mathcal{C}$  (Cluster-Atome),  $\mathcal{L}$  (Liganden-Mengen),  $\mathcal{M}$  (Modes).

## A.2 Indizes

- $i, j, k$ : laufen über Schwingungsmoden ( $i = 1, \dots, N_{\text{modes}}$ )
- $a, b, c$ : laufen über Atome ( $a = 1, \dots, N_{\text{atoms}}$ )
- $\alpha, \beta$ : laufen über Kartesische Komponenten ( $x, y, z$ )
- $X, Y, Z$ : stehen für Bindungs-Kanäle ( $X \in \{\text{FeFe}, \text{FeN}, \text{FeS}, \text{NH}, \text{HA}\}$ )
- $p, q$ : laufen über Kanal-Sub-Indizes (z. B. verschiedene Fe-N-Bindungen innerhalb des FeN-Kanals)

## A.3 Einheiten-Konventionen

Das gesamte Handbuch und die Software verwenden konsequent folgende Einheiten:

**Längen.** Å ( $1 \text{ Å} = 10^{-10} \text{ m}$ ). PDB-Standard. Cluster- Geometrien und Bindungsabstände werden in Å angegeben. Im SI-internen Code-Pfad wird zur Umrechnung  $r_{\text{SI}} = r_{\text{Å}} \cdot 10^{-10} \text{ m}$  verwendet.

**Frequenzen.**  $\text{cm}^{-1}$  (Wellenzahlen, NRVs-Konvention). Wandlung in SI:

$$\omega_{\text{SI}} = 2\pi c \omega_{\text{cm}^{-1}} \quad \text{mit} \quad c = 2.99792458 \times 10^{10} \text{ cm/s} \quad (52)$$

und in Energie:

$$E_{\text{cm}}^{-1} = \frac{E_{\text{J}}}{hc} \quad \text{mit} \quad hc = 1.98644586 \times 10^{-23} \text{ J cm} \quad (53)$$

**Massen.** amu (atomic mass units;  $1 \text{ amu} = 1.66053906660 \times 10^{-27} \text{ kg}$ ). Reduzierte Massen  $\mu$  werden *immer* in amu angegeben, auch wenn sie aus Mode-Eigenvektoren ( $\mu_{\text{mode}}$ ) berechnet sind.

**Energien.**  $\text{cm}^{-1}$  in den Reorg-Sheets, J im SI-internen Code-Pfad. Wandlung am Ende der Berechnung im Modul `reorganization` via `_HC_JCM = h*c`.

**Temperaturen.** K (Kelvin). Tieftemperatur-NRVS: 5 K (Standard im hier beschriebenen Tool); Standard-NRVS: 40 K; Raumtemperatur: 300 K.

**Auslenkungen, Modulationen.** Die thermisch skalierten Mode-Auslenkungen  $\mathbf{e}_a^{\text{thermal}} = \mathbf{e}_a^{\text{normalized}} \cdot u_{\text{rms}}$  haben Einheit Å. Die daraus berechneten Bindungs-Modulationen  $\Delta r_X$  ebenfalls Å.

#### A.4 Vorzeichen-Konventionen

**Bindungs-Modulationen  $\Delta r_X$ .** Vorzeichen-behaftet: positiver Wert bedeutet *Streckung* der Bindung in der gegebenen Mode-Auslenkung; negativer Wert bedeutet *Stauchung*. Für Reorg-Beiträge  $\lambda_X = \frac{1}{2} \mu \omega^2 (\Delta r_X)^2$  ist nur das Quadrat relevant; bei der Aggregation über Sub-Kanäle (z. B.  $\text{FeN\_His1} + \text{FeN\_His2} \rightarrow \text{FeN}$ ) wird *vorzeichenfrei* aggregiert (RSS, siehe §A).

**Kabsch-Alignment-Vorzeichen.** Das Kabsch-Alignment liefert eine Rotation, die die PDB-Geometrie auf die Gauss-Geometrie abbildet. Bei links-/rechts-händigen Spiegelungen wird das Vorzeichen der z-Komponente korrigiert (siehe `geometry.kabsch_align`).

**Cluster-Normale  $\hat{\mathbf{n}}$ .** Per Konvention zeigt  $\hat{\mathbf{n}}$  in die Richtung mit positiver z-Komponente in der Cluster-Lokalachsen-Konvention. Diese Wahl ist beliebig, aber konsistent in allen Sheets gepflegt. Eine Mode mit  $\text{OOP\%} > 60$  hat den überwiegenden Teil ihrer quadrierten Auslenkung in  $\hat{\mathbf{n}}$ -Richtung; ob diese Auslenkung „nach oben“ oder „nach unten“ zeigt, ist spektroskopisch egal.

#### A.5 Summen-, Produkt- und Erwartungswert-Konventionen

**Summe über Mode-Indizes.**  $\sum_i$  ohne weitere Spezifikation läuft *immer* über alle nach Filterung im Frequenzfenster verbleibenden Schwingungsmoden, nicht über alle  $3N_{\text{atoms}} - 6$  Moden des Gesamtsystems.

**Quantum-Mechanischer Harmonischer Oszillator (QHO).**  $\langle x^2 \rangle = \frac{\hbar}{2m\omega} \coth(\hbar\omega/2k_B T)$  ist der Erwartungswert des Auslenkungs-Quadrats im thermischen Gleichgewicht. Bei  $T \rightarrow 0$

wird das zu  $\hbar/(2m\omega)$  (Nullpunkts-Energie). Im Tool wird daraus

$$u_{\text{rms}} = \sqrt{\langle x^2 \rangle} \quad (54)$$

abgeleitet (siehe `core.compute_thermal_amplitude`).

**Reduzierte Massen-Konvention.** Für eine Bindung zwischen den Atomen  $a$  und  $b$ :

$$\mu_{\text{pair}}(a, b) = \frac{m_a m_b}{m_a + m_b} \quad (55)$$

Diese ist *eindeutig* pro Bindung, unabhängig von Mode-Index. Im Gegensatz dazu ist  $\mu_{\text{mode}}(i)$  die effektive reduzierte Masse der Mode  $i$ , wie sie Gaussian/ORCA in der Frequenzrechnung ausgibt – diese ist mode-spezifisch.

## A.6 Notation für algorithmische Schritte

Im später zu ergänzenden Pseudocodes-Anhang werden folgende Konventionen verwendet:

- $a \leftarrow b$ : Zuweisung
- $a == b$ : Gleichheits-Test
- `FUNCTION( $a, b$ )`: Funktions-Aufruf in Kapitelälchen
- `procedure`: Pseudocode-Block (kein expliziter Output)
- `function`: Pseudocode-Block (mit Return-Wert)

## B Symbolverzeichnis

Sortierte Liste aller im Handbuch und in der Software verwendeten Symbole. Die Reihenfolge folgt der Konvention: lateinische Buchstaben, dann griechische, dann Sonderzeichen.

## B.1 Lateinische Buchstaben

| Symbol             | Bedeutung                                           | Einheit / Wertebereich                                              |
|--------------------|-----------------------------------------------------|---------------------------------------------------------------------|
| $a, b, c$          | Atom-Indizes                                        | $1, \dots, N_{\text{atoms}}$                                        |
| $B$                | Debye-Waller-Tensor / B-Faktor                      | $\text{\AA}^2$                                                      |
| $c$                | Lichtgeschwindigkeit                                | $2.998 \times 10^{10} \text{ cm/s}$                                 |
| $\mathcal{C}$      | Menge der Cluster-Atome (Fe + S <sub>bridge</sub> ) | $ \mathcal{C}  = 4$                                                 |
| $C_{\text{clus}}$  | Cluster-Beteiligung einer Mode                      | $[0, 1]$                                                            |
| $C_{\text{PCET}}$  | Co-Modulations-Indikator                            | $[0, 1]$                                                            |
| $\Delta r_X$       | Bindungs-Modulation des Kanals $X$                  | $\text{\AA}$                                                        |
| $\mathbf{e}_a$     | Eigenvektor-Komponente an Atom $a$                  | $\text{\AA}$ (thermisch skaliert)                                   |
| $E$                | Energie                                             | J oder $\text{cm}^{-1}$                                             |
| $f_{\text{LM}}$    | Lamb-Mößbauer-Faktor                                | $[0, 1]$                                                            |
| $\mathbf{F}$       | Frequenz-Vektor                                     | $\text{cm}^{-1}$                                                    |
| $h$                | Plancksches Wirkungsquantum                         | $6.626 \times 10^{-34} \text{ Js}$                                  |
| $\hbar$            | Reduzierte Planck-Konstante                         | $h/(2\pi)$                                                          |
| $H$                | Hesse-Matrix der Kraftkonstanten                    | a.u. in Gaussian                                                    |
| $\hat{H}$          | Hamilton-Operator                                   | J                                                                   |
| $i, j, k$          | Mode-Indizes                                        | $1, \dots, N_{\text{modes}}$                                        |
| $k_B$              | Boltzmann-Konstante                                 | $1.381 \times 10^{-23} \text{ J/K}$                                 |
| $\mathcal{L}$      | Menge der Liganden-Atome (Fe-koordiniert)           | $ \mathcal{L}  \approx 4\text{--}8$                                 |
| $m_a$              | Masse des Atoms $a$                                 | amu                                                                 |
| $\mathbf{n}$       | Cluster-Normale (durch Best-Fit-Ebene)              | dimensionsloser Einheitsvektor                                      |
| $N_{\text{atoms}}$ | Anzahl der Atome im System                          | $\approx 50\text{--}3000$                                           |
| $N_{\text{modes}}$ | Anzahl der Schwingungsmoden im Filterbereich        | $\approx 100\text{--}10\,000$                                       |
| $\mathbf{r}_a$     | Position des Atoms $a$ in Kartesischen Koord.       | $\text{\AA}$                                                        |
| $r_{\text{eq}}$    | Gleichgewichts-Bindungsabstand                      | $\text{\AA}$                                                        |
| $S$                | Huang-Rhys-Faktor                                   | dimensionslos                                                       |
| $T$                | Temperatur                                          | K                                                                   |
| $u_{\text{rms}}$   | RMS-Amplitude einer Mode (QHO-Erwartungswert)       | $\text{\AA}$                                                        |
| $X, Y, Z$          | Bindungs-Kanal-Index                                | $\in \{\text{FeFe}, \text{FeN}, \text{FeS}, \text{NH}, \text{HA}\}$ |

## B.2 Griechische Buchstaben

| Symbol                     | Bedeutung                                   | Einheit / Wertebereich         |
|----------------------------|---------------------------------------------|--------------------------------|
| $\alpha$                   | In SCSD: D <sub>2h</sub> -Irrep-Koeffizient | Å                              |
| $\alpha_X$                 | Mode-Anteil auf Bindung $X$                 | [0, 1]                         |
| $\Delta Q$                 | Statische Mode-Verschiebung (Marcus-Hush)   | amu <sup>1/2</sup> Å           |
| $\Delta r_X$               | Bindungs-Modulation                         | Å                              |
| $\hat{\mathbf{n}}$         | Cluster-Normale                             | dimensionsloser Einheitsvektor |
| $\lambda$                  | Marcus-Hush-Reorganisationsenergie          | cm <sup>-1</sup>               |
| $\lambda_X(i)$             | Pro-Mode-Beitrag, Kanal $X$ , Mode $i$      | cm <sup>-1</sup>               |
| $\Lambda_X^{\text{total}}$ | System-Total-Reorg, Kanal $X$               | cm <sup>-1</sup>               |
| $\Lambda_X(\omega)$        | Kumulative Reorg-Kurve                      | cm <sup>-1</sup>               |
| $\mu_{\text{pair}}$        | Reduzierte Masse einer Bindung              | amu                            |
| $\mu_{\text{mode}}$        | Reduzierte Masse einer Mode (aus DFT)       | amu                            |
| $\sigma$                   | Gauss-Verbreiterung der Spektren            | cm <sup>-1</sup>               |
| $\sigma_X$                 | Statistische Unsicherheit von $X$           | wie $X$                        |
| $\Phi$                     | Phase einer Mode-Auslenkung (intern)        | rad                            |
| $\omega$                   | Mode-Frequenz                               | cm <sup>-1</sup> oder rad/s    |
| $\omega_i$                 | Frequenz der Mode $i$                       | cm <sup>-1</sup>               |
| $\Omega$                   | Vektor aller Mode-Frequenzen                | cm <sup>-1</sup>               |

### B.3 Sonderzeichen und Abkürzungen

| Symbol                  | Bedeutung                                                |
|-------------------------|----------------------------------------------------------|
| Å                       | Ångstrom-Einheit                                         |
| $\langle \cdot \rangle$ | Quantenmechanischer/thermischer Erwartungswert           |
| $ \cdot $               | Betrag (Skalar) bzw. Norm (Vektor)                       |
| $\ \cdot\ $             | L2-Norm eines Vektors                                    |
| $\hat{\cdot}$           | Einheitsvektor (z. B. $\hat{\mathbf{n}}$ )               |
| $\cdot^*$               | Komplex konjugiert                                       |
| $\sum_i$                | Summe über Mode-Indizes (in Filterbereich)               |
| $\sum_a$                | Summe über Atom-Indizes                                  |
| $\sum_X$                | Summe über Kanal-Indizes (FeFe, FeN, FeS, NH, HA)        |
| RSS                     | Root Sum of Squares: $\sqrt{\sum_i x_i^2}$               |
| RMS                     | Root Mean Square: $\sqrt{\frac{1}{n} \sum_i x_i^2}$      |
| pDOS                    | Projizierte Zustandsdichte (projected density of states) |
| pCH                     | Pyrrol-C-H (in NRVs-Literatur)                           |
| HP                      | High-Precision (Gaussian-Eigenvektoren)                  |
| Std                     | Standard-Genauigkeit (Gaussian-Eigenvektoren)            |
| PCET                    | Proton-Coupled Electron Transfer                         |
| ET                      | Electron Transfer                                        |
| PT                      | Proton Transfer                                          |
| NRVS                    | Nuclear Resonance Vibrational Spectroscopy               |
| SCSD                    | Symmetry-Coordinate Structural Decomposition             |
| OOP                     | Out-of-Plane (senkrecht zur Cluster-Ebene)               |
| INP                     | In-Plane (in der Cluster-Ebene)                          |
| QHO                     | Quantum-Mechanischer Harmonischer Oszillator             |
| WT                      | Wild-Typ                                                 |
| Mut                     | Mutante                                                  |
| prot                    | Protoniert (Imidazol-NH vorhanden)                       |
| deprot                  | Deprotoniert (Imidazol-NH abgespalten)                   |
| $D_{2h}$                | Punktgruppe $D_{2h}$ (rhombischer Cluster)               |
| $A_g, B_{1g}, \dots$    | Irreps der $D_{2h}$ -Symmetrie                           |

## C Glossar

Begriffe und Konzepte, die in der wissenschaftlichen Literatur und diesem Handbuch verwendet werden, mit kurzer Definition. Sortiert alphabetisch.

**Akzeptor (H-Bridge).** Atom mit freiem Elektronenpaar, das eine Wasserstoffbrücke empfängt. In [2Fe-2S]-Proteinen typisch: Carbonyl-Sauerstoff (C=O) eines Backbones, Hydroxyl-Sauerstoff einer Tyr/Ser/Thr, oder Wasser-Moleküle. Der „Hauptakzeptor“ eines His-N-H ist der mit max. Gauss-Gewicht (Distanz näher zum Optimum  $r_0 = 2.8 \text{ \AA}$ ).

**B-Faktor (Debye-Waller-Faktor).** Mittlere quadratische Auslenkung eines Atoms im thermischen Gleichgewicht:  $B_a = 8\pi^2 \langle u_a^2 \rangle / 3$ . Einheit  $\text{\AA}^2$ . Aus den Modes berechnet:  $B_a = 8\pi^2 / 3 \cdot \sum_i u_{\text{rms}}^2(i) |e_a(i)|^2$ .

**Bindungs-Kanal.** Ein Bindungs-Kanal ist eine Klasse aller chemisch äquivalenten Bindungen, deren Modulation gemeinsam aggregiert wird. Fünf Kanäle werden im Tool berechnet: FeFe (Cluster-Atmung), FeN (Fe-N<sub>His</sub>), FeS (Fe-S<sub>Cys</sub> + Fe-S<sub>bridge</sub>), NH (Imidazol-Stretching), HA (H-Akzeptor; Reaktionskoordinaten-Modus).

**Cluster-Atmung.** Symmetrische Mode, in der sich Fe-Fe-Distanz ändert (Streckung/Stauchung des Cluster-Rhombus).  $A_g$ -Symmetrie in  $D_{2h}$ . Frequenz  $\sim 200 \text{ cm}^{-1}$  in typischen [2Fe-2S]-Proteinen.

**Cluster-Normale  $\hat{n}$ .** Einheitsvektor senkrecht zur durch die vier Cluster-Atome (2 Fe + 2 S <sub>$\mu$</sub> ) am besten gefitteten Ebene. Wird via SVD der zentrierten Atom-Koordinaten berechnet. Definiert die OOP/INP-Trennung.

**Co-Modulation.** Gleichzeitige Modulation zweier Bindungs-Kanäle durch dieselbe Mode. Indikator:  $C_{\text{PCET}}(\omega) = (M_{\text{NH}}(\omega) \cdot M_{\text{HA}}(\omega))^{1/2}$ . Hohe Werte bei reaktions-relevanten PCET-Modes.

**Cys<sub>2</sub>His<sub>2</sub>, Cys<sub>3</sub>His<sub>1</sub>, Cys<sub>4</sub>.** Liganden-Schemata des [2Fe-2S]-Clusters:

- Cys<sub>4</sub>: alle vier Fe-koordinierenden Liganden sind Cysteinate (S<sup>-</sup>). Standard-Ferredoxine.
- Cys<sub>2</sub>His<sub>2</sub>: zwei Cys + zwei His. Rieske-Typ. PCET möglich.
- Cys<sub>3</sub>His<sub>1</sub>: drei Cys + ein His. mitoNEET-Typ.

**D<sub>2h</sub>-Irreps.** Irreduzible Darstellungen der Punktgruppe  $D_{2h}$  (rhombischer Cluster mit drei orthogonalen  $C_2$ -Achsen + Inversionszentrum). Acht Irreps:  $A_g, B_{1g}, B_{2g}, B_{3g}, A_u, B_{1u}, B_{2u}, B_{3u}$ . SCSD zerlegt jede Mode-Auslenkung in genau eine Linearkombination dieser acht Irreps.

**DFT (Density Functional Theory).** Quantenchemische Methode zur Berechnung elektronischer Strukturen und Schwingungsfrequenzen. Im Tool werden DFT-Frequenzen aus Gaussian-16 oder ORCA-6 erwartet (typisch B3LYP/6-31G\* mit Konvergenz auf  $10^{-8}$  Hartree).

**Eigenvektor.** Massengewichtete Auslenkungs-Komponenten einer Schwingungsmode relativ zur Gleichgewichtsgeometrie. Für Atom  $a$  in Mode  $i$ :  $\mathbf{e}_a^{(i)}$ . Normierung in Gaussian:  $\sum_a m_a |\mathbf{e}_a^{(i)}|^2 = 1$  (massengewichtet).

**Embedding.** Niedrigdimensionale Darstellung hochdimensionaler Mode-Feature- Vektoren. Im Tool: 31-dim. Feature-Matrix wird via UMAP auf 2D abgebildet.

**Feature-Matrix.**  $N_{\text{modes}} \times 31$ -dim. Matrix mit pro Mode 31 Skalaren (Frequenz, OOP%, Cluster-Beteiligung, vier Liganden-OOP, SCSD-Irrep-Anteile, etc.). Eingabe für das UMAP-Embedding.

**Frequenz-Fenster (Window).** Frequenz-Bereich (`lo`, `hi`) in  $\text{cm}^{-1}$ , der separat ausgewertet werden soll. Multi-Window-Modus: mehrere Fenster parallel, jeweils mit eigenen Reorg-Aggregaten und Embeddings.

**Gauss-Eigenvektor (HP / Std).** Gaussian schreibt Schwingungsmoden-Eigenvektoren in zwei Blöcken:

- **Standard (Std):** 4 Dezimalstellen, kompakt, immer vorhanden.
- **High Precision (HP):** 5 Dezimalstellen, durch `freq=hpmodes` aktiviert; benötigt mehr Speicher in der Logdatei. Empfohlen für dieses Tool.

**HDBSCAN.** Hierarchisches Density-Based Spatial Clustering of Applications with Noise. Cluster-Algorithmus, der UMAP-Punkte zu Clustern zusammenfasst und Rauschen separat markiert.

**HPmodes.** Gaussian-Schlüsselwort (`freq=hpmodes`), das die HP- Eigenvektoren zusätzlich in die Logdatei schreibt.

**Huang-Rhys-Faktor.**  $S = \frac{\mu\omega(\Delta q)^2}{2\hbar}$ . Dimensionslose Verschiebung einer harmonischen Mode zwischen elektronischen Zuständen, in Einheiten der Nullpunkts-Auslenkung. Verwandt mit unserem  $\lambda_X$ , aber in einer anderen Konvention (Verschiebungs- vs. Auslenkungs-Quadrat).

**Imidazol.** Aromatischer 5-Ring mit zwei Stickstoffen ( $N_\delta$  und  $N_\epsilon$ ) in Histidin. Eines der Stickstoffe (typisch  $N_\epsilon$ ) bindet das Fe; der andere kann je nach Tautomer protoniert oder nicht sein.

**INP (In-Plane).** Mode-Auslenkung überwiegend in der Cluster-Ebene (senkrecht zu  $\hat{\mathbf{n}}$ ). Klassifiziert mit  $\text{OOP}\% < 40$  (binaere Schwelle bei 60).



**Kabsch-Alignment.** Algorithmus zum optimalen Aufeinanderlegen zweier Atomkoordinatensätze (PDB  $\leftrightarrow$  Gaussian). Liefert Rotations-Matrix und RMSD.

**Kern-Klassifikation.** Heuristische Mode-Typ-Zuweisung: Cluster-Atmung, Cluster-Hinge, Cluster-Twist, Liganden-Stretch, etc. Implementiert in `core.py:classify_kern`. Nicht orthogonal mit SCSD-Irreps; mehrere Kern-Typen koennen demselben Irrep entsprechen.

**Lamb-Mößbauer-Faktor.**  $f_{\text{LM}} = \exp(-2W)$ , mit  $W$  dem Debye-Waller-Faktor des Mößbauer-aktiven Kerns ( $^{57}\text{Fe}$ ). Misst, welcher Anteil der Resonanzabsorption ohne Phononen-Anregung erfolgt (elastischer Anteil im NRV-Spektrum).

**Marcus-Hush-Theorie.** Klassische Theorie des Elektronentransfers (Marcus 1956, Hush 1958), die die Reaktionsrate über eine harmonische Approximation der Reaktanten- und Produkt-Energieflächen mit einer einzigen Reorganisations-Koordinate zusammenfasst.

**mitoNEET.** Cys<sub>3</sub>His<sub>1</sub>-koordiniertes [2Fe-2S]-Protein. Bekannt für seine spektroskopisch besonders gut untersuchten NRV-Bandenstruktur (Gee 2021, Bergner 2017).

**Modulations-Spektrum**  $M_X(\omega)$ . Gauss-verbreitertes Spektrum der Bindungs-Modulationen pro Kanal:  $M_X(\omega) = \sum_i |\Delta r_X(i)| \cdot G(\omega - \omega_i, \sigma)$ . Zeigt, in welchem Frequenzbereich Bindung  $X$  stark moduliert wird.

**NRVS (Nuclear Resonance Vibrational Spectroscopy).** Synchrotron-Spektroskopie an Mößbauer-aktiven Kernen (typisch  $^{57}\text{Fe}$ ). Misst  $^{57}\text{Fe}$ -projizierte Vibrations-Zustandsdichte. Komplementär zu Raman/IR (elementselektiv, nicht symmetrieselektiv). Im Tool wird nicht das NRV-Spektrum selbst berechnet, sondern die Reorg-Beiträge, die zur Bandenidentifikation genutzt werden koennen.

**OOP (Out-of-Plane).** Mode-Auslenkung überwiegend senkrecht zur Cluster-Ebene (parallel zu  $\hat{\mathbf{n}}$ ). Klassifiziert mit  $\text{OOP}\% > 60$ .

**OOP%.** Quadrat-Anteil der Mode-Auslenkung in  $\hat{\mathbf{n}}$ -Richtung, relativ zur Gesamt-Auslenkung.  $\text{OOP}\% = 100 \cdot \sum_a (\mathbf{e}_a \cdot \hat{\mathbf{n}})^2 / \sum_a |\mathbf{e}_a|^2$ .

**PCET (Proton-Coupled Electron Transfer).** Konzertierter Transfer eines Elektrons und eines Protons. In [2Fe-2S]-Proteinen typischerweise: Reduktion des Clusters ( $\text{Fe}^{3+} + e^- \rightarrow \text{Fe}^{2+}$ ) gekoppelt mit Imidazol-NH-Deprotonierung (Rieske:  $pK_a$  verschiebt um 4-5 Einheiten zwischen oxidiertem und reduziertem Zustand).

**Pseudocode.** Algorithmus-Beschreibung in einer informellen, aber präzisen Notation ohne spezifische Programmiersprache. Wird im Anhang D für die zentralen Algorithmen verwendet.

**Reaktionskoordinaten-Modus (HA).** Definition der HA-Modulation: Anstelle der Modulation der H-Akzeptor-Distanz wird die Bewegung des H-Atoms relativ zum Donor-N entlang der N→Akzeptor-Achse berechnet. Klassische Schreibweise:  $\Delta r_{\text{HA}} = (\mathbf{e}_H - \mathbf{e}_N) \cdot \hat{\mathbf{n}}_{N \rightarrow \text{Akz.}}$ . Misst echte Protonenbewegung statt unspezifischer Skelett-Modes.

**Reorganisations-Energie  $\lambda_X$ .** Im Tool: thermische Bindungs-Längen-Fluktuations-Energie pro Mode entlang Bindung  $X$ , berechnet in Marcus-Hush-Form mit thermisch skalierten Mode-Auslenkungen. Verwandt mit, aber nicht identisch zur klassischen Marcus-Hush-Reorganisationsenergie (siehe §2.12).

**Rieske-Protein.** Cys<sub>2</sub>His<sub>2</sub>-koordiniertes [2Fe-2S]-Protein. Komponente in Cytochrom-bc<sub>1</sub>-Komplexen, beteiligt am Q-Cycle. Klassisches PCET-System (Imidazol-NH-Deprotonierung gekoppelt an Cluster-Reduktion).

**RMS (Root Mean Square).**  $\sqrt{\frac{1}{n} \sum_i x_i^2}$ . Mittelwert der Quadrate, dann Wurzel.

**RSS (Root Sum of Squares).**  $\sqrt{\sum_i x_i^2}$ . Summe der Quadrate, dann Wurzel. **Nicht** mit RMS verwechseln (durch  $n$  geteilt).

**SCSD (Symmetry-Coordinate Structural Decomposition).** Methode von Kingsbury & Senge (2024), die strukturelle Verzerrungen in einer beliebigen Geometrie als Linearkombination von Symmetriekoordinaten einer kanonischen Referenzgeometrie darstellt. Im Tool: D<sub>2h</sub>-Zerlegung mit kanonischer Referenz-[2Fe-2S]-Cluster (Fe-Fe = 2.73 Å, Fe-S = 2.20 Å).

**Sekundärstruktur (SSE).** Lokale 3D-Struktur eines Proteins (Helix, Beta-Faltblatt, Loop). Im Tool aus dem PDB-File abgeleitet (HELIX/SHEET-Records oder DSSP-Fallback oder  $\varphi/\psi$ -Heuristik).

**TOML.** Konfigurationsformat (*Tom's Obvious, Minimal Language*). Im Tool: `config.toml` oder `run.toml` für reproduzierbare Läufe.

**Thermisch skalierte Eigenvektoren.**  $\mathbf{e}_a^{\text{thermal}}(i) = \mathbf{e}_a^{\text{normalized}}(i) \cdot u_{\text{rms}}(i)$ . Eigenvektoren multipliziert mit der Mode-spezifischen RMS-Amplitude (QHO-Erwartungswert bei der gegebenen Temperatur). Direkt verwendbar zur Berechnung thermischer Bindungs-Modulationen.

**UMAP (Uniform Manifold Approximation and Projection).** Topologie-erhaltende Dimensions-Reduktions-Methode (McInnes 2018). Lokale + globale Strukturen werden gleichzeitig erhalten, deterministisch reproduzierbar mit Seed.

**Wasserstoffbrücke (H-Bridge).** Schwache, aber gerichtete Wechselwirkung zwischen einem Proton-Donor (X-H mit X = N, O) und einem Akzeptor (Y mit freiem Elektronenpaar, Y = O, N). Energie typisch 5-30 kJ/mol. In Proteinen verantwortlich fuer Sekundärstruktur und PCET-Reaktionskanäle.

## D Algorithmus-Pseudocodes

Die zentralen Algorithmen des Tools werden hier als Pseudocode dokumentiert. Sprachebene: zwischen formaler Mathematik und Python – keine Typdetails, aber alle nicht-trivialen Kontrollflüsse explizit. Variablen-Namen folgen den Modulnamen im Code.

Die Pseudocodes sind *nicht* 1:1-Implementierungen, sondern Skizzen der Logik. Der echte Code in `src/modenanalyse_2fe2s/` hat zusätzlich Performance-Optimierungen, Caching, Logging und Fehlerbehandlung, die hier zur Lesbarkeit weggelassen sind.

### D.1 Cluster-Erkennung

Zentrale Aufgabe: aus einer Liste von Atomen finde alle [2Fe-2S]- Cluster. Bei Multi-Cluster-Systemen (Glutaredoxin-Dimere etc.) müssen mehrere Cluster eindeutig gruppiert und sortiert werden.

**Pseudocode 1** FINDALLCLUSTERS

**Eingabe:** Atomliste  $A = \{a_1, \dots, a_N\}$  mit Element + Kartesischer Position; Cutoffs  $c_{\text{FeFe}}, c_{\text{FeS}}$  in Å

**Ausgabe:** Liste von Clustern  $\mathcal{C}_1, \mathcal{C}_2, \dots$ , sortiert nach Fe-Fe-Distanz aufsteigend

```

1:  $\text{Fe} \leftarrow \{a \in A : \text{element}(a) = \text{Fe}\}$ 
2:  $\text{S} \leftarrow \{a \in A : \text{element}(a) = \text{S}\}$ 
3: wenn  $|\text{Fe}| < 2$  oder  $|\text{S}| < 2$  then
4:   gib zurück  $\emptyset$  ▷ Kein Cluster möglich
5: ende wenn
6: Bilde alle Fe-Paare  $(f_i, f_j)$  mit  $\|\mathbf{r}(f_i) - \mathbf{r}(f_j)\| \leq c_{\text{FeFe}}$ 
7: Sortiere die Fe-Paare nach Distanz aufsteigend
8:  $\text{verwendet} \leftarrow \emptyset$  ▷ Set bereits zugeordneter Atome
9:  $\text{cluster\_list} \leftarrow \emptyset$ 
10: für alle Fe-Paare  $(f_i, f_j)$  in sortierter Reihenfolge tue
11:   wenn  $f_i \in \text{verwendet}$  oder  $f_j \in \text{verwendet}$  then
12:     weiter ▷ Atom schon einem Cluster zugeordnet
13:   ende wenn
14:    $\mathcal{S}_\mu \leftarrow \{s \in \text{S} : \text{S überbrückt } f_i, f_j \text{ mit } \|\mathbf{r}(s) - \mathbf{r}(f_i)\| \leq c_{\text{FeS}} \text{ und } \|\mathbf{r}(s) - \mathbf{r}(f_j)\| \leq c_{\text{FeS}}\}$ 
15:   wenn  $|\mathcal{S}_\mu| \geq 2$  then ▷ Genug Brückenschwefel?
16:      $(s_1, s_2) \leftarrow \text{die zwei nächsten S aus } \mathcal{S}_\mu$ 
17:      $\text{cluster\_list} \leftarrow \text{cluster\_list} \cup \{(f_i, f_j, s_1, s_2)\}$ 
18:      $\text{verwendet} \leftarrow \text{verwendet} \cup \{f_i, f_j, s_1, s_2\}$ 
19:   ende wenn
20: ende für
21: gib zurück  $\text{cluster\_list}$ 

```

**Algorithmus.**

**Subtilitäten in der Implementation.**

- Die Sortierung der Fe-Paare nach Distanz ist *deterministisch* und stellt sicher, dass das engste Cluster zuerst belegt wird. Damit ist `cluster_index = 0` immer das engste, ohne dass der Nutzer die Atom-Reihenfolge im Logfile berücksichtigen muss.
- Die Cutoffs  $c_{\text{FeFe}}$  und  $c_{\text{FeS}}$  sind Config-Parameter (Default 3.5 und 3.0 Å). Für sehr ausgedehnte Cluster (z. B. [4Fe-4S] oder Mo-Fe-Cofaktor) müssen diese ggf. erhöht werden – wobei das Tool dann nur noch das [2Fe-2S]-Substrukturteilstück liest.
- Wird ein Atom durch ein engeres Cluster bereits „verbraucht“, so wird es nicht nochmal in einem weiteren Cluster verwendet. Damit findet der Algorithmus auch in eng gepackten Multi-Cluster-Systemen die wahre Anzahl von Clustern.

## D.2 Cluster-Normale via SVD

Aus den vier Cluster-Atomen wird per Singulärwertzerlegung die Best-Fit-Ebene und damit die Cluster-Normale  $\hat{\mathbf{n}}$  bestimmt.

---

### Pseudocode 2 CLUSTERNORMALE

---

**Eingabe:** Cluster-Atome  $\mathcal{C} = \{a_1, a_2, a_3, a_4\}$  mit Positionen  $\mathbf{r}_1, \dots, \mathbf{r}_4 \in \mathbb{R}^3$

**Ausgabe:** Einheitsvektor  $\hat{\mathbf{n}}$  senkrecht zur Best-Fit-Ebene

```

1:  $\bar{\mathbf{r}} \leftarrow \frac{1}{4} \sum_{i=1}^4 \mathbf{r}_i$  ▷ Schwerpunkt
2: Konstruiere zentrierte Matrix  $\tilde{\mathbf{R}} \in \mathbb{R}^{4 \times 3}$ :  $\tilde{\mathbf{R}}_{i,:} = \mathbf{r}_i - \bar{\mathbf{r}}$ 
3:  $\mathbf{U}, \mathbf{\Sigma}, \mathbf{V}^\top \leftarrow \text{SVD}(\tilde{\mathbf{R}})$  ▷  $\mathbf{V}$  ist orthogonale  $3 \times 3$ -Matrix
4:  $\hat{\mathbf{n}} \leftarrow \mathbf{V}_{:,3}$  ▷ dritte Spalte = Richtung kleinster Varianz
5: wenn  $\hat{n}_z < 0$  then ▷ Vorzeichen-Konvention
6:    $\hat{\mathbf{n}} \leftarrow -\hat{\mathbf{n}}$ 
7: ende wenn
8: return  $\hat{\mathbf{n}}$ 

```

---

Bemerkung: das Faltungs-Residual ist  $\Sigma_{33}$  (kleinster Singulärwert). Werte  $> 0.1 \text{ \AA}$  deuten auf einen stark nicht-planaren Cluster hin – ungewöhnlich für native [2Fe-2S]-Cluster, aber möglich bei stark verzerrten Mutanten.

## D.3 Kabsch-Alignment (PDB $\leftrightarrow$ Gauss)

Wenn ein PDB-File mitgegeben wird, müssen die PDB-Koordinaten auf die Gaussian-Koordinaten gemappt werden – die Geometrien sind in der Regel rotationsverschoben. Der Kabsch-Algorithmus [17] liefert die optimale Rotation.

---

### Pseudocode 3 KABSCHALIGN

---

**Eingabe:** Punktmengen  $\mathbf{P}, \mathbf{Q} \in \mathbb{R}^{n \times 3}$ , korrespondierend (gleicher Atom-Reihenfolge)

**Ausgabe:** Rotation  $\mathbf{R}$ , Translation  $\mathbf{t}$ , RMSD

```

1:  $\bar{\mathbf{p}} \leftarrow \frac{1}{n} \sum_i \mathbf{P}_{i,:}$ ,  $\bar{\mathbf{q}} \leftarrow \frac{1}{n} \sum_i \mathbf{Q}_{i,:}$ 
2:  $\mathbf{P}' \leftarrow \mathbf{P} - \bar{\mathbf{p}}$ ,  $\mathbf{Q}' \leftarrow \mathbf{Q} - \bar{\mathbf{q}}$  ▷ Schwerpunkt jeweils auf Ursprung
3:  $\mathbf{H} \leftarrow \mathbf{P}'^\top \mathbf{Q}'$  ▷  $3 \times 3$ -Kreuzkorrelation
4:  $\mathbf{U}, \mathbf{\Sigma}, \mathbf{V}^\top \leftarrow \text{SVD}(\mathbf{H})$ 
5:  $d \leftarrow \text{sign}(\det(\mathbf{V}\mathbf{U}^\top))$  ▷ Reflektions-Vorzeichen
6:  $\mathbf{D} \leftarrow \text{diag}(1, 1, d)$ 
7:  $\mathbf{R} \leftarrow \mathbf{V}\mathbf{D}\mathbf{U}^\top$  ▷ Optimale Rotation
8:  $\mathbf{t} \leftarrow \bar{\mathbf{q}} - \mathbf{R}\bar{\mathbf{p}}$ 
9:  $\text{RMSD} \leftarrow \sqrt{\frac{1}{n} \|\mathbf{R}\mathbf{P}' - \mathbf{Q}'\|_F^2}$ 
10: return  $(\mathbf{R}, \mathbf{t}, \text{RMSD})$ 

```

---

**Was die D-Matrix tut.** Die „naive“ Lösung  $\mathbf{R} = \mathbf{V}\mathbf{U}^\top$  kann eine Reflektion sein (Determinante  $-1$ ), wenn die zwei Punktmengen chiral verschieden sind (z. B. versehentlich gespiegelt).

Die **D**-Matrix korrigiert das Vorzeichen der dritten Singulärvektor- Achse, sodass eine echte Rotation (Determinante +1) zurückgegeben wird. Bei korrekt korrespondierenden Punktmengen ist  $d = +1$ , also  $\mathbf{D} = \mathbf{I}$ .

#### D.4 Mode-Loop mit thermischer Skalierung

Der zentrale Loop des Tools: für jede Schwingungsmode wird der Eigenvektor gelesen, thermisch skaliert, und in die OOP/INP-, Reorg- und SCSD-Pipelines gespeist.

---

##### Pseudocode 4 ANALYZEMODE

---

**Eingabe:** Mode-Index  $i$ , Frequenz  $\omega_i$ , reduzierte Masse  $\mu_i$ , Temperatur  $T$ , Eigenvektor  $\mathbf{e}^{(i)}$  (mass-gewichtet, normalisiert), Cluster-Atome  $\mathcal{C}$ , Liganden  $\mathcal{L}$

**Ausgabe:** Result-Dict  $r$  mit OOP%,  $\Delta r_X$ ,  $\lambda_X$ , SCSD-Anteilen, Kern-Klassifikation

```

1:                                     ▷ 1. Thermische RMS-Amplitude (Quanten-Erwartungswert)
2:  $u_{\text{rms}}(i) \leftarrow \sqrt{\frac{\hbar}{2\mu_i\omega_i} \coth\left(\frac{\hbar\omega_i}{2k_B T}\right)}$ 
3:  $\mathbf{e}_a^{\text{therm}} \leftarrow \mathbf{e}_a^{(i)} \cdot u_{\text{rms}}(i) \quad \forall a \in \mathcal{C} \cup \mathcal{L}$ 
4:                                     ▷ 2. OOP/INP-Klassifikation
5:  $\mathbf{e}_a^{\text{OOP}} \leftarrow (\mathbf{e}_a^{\text{therm}} \cdot \hat{\mathbf{n}}) \hat{\mathbf{n}}$ 
6:  $\alpha_{\text{OOP}} \leftarrow 100 \cdot \frac{\sum_{a \in \mathcal{C}} \|\mathbf{e}_a^{\text{OOP}}\|^2}{\sum_{a \in \mathcal{C}} \|\mathbf{e}_a^{\text{therm}}\|^2}$ 
7:  $r.\text{oop\_pct} \leftarrow \alpha_{\text{OOP}}$ 
8:  $r.\text{type} \leftarrow \text{CLASSIFYOOP}(\alpha_{\text{OOP}}, \theta_{\text{OOP}} = 60)$ 
9:                                     ▷ 3. Bindungs-Modulationen
10: für alle Bindungs-Kanäle  $X \in \{\text{FeFe}, \text{FeN}, \text{FeS}, \text{NH}, \text{HA}\}$  tue
11:    $\Delta r_X(i) \leftarrow \text{COMPUTEBONDMODULATION}(X, \mathbf{e}^{\text{therm}}, \text{Geometrie})$                                      ▷ siehe §2.12
12:    $\lambda_X(i) \leftarrow \frac{1}{2}\mu_i\omega_i^2 (\Delta r_X(i))^2$ 
13: ende für
14:                                     ▷ 4. SCSD-Symmetriezerlegung (optional)
15: wenn cfg.analyze_scsd then
16:    $\text{VERSCHIEBUNG} \leftarrow \mathbf{e}^{\text{therm}}|_{\mathcal{C}}$                                      ▷ nur Cluster-Atome
17:    $\text{IRREP-ANTEILE} \leftarrow \text{PROJEKTOND2HIRREPS}(\text{VERSCHIEBUNG}, \text{Referenzgeometrie})$ 
18:    $r.\text{scsd} \leftarrow \text{IRREP-ANTEILE}$ 
19: ende wenn
20:                                     ▷ 5. Heuristische Kern-Klassifikation
21:  $r.\text{kern\_type} \leftarrow \text{CLASSIFYKERN}(\mathbf{e}^{\text{therm}}, \mathcal{C}, \alpha_{\text{OOP}})$ 
22: return  $r$ 

```

---

##### Subtilitäten:

- Bei `temp_k = None` entfällt die thermische Skalierung;  $u_{\text{rms}}$  wird durch `cfg.amplitude` (Default 1.0) ersetzt. Das ist der „klassische“ Modus, in dem alle Modes gleich gewichtet sind.

- Bei niedriger Frequenz und hoher Temperatur wird das Coth-Argument klein und  $u_{\text{rms}}$  groß – für Modes unter  $\sim 30 \text{ cm}^{-1}$  kann das in einem typischen Filter-Bereich Anteile  $> 50\%$  der Total-Reorg ergeben. Daher die Empfehlung: `freq_min` immer auf 50 oder 100 setzen, wenn Niederfrequenz-Skelett-Bewegungen unterdrückt werden sollen.
- Im „no-His“-Pfad (kein Histidin im Cluster) werden die Kanäle NH und HA *vor* der Reorg-Schleife auf null gesetzt – nicht erst durch  $\text{null-}\Delta r$ , sondern bereits durch den übergeordneten Aufruf in `runner.py`. Das spart Geometrie-Berechnungen und macht den Pfad deterministisch sauber.

## D.5 Reorg-Aggregation pro Mode

Pro Mode werden die Bindungs-Modulationen  $\Delta r_X$  aus den thermisch skalierten Eigenvektoren berechnet.

---

**Pseudocode 5** COMPUTEBONDMODULATION (FeFe-Beispiel)

---

**Eingabe:** Bindungs-Atome  $a, b$  (mit Positionen + thermisch skalierten Auslenkungen  $\mathbf{e}_a, \mathbf{e}_b$ )

**Ausgabe:** Bindungs-Modulation  $\Delta r$  (vorzeichenbehaftet)

```

1:  $\mathbf{r}_a^{\text{neu}} \leftarrow \mathbf{r}_a + \mathbf{e}_a$ 
2:  $\mathbf{r}_b^{\text{neu}} \leftarrow \mathbf{r}_b + \mathbf{e}_b$ 
3:  $r_{\text{neu}} \leftarrow \|\mathbf{r}_a^{\text{neu}} - \mathbf{r}_b^{\text{neu}}\|$ 
4:  $r_{\text{eq}} \leftarrow \|\mathbf{r}_a - \mathbf{r}_b\|$ 
5:  $\Delta r \leftarrow r_{\text{neu}} - r_{\text{eq}}$ 
6: return  $\Delta r$ 

```

---

Für Multi-Bond-Kanäle (z. B. FeS mit vier Fe-S-Bindungen) wird COMPUTEBONDMODULATION pro Bindung aufgerufen, und die Beiträge werden *vorzeichenfrei* per RSS aggregiert (§A):

$$\Delta r_X^{\text{rss}} = \sqrt{\sum_{(a,b) \in X} (\Delta r_{(a,b)})^2} \quad (56)$$

Damit ist der Kanal-Beitrag  $\lambda_X = \frac{1}{2}\mu\omega^2(\Delta r_X^{\text{rss}})^2$  identisch mit der Summe der Pair-Beiträge:

$$\lambda_X = \sum_{(a,b) \in X} \frac{1}{2}\mu\omega^2(\Delta r_{(a,b)})^2. \quad (57)$$

Diese Marcus-Hush-Additivität ist die zentrale Konsistenz-Bedingung und Smoke-Test (§4.5).

## D.6 HA-Reaktionskoordinaten-Berechnung

Der HA-Kanal misst die H-Akzeptor-Distanzmodulation entlang der Reaktionskoordinate (statt der naiven H-Akz-Distanz).

**Pseudocode 6** COMPUTEHAREACTIONCOORD**Eingabe:**  $N_{\text{Donor}}$ , H, Akzeptor A (Positionen + Auslenkungen)**Ausgabe:** Reaktions-Koordinaten-Modulation  $\Delta r_{\text{HA}}$ 

- 1:  $\hat{\mathbf{n}}_{N \rightarrow A} \leftarrow \frac{\mathbf{r}_A - \mathbf{r}_N}{\|\mathbf{r}_A - \mathbf{r}_N\|}$  ▷ Donor-Akzeptor-Achse, Einheitsvektor
- 2:  $\Delta \mathbf{e} \leftarrow \mathbf{e}_H - \mathbf{e}_N$  ▷ H-Bewegung relativ zum Donor
- 3:  $\Delta r_{\text{HA}} \leftarrow \Delta \mathbf{e} \cdot \hat{\mathbf{n}}_{N \rightarrow A}$  ▷ Projektion auf Reaktionskoordinate
- 4: **return**  $\Delta r_{\text{HA}}$

**Warum dieser Ansatz?** Die naive H-Akz-Distanz misst die *Gesamtbewegung* des H-Atoms relativ zum Akzeptor-Atom. Damit zeigen reine Skelett-Modes (in denen der ganze Komplex sich kollektiv bewegt) ein großes  $\Delta r$ , obwohl das Proton sich *relativ* zum Donor gar nicht bewegt – sie sind keine echten PCET-relevanten Modes. Die Reaktionskoordinaten-Konvention extrahiert nur die echte Protonen-Bewegung.

**D.7 Modulations-Spektrum und kumulative Reorg-Kurve**

Aus den pro-Mode-Werten werden frequenz aufgelöste Spektren gebaut.

**Pseudocode 7** MODULATIONSSPECTRUM**Eingabe:** Mode-Liste mit  $(\omega_i, \Delta r_X(i))$ , Verbreiterung  $\sigma$ , Frequenzraster  $\omega$ **Ausgabe:** Modulations-Spektrum  $M_X(\omega)$ 

- 1:  $M_X(\omega) \leftarrow 0 \quad \forall \omega \in \omega$
- 2: **für alle** Modes  $i$  **tue**
- 3:    $g_i(\omega) \leftarrow \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(\omega - \omega_i)^2}{2\sigma^2}\right)$
- 4:    $M_X(\omega) \leftarrow M_X(\omega) + |\Delta r_X(i)| \cdot g_i(\omega)$
- 5: **ende für**
- 6: **return**  $M_X(\omega)$

**Pseudocode 8** KUMULATIVE REORG**Eingabe:** Mode-Liste mit  $(\omega_i, \lambda_X(i))$ , sortiert aufsteigend nach  $\omega$ **Ausgabe:** Kumulative Kurve  $\Lambda_X(\omega)$ 

- 1:  $\Lambda \leftarrow 0$
- 2: **für alle** Modes  $i$  (sortiert aufsteigend) **tue**
- 3:   Schreibe  $(\omega_i^-, \Lambda)$  und  $(\omega_i^+, \Lambda + \lambda_X(i))$  ▷ Stufenfunktion: Sprung an  $\omega_i$
- 4:    $\Lambda \leftarrow \Lambda + \lambda_X(i)$
- 5: **ende für**
- 6: Schreibe Endwert  $(\omega_{\text{max}}, \Lambda)$
- 7: **return**  $\Lambda_X(\omega)$

Beide Spektren sind im Sheet `Modulations_Spektren` bzw. `Lambda_kumulativ` ausgegeben (§5).



## D.8 HDBSCAN-Clusterung des Embeddings

Nach der UMAP-Projektion auf 2D werden die Punkte mit HDBSCAN [38] dichtebasiert geclustert.

---

### Pseudocode 9 HDBSCANCLUSTER

---

**Eingabe:** 2D-Embedding-Punkte  $\{x_1, \dots, x_N\}$ , `min_cluster_size`, `min_samples`

**Ausgabe:** Cluster-Labels  $\ell_1, \dots, \ell_N \in \{-1, 0, 1, \dots\}$  (-1 = Rauschen)

```

1:           ▷ 1. Gewichteter Graph: jeder Punkt hat Distanz zu seinen K nächsten Nachbarn
2: core_dist(xi) ← Distanz zum min_samples-ten Nachbarn
3: mutual_reachability(xi, xj) ← max(core_dist(xi), core_dist(xj), ||xi - xj||)
4:           ▷ 2. Minimum-Spanning-Tree der mutual_reachability-Matrix
5: MST ← KRUSKALMST(mutual_reachability)
6:           ▷ 3. Hierarchischer Cluster-Baum
7: Tree ← CONVERTMSTTOHIERARCHY(MST)
8:           ▷ 4. Stabile Cluster auswählen (Excess of Mass)
9: cluster_list ← EXCESSOFMASSSELECTION(Tree, min_cluster_size)
10:          ▷ 5. Punkte den Clustern zuweisen oder als Rauschen markieren
11: für alle Punkte  $x_i$  tue
12:   wenn  $x_i$  ist Mitglied eines stabilen Clusters  $C_k$  then
13:      $\ell_i \leftarrow k$ 
14:   sonst
15:      $\ell_i \leftarrow -1$            ▷ Rauschen
16:   ende wenn
17: ende für
18: return  $\ell$ 

```

---

### Warum HDBSCAN statt DBSCAN?

- HDBSCAN braucht keine globale  $\epsilon$ -Schwelle (DBSCAN braucht eine – die ist bei verschiedener Cluster-Dichte problematisch).
- HDBSCAN findet Cluster verschiedener Dichte automatisch (durch die hierarchische Konstruktion).
- HDBSCAN ist robust gegen Outlier (sie landen automatisch im Rauschen, ohne dass eine Schwelle angepasst werden muss).

In der Standard-Konfiguration verwendet das Tool `min_cluster_size = 8` und `min_samples = 5`; siehe §2.8 für die Begründung.

## E Excel-Sheet-Vollreferenz

Pro Lauf entstehen bis zu *vier* Excel-Workbooks. Dieser Anhang dokumentiert jede Spalte jedes Sheets, sodass Tabellenwerte ohne Rückgriff auf den Code interpretierbar sind. Sheet-Namen, die in `export.py` per `wb.create_sheet(...)` erzeugt werden, sind hier in der gleichen Reihenfolge gelistet.

### E.1 Hauptauswertungs-Workbook (\*\_analysis.xlsx)

Enthält 16 Sheets mit allen modenbezogenen Auswertungen, Cluster- Geometrie und SCSD-Symmetriezerlegung. Pflicht-Sheet für jede Veröffentlichung.

#### Modenanalyse – Mode-by-mode Detail-Tabelle

Eine Zeile pro Schwingungsmode (typisch 60–800 Modes je nach `freq_max`-Filter). 32 Spalten:

| Spalte     | Einheit          | Bedeutung                                                                         |
|------------|------------------|-----------------------------------------------------------------------------------|
| Modus #    | –                | Mode-Index aus dem Logfile (1-basiert)                                            |
| Frequenz   | $\text{cm}^{-1}$ | Frequenz $\omega_i$                                                               |
| u_rms      | Å                | Thermische RMS-Amplitude<br>$\sqrt{\hbar/(2\mu\omega) \coth(\hbar\omega/2k_B T)}$ |
| Red.Masse  | AMU              | Reduzierte Masse $\mu_i$                                                          |
| Frc.Const. | mdyn/Å           | Kraftkonstante                                                                    |
| Sym.       | –                | Mulliken-Symbol aus Gaussian (z. B. A, B <sub>g</sub> )                           |
| Typ        | –                | OOP/INP-Klassifikation (binär, Schwelle 60 %)                                     |
| Typ (fein) | –                | 7-stufige OOP/INP-Klassifikation                                                  |
| Praez.     | –                | HP/Std-Eigenvektor-Quelle                                                         |
| Lig OOP%   | %                | OOP-Anteil der Mode auf Liganden-Sphäre                                           |
| ±sigma     | %                | Bootstrap-Streuung der Schätzung                                                  |
| Lig INP%   | %                | INP-Anteil auf Liganden                                                           |
| ±sigma     | %                | Streuung                                                                          |
| Lig  d     | Å                | Liganden-Auslenkung (Norm der Verschiebung)                                       |
| ±sigma     | Å                | Streuung                                                                          |
| 2nd OOP%   | %                | wie Lig OOP% für 2. Liganden-Sphäre (z. B. Backbone-N)                            |
| ±sigma     | %                | Streuung                                                                          |
| 2nd INP%   | %                | 2. Liganden-Sphäre INP                                                            |
| ±sigma     | %                | Streuung                                                                          |
| 2nd  d     | Å                | 2. Liganden-Sphäre Auslenkung                                                     |

Spalten 21–32 (nicht oben gelistet) enthalten Kern-Anteile (Kern OOP%, Kern INP%, etc.) sowie OOP/INP- Anteile der einzelnen Cluster-Atome (Fe<sub>1</sub>, Fe<sub>2</sub>, S<sub>1</sub>, S<sub>2</sub>).

**Gruppen\_OOP, \_INP, \_Winkel, \_Tors**

Vier separate Sheets, jeweils eine Zeile pro Mode + Spalte pro Liganden-Gruppe (Cys<sub>n</sub>, His<sub>n</sub>, etc.). Werte sind die OOP/INP- Anteile bzw. Bind-Winkel pro Gruppe. Nutzbar für die Liganden-spezifische Analyse einer einzelnen Mode.

**Fe\_S\_Cys und Fe\_N\_His**

Pro Fe-Liganden-Bindung (z. B. Fe1-Cys72-S, Fe2-Cys83-S, etc.) eine eigene Spalte. Eine Zeile pro Mode, Inhalt:

- **stretch**: Anteil der Mode-Bewegung entlang der Bindungsachse.
- **bend\_inp**: In-plane-Bend-Anteil (in Cluster-Ebene).
- **bend\_oop**: OOP-Bend-Anteil (senkrecht zur Cluster- Ebene).

Diese Sheets sind die Datenquelle für die Mode-Loop-Aggregation (§2.12); sie zeigen, wie eine einzelne Mode auf jede Fe-Liganden-Bindung wirkt.

**Kern\_Scores – Heuristische Cluster-Zerlegung**

Eine Zeile pro Mode, 10 Spalten mit den heuristischen Cluster-Score- Funktionen aus §2.6:

- Translation, Umbrella, Hinge-Fe, Hinge-S: Cluster-Bewegungs-Klassen.
- OOP-Twist, Fe-Streckung, S-Streckung, Breathing, Rhombus-Scherung, Rotation-ip: Sechs in-plane / OOP-Bewegungsmodi.

**Wichtiger Hinweis im Sheet-Header:** Die Kern-Scores sind *heuristische geometrische Projektionen*, summieren sich i. A. nicht zu 1, und sind nicht-orthogonal. Für eine **rigorose Symmetriezerlegung** verweist das Sheet auf SCSD (siehe unten).

**Abstaende\_Gleichgewicht**

Tabelle der Gleichgewichts-Bindungslängen aller relevanten Cluster- und Liganden-Bindungen. Eine Zeile pro Bindung. Spalten: Bindungs-Bezeichnung, Distanz in Å, Atom-Indizes.

**Coordination – Liganden- und Gruppen-Atomzuordnung (seit v1.0.3)**

Diagnose-Sheet, das die PDB-zu-Gaussian-Atomzuordnungen offenlegt, die alle nachfolgenden Analysen verwenden. Drei Blöcke, durch Leerzeilen getrennt:

- **Liganden**: eine Zeile pro Fe-koordinierendem Liganden (LigandInfo in geometry.py). Spalten: **label** (z. B. “Cys 207”), **element** (S/N/O), **fe\_center** (1-basierter Gaussian-Center des gebundenen Fe), **lig\_center** (Gaussian-Center des Donor-Atoms), **bond\_len\_A**,

**his\_protonated** (Boolean), **h\_center** (Gaussian-Center des Imidazol-NH-H, falls vorhanden), **his\_hn\_center** (das Donor-N, das dieses H trägt, NE2 oder ND1).

- **Gruppen (group\_map)**: eine Zeile pro Atomgruppe, die in den Groups\_OOP/INP/Winkel/Tors-Blättern verwendet wird. Spalten: **group** (Bezeichnung), **centers** (kommagetrennte Liste 1-basierter Gaussian-Centers).
- **Cluster-Atome**: ein 4-Zeilen-Block mit Fe<sub>1</sub>, Fe<sub>2</sub>, S<sub>1</sub>, S<sub>2</sub>, ihren Gaussian-Centers und der Gleichgewichts-(*x, y, z*) in Å.

Dieses Sheet ist die erste Anlaufstelle, wenn eine Excel-Zeile unerwartet leer aussieht: eine leere **centers**-Liste oder ein fehlendes **h\_center** erklärt eine nachgelagerte Null-Zeile in den Groups\_\*, Fe\_\*- oder His\_HN-Blättern (§2.3).

### SCSD – Rigorose D<sub>2h</sub>-Symmetriezerlegung

Pro Mode 8 Spalten für die Anteile auf die D<sub>2h</sub>-Irreps: *A<sub>g</sub>, B<sub>1g</sub>, B<sub>2g</sub>, B<sub>3g</sub>, A<sub>u</sub>, B<sub>1u</sub>, B<sub>2u</sub>, B<sub>3u</sub>*. Werte in % des Cluster-Mode-Beitrags. Im Gegensatz zu **Kern\_Scores** sind diese Werte *orthogonal* und summieren sich exakt zu 100 %.

Methode: Kingsbury & Senge (Chem. Sci. 15, 13638, 2024) mit kanonischer D<sub>2h</sub>-Referenz (Fe-Fe=2.73 Å, Fe-S=2.20 Å, Achsen *x*=Fe-Fe, *y*=S-S, *z*=Normale).

### Reorganisationsenergie

Hauptsheet für die Reorg-Pipeline. Eine Zeile pro Mode, 21 Spalten:

| Spalte                                                             | Einheit          | Bedeutung                                            |
|--------------------------------------------------------------------|------------------|------------------------------------------------------|
| freq_cm1                                                           | cm <sup>-1</sup> | Mode-Frequenz                                        |
| dr_FeFe_rss_a                                                      | Å                | RSS-Aggregat der Fe-Fe-Modulation                    |
| dr_FeFe_sum_signed_a                                               | Å                | Signed-Sum-Aggregat (kann negativ sein)              |
| lambda_FeFe_pair_cm1                                               | cm <sup>-1</sup> | Reorg pro Bindungspaar (Sub-Aufschlüsselung)         |
| lambda_FeFe_mode_cm1                                               | cm <sup>-1</sup> | Reorg pro Mode (Aggregat über alle Pairs des Kanals) |
| <i>Wiederholt für Kanäle: FeN, FeS, NH, HA (jeweils 4 Spalten)</i> |                  |                                                      |

**Konvention:** **rss** (Root-Sum-Squared) ist immer positiv und macht die Marcus-Hush-Additivität exakt (§D.5). **sum\_signed** ist die vorzeichenfreie Summe über alle Bindungs-Modulationen des Kanals; sie zeigt, ob die Bindungs-Modulationen kohärent (Sum ≈ rss) oder inkohärent (Sum ≪ rss) sind.

**Mode-vs-Pair-Konvention:** **lambda\_X\_pair** = einzelne Bindungspaar-Beiträge summiert; **lambda\_X\_mode** = mit  $\mu_i \omega_i^2$ -Gewichtung pro Mode aggregiert. Beide sind erhalten für unterschiedliche Auswertungs-Zwecke.

### Reorg\_Total – System-Aggregate pro Kanal

Vier Zeilen (eine pro Kanal: FeFe, FeN, FeS, NH, HA – 5 Zeilen total). Spalten:

- Kanal: Bezeichnung des Bindungs-Kanals.
- Lambda\_total\_pair\_cm1:  $\Lambda_X^{\text{total}}$  aus Pair-Aggregation.
- Lambda\_total\_mode\_cm1:  $\Lambda_X^{\text{total}}$  aus Mode-Aggregation.
- n\_modes\_contributing: Anzahl Modes mit nicht-trivialem Beitrag ( $\lambda_X(i) > 10^{-6} \text{ cm}^{-1}$ ).

Dies sind die zentralen *publikationsfertigen Werte* der Reorg-Pipeline.

### Reorg\_pro\_Bindung – Aufschlüsselung pro einzelner Bindung

Eine Zeile pro Einzel-Bindung (z. B. Fe1-Cys72-S, Fe1-Fe2, Fe1-S<sub>b</sub>1, etc.). Sechs Spalten:

- Bindung: Bindungs-Bezeichnung.
- Parent\_Kanal: zu welchem Kanal (FeFe, FeS, FeN, ...) die Bindung gehört.
- Akzeptor\_Gewicht: für HA-Kanal das Gauss-Gewicht des H-Akzeptor-Pairs (Default 1.0 für Hauptakzeptor).
- Lambda\_total\_pair\_cm1, Lambda\_total\_mode\_cm1: wie in Reorg\_Total, aber pro Bindung.
- n\_modes\_contributing: Modes mit Beitrag  $> 10^{-6} \text{ cm}^{-1}$ .

Erlaubt die Frage zu beantworten: *Welche einzelne Fe-S-Bindung trägt am meisten zu  $\Lambda_{\text{FeS}}$  bei?*

### Modulations\_Spektren

Frequenz aufgelöste Modulations-Spektren  $M_X(\omega)$ , plus Co-Spektren für PCET-Analyse. Eine Zeile pro Frequenz-Rasterpunkt (Default:  $0.5 \text{ cm}^{-1}$  Schritt). 8 Spalten:

- freq\_cm1: Frequenz-Rasterpunkt.
- M\_FeFe, M\_FeN, M\_FeS, M\_NH, M\_HA: Modulations- Spektren  $M_X(\omega) = \sum_i |\Delta r_X(i)| \cdot \mathcal{N}(\omega - \omega_i, \sigma)$  mit Default  $\sigma = 5 \text{ cm}^{-1}$ .
- C\_ET\_FeS: Co-Spektrum  $\sqrt{M_{\text{FeFe}}(\omega) \cdot M_{\text{FeS}}(\omega)}$  – markiert Frequenzregionen, in denen FeFe und FeS gleichzeitig moduliert werden. Hoch-Indikator für ET-relevante Cluster-Atmungs-Modes.
- C\_PCET: Co-Spektrum  $\sqrt{M_{\text{NH}}(\omega) \cdot M_{\text{HA}}(\omega)}$  – markiert PCET-relevante Modes (gleichzeitige N-H- und H-Akzeptor-Modulation).

**Lambda\_kumulativ**

Kumulative Reorg-Kurven  $\Lambda_X(\omega) = \sum_{\omega_i \leq \omega} \lambda_X(i)$ . Eine Zeile pro Frequenz-Rasterpunkt. 6 Spalten: `freq_cm1`, `Lambda_FeFe`, `Lambda_FeN`, `Lambda_FeS`, `Lambda_NH`, `Lambda_HA`.

Jede Spalte ist eine **monotone Stufenfunktion**: Sprünge markieren Modes mit  $\lambda_X$ -Beitrag. Direkt mit NRVS-Spektrum überlagerbar für Bandenidentifikation.

**B\_Faktoren**

Pro Atom: thermische B-Faktoren  $B_a = \frac{8\pi^2}{3} \langle u_a^2 \rangle$  aus der QHO-Mittelung über alle Modes. Spalten: Atom-Index, Element, B-Faktor in  $\text{\AA}^2$ .

**Info**

Pro-Lauf-Metadaten: Logfile-Pfad, Anzahl Modes, Frequenz-Range, Cluster-Geometrie, Liganden-Liste, Konfigurations-Parameter. Volltext-Beschreibung des Laufs in einem Sheet.

**E.2 Embeddings-Workbook (\*\_analysis\_Embeddings.xlsx)**

Enthält die UMAP-Projektionen und HDBSCAN-Clusterungen. Das Workbook beherbergt *drei* parallele Einbettungen derselben Mode-Menge, jede in ihrem eigenen Paar von `*_clusters-` / `*_profile`-Sheets, plus die pro-Mode-Roh- $C_\alpha$ -Amplituden-Matrix als Eingabe für das Ca-UMAP.

**Projektionen**

Globale UMAP. Eine Zeile pro Mode, Spalten: `Modus #`, `Frequenz`, `UMAP_x`, `UMAP_y`. Berechnet auf der vollen Feature-Matrix aus `embedding.build_feature_matrix` (Marcus-Hush-Reorg-Features + Bindungs-Modulations-Features + Kernel-Scores). Direkt plotbar als 2D-Embedding.

**Ca\_Amplituden**

Pro Mode und pro  $C_\alpha$ -Residuum: die thermisch skalierte  $\|e\|$ -Amplitude des Rückgrat- $\alpha$ -Kohlenstoffs des Residuums. Verwendet als Feature-Matrix für das Ca-UMAP (siehe unten). Format: Zeilen = Modes, Spalten = Residuennummern.

**Cluster / Cluster\_Profil**

Globale UMAP-Cluster-Zuordnungen. `Cluster` hat eine Zeile pro Mode mit ihrer HDBSCAN-Cluster-ID (`cluster_label`: -1 = Rauschen; 0, 1, ... = Cluster-Index), Distanz zum Cluster-Zentrum, und allen Feature-Werten. `Cluster_Profil` hat eine Zeile pro HDBSCAN-Cluster mit dem mittleren Feature-Vektor, Fisher-F-Statistik pro Feature, und einer geordneten Liste repräsentativer Modes (nächster zum Zentrum).

**SSE\_UMAP\_clusters / SSE\_UMAP\_profile (seit v1.0.3)**

Sekundärstruktur-UMAP, beschränkt auf Modes, die mindestens einen nicht-null Eintrag in der pro-SSE-Element-Feature-Zeile haben (`sse`-Dict nach `analyze_all_sse` nicht leer). Nützlich zur Identifikation kollektiver Protein-Rückgrat-Modes, die mehrere Sekundärstrukturen gleichzeitig anregen. Das \*\_clusters-Sheet listet Modes mit ihren SSE-UMAP-Koordinaten und HDBSCAN-Cluster-ID; das \*\_profile-Sheet gibt das Z-Score-Profil der diskriminierenden Top-30-SSE-Elemente pro Cluster aus.

**Ca\_UMAP\_clusters / Ca\_UMAP\_profile (seit v1.0.3)**

$C_\alpha$ -Amplituden-UMAP. Jede Mode wird als Punkt in einem  $N_{C_\alpha}$ -dimensionalen Raum dargestellt, eine Dimension pro Rückgrat- $\alpha$ -Kohlenstoff (die Spalten von `Ca_Amplituden`). Features werden vor UMAP pro Residuum z-skaliert, sodass kein einzelnes hochamplitudisches Residuum die Embedding-Distanz dominiert.

Konzeptionell beantworten die drei UMAPs komplementäre Fragen:

- *Globales UMAP (Projektionen)*: Welche Modes koppeln an dieselben Reorg-Kanäle (Fe-X, NH, HA)? Nützlich zur Identifikation ET-aktiver bzw. PCET-aktiver Modes.
- *SSE-UMAP (SSE\_UMAP\_\*)*: Welche Modes haben denselben Sekundärstruktur-Fußabdruck? Nützlich zur Identifikation domänenkollektiver Modes.
- *Ca-UMAP (Ca\_UMAP\_\*)*: Welche Modes haben ähnliche räumliche Verteilungen der Rückgrat-Bewegung? Nützlich zur Identifikation langreichweitiger allosterischer Pfade und auf bestimmte Protein-Regionen lokalisierter Modes.

Begleitende PNGs (nur wenn `cfg.export_embedding_plots = true`): `_embedding_UMAP.png` (2 Panele), `_embedding_SSE_UMAP.png` (3 Panele: Frequenz / Mode-Typ / Cluster), `_embedding_Ca_UMAP.png` (3 Panele), und `_ca_amplitudes_heatmap.png` (log-skalierte Residuum  $\times$  Frequenz Heatmap der  $C_\alpha$ -Amplituden).

**E.3 Interpoliertes-pDOS-Workbook (\*\_analysis\_interp0.05.xlsx)**

Ein einziges Sheet `Interpoliert` mit der pDOS-Auswertung auf einem feinen Frequenzraster (Default  $0.05 \text{ cm}^{-1}$ ). Spalten: `freq_cm1`, `pDOS_Fe1`, `pDOS_Fe2`, `pDOS_S1`, `pDOS_S2`, `pDOS_total`. Verwendet für den direkten NRVs-Spektrums-Vergleich.

**E.4 Sekundärstruktur-Workbook (\*\_analysis\_SSE.xlsx, optional)**

Wird nur erzeugt, wenn ein PDB-File mit (oder DSSP-extrahierten) Sekundärstruktur-Records mitgeliefert wird. Enthält typischerweise 9–11 Sheets, je nach SSE-Komplexität:

### Pro-SSE-Element-Sheets (SSE\_\*)

Pro SSE-Metrik ein eigenes Sheet: `SSE_amplitude_mean`, `SSE_amplitude_max`, `SSE_com_amplitude` (Schwerpunkts-Amplitude), `SSE_lateral_std` (laterale Bewegungs-Streuung), `SSE_lateral_amplitude`, `SSE_stretching` (axiale Längen-Änderung), `SSE_axial_amplitude`, `SSE_tilting_angle` (Helix-Tilt), `SSE_internal_amplitude` (interne Bewegung).

Jedes Sheet hat eine Zeile pro Mode + Spalte pro SSE-Element.

### SSE\_UMAP\_Cluster und SSE\_UMAP\_Profil

Wie `UMAP_Cluster` und `UMAP_Cluster_Profil`, aber auf der SSE-Feature-Matrix (statt der Cluster-Liganden-Matrix). Findet strukturelle Cluster der Modes basierend auf ihrer Wirkung auf Sekundärstruktur-Elemente.

**Welche Sheets sind Pflicht für eine Veroeffentlichung?** Für eine Reorg-Manuskript-Tabelle reichen typisch `Reorg_Total` und `Reorg_pro_Bindung` (Hauptauswertung). Für die Bandenzuordnung kommt `Lambda_kumulativ` dazu (NRVS- Überlagerung). Für die Mode-Charakterisierung das Sheet `Modenanalyse` und (bei symmetrie-relevanten Fragen) `SCSD`. Der Rest dient internen Diagnose-Zwecken.

## Literatur

- [1] C. J. Kingsbury, M. O. Senge, *Quantifying near-symmetric molecular distortion using symmetry-coordinate structural decomposition*, **Chem. Sci.** **15**, 13638–13649 (2024). DOI: 10.1039/D4SC01670J. Web-Implementation: <https://www.kingsbury.id.au/scsd>.
- [2] C. J. Kingsbury, M. O. Senge, *Quantifying near-symmetric molecular distortion using symmetry-coordinate structural decomposition*, ChemRxiv preprint, doi:10.26434/chemrxiv-2024-6b25s (2024).
- [3] S. Iwata, M. Saynovits, T. A. Link, H. Michel, *Structure of a water soluble fragment of the ‘Rieske’ iron-sulfur protein of the bovine heart mitochondrial cytochrome bc<sub>1</sub> complex determined by MAD phasing at 1.5 Å resolution*, **Structure** **4**, 567–579 (1996).
- [4] P. Sauer, M. Heyden, *Frequency-selective anharmonic mode analysis of thermally excited vibrations in proteins*, **J. Chem. Phys.** (2023).
- [5] K. Achterhold, F. G. Parak, *Protein dynamics: determination of anisotropic vibrations at the heme iron of myoglobin*, **J. Phys.: Condens. Matter** **14**, S1399–S1421 (2002).
- [6] H. Paulsen, H. Winkler, A. X. Trautwein *et al.*, *Measurement and simulation of nuclear inelastic-scattering spectra of molecular crystals*, **Phys. Rev. B** **59**, 975 (1999).



- [7] L. B. Gee, V. Pelmenschikov, C. Mons, N. Mishra, H. Wang, Y. Yoda, K. Tamasaku, M.-P. Golinelli-Cohen, S. P. Cramer, *NRVS and DFT of mitoNEET: Understanding the special vibrational structure of a [2Fe–2S] cluster with (Cys)<sub>3</sub>(His)<sub>1</sub> ligation*, **Biochemistry** **60**, 2419–2424 (2021). DOI: 10.1021/acs.biochem.1c00252.
- [8] A. R. Conlan, M. L. Paddock, C. Homer *et al.*, *Mutation of the His ligand in mitoNEET stabilizes the 2Fe–2S cluster despite conformational heterogeneity in the ligand environment*, **Acta Cryst. F** **67**, 516–523 (2011).
- [9] N. Go, T. Noguti, T. Nishikawa, *Dynamics of a small globular protein in terms of low-frequency vibrational modes*, **Proc. Natl. Acad. Sci. USA** **80**, 3696 (1983).
- [10] F. Parak, E. W. Knapp, *A consistent picture of protein dynamics*, **Proc. Natl. Acad. Sci. USA** **81**, 7088 (1984).
- [11] E. B. Wilson, J. C. Decius, P. C. Cross, *Molecular Vibrations: The Theory of Infrared and Raman Vibrational Spectra*, McGraw-Hill, New York (1955); Dover Reprint (1980).
- [12] W. Sturhahn, *Nuclear resonant spectroscopy*, **J. Phys.: Condens. Matter** **16**, S497–S530 (2004).
- [13] W. Sturhahn, A. Chumakov, *Lamb-Mössbauer factor and second-order Doppler shift from inelastic nuclear resonant absorption*, **Hyperfine Interact.** **123/124**, 809–824 (2000).
- [14] H. J. Lipkin, *Mössbauer sum rules for use with synchrotron sources*, **Phys. Rev. B** **52**, 10073–10079 (1995).
- [15] K. S. Singwi, A. Sjölander, *Resonance absorption of nuclear gamma rays and the dynamics of atomic motions*, **Phys. Rev.** **120**, 1093–1102 (1960).
- [16] V. G. Kohn, A. I. Chumakov, R. Rüffer, *Nuclear resonant inelastic absorption of synchrotron radiation in an anisotropic single crystal*, **Phys. Rev. B** **58**, 8437–8444 (1998).
- [17] W. Kabsch, *A solution for the best rotation to relate two sets of vectors*, **Acta Cryst. A** **32**, 922–923 (1976).
- [18] S. Hammes-Schiffer, A. A. Stuchebrukhov, *Theory of coupled electron and proton transfer reactions*, **Chem. Rev.** **110**, 6939–6960 (2010).
- [19] R. A. Marcus, *On the Theory of Oxidation-Reduction Reactions Involving Electron Transfer. I*, **J. Chem. Phys.** **24**, 966–978 (1956). DOI: 10.1063/1.1742723.
- [20] R. A. Marcus, *Electron transfer reactions in chemistry. Theory and experiment (Nobel Lecture)*, **Angew. Chem. Int. Ed. Engl.** **32**, 1111–1121 (1993). DOI: 10.1002/anie.199311113.
- [21] R. A. Marcus, N. Sutin, *Electron transfers in chemistry and biology*, **Biochim. Biophys. Acta** **811**, 265–322 (1985).

- [22] W. Sturhahn, V. G. Kohn, *Theoretical aspects of incoherent nuclear resonant scattering*, **Hyperfine Interact.** **123/124**, 367–377 (1999).
- [23] A. I. Chumakov, W. Sturhahn, *Experimental aspects of inelastic nuclear resonant scattering*, **Hyperfine Interact.** **123/124**, 781–808 (1999).
- [24] A. A. Maradudin, P. A. Flinn, *Anharmonic contributions to the Debye-Waller factor*, **Phys. Rev.** **129**, 2529 (1963).
- [25] H. J. Lipkin, *Some simple features of the Mößbauer effect*, **Ann. Phys.** (N.Y.) **9**, 332 (1960).
- [26] M. Y. Hu, W. Sturhahn, T. S. Toellner *et al.*, *Measuring velocity of sound with nuclear resonant inelastic X-ray scattering*, **Phys. Rev. B** **67**, 094304 (2003).
- [27] B. M. Leu, M. Z. Hu, J. Zhao, S. P. Cramer, *Quantitative vibrational dynamics of iron in carbonyl compounds*, **J. Am. Soc. Mass Spectrom.** **17**, 235 (2008).
- [28] P. Thompson, D. E. Cox, J. B. Hastings, *Rietveld refinement of Debye-Scherrer synchrotron X-ray data from  $\text{Al}_2\text{O}_3$* , **J. Appl. Crystallogr.** **20**, 79 (1987).
- [29] K. Achterhold, F. G. Parak, *ina32.f – Fortran source code for analysis of nuclear inelastic scattering spectra*; interne Publikation, TU München, Abteilung Biophysik (2005–).
- [30] E. Tiesinga, P. J. Mohr, D. B. Newell, B. N. Taylor, *CODATA recommended values of the fundamental physical constants: 2018*, **Rev. Mod. Phys.** **93**, 025010 (2021).
- [31] K. Pearson, *On lines and planes of closest fit to systems of points in space*, **Philos. Mag.** **2**, 559–572 (1901).
- [32] H. Hotelling, *Analysis of a complex of statistical variables into principal components*, **J. Educ. Psychol.** **24**, 417–441 (1933).
- [33] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed., Springer (2002).
- [34] L. van der Maaten, G. Hinton, *Visualizing data using t-SNE*, **J. Mach. Learn. Res.** **9**, 2579–2605 (2008).
- [35] L. van der Maaten, *Accelerating t-SNE using tree-based algorithms*, **J. Mach. Learn. Res.** **15**, 3221–3245 (2014).
- [36] L. McInnes, J. Healy, J. Melville, *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*, **arXiv** 1802.03426 (2018).
- [37] E. Becht, L. McInnes, J. Healy *et al.*, *Dimensionality reduction for visualizing single-cell data using UMAP*, **Nat. Biotechnol.** **37**, 38–44 (2019).
- [38] R. J. G. B. Campello, D. Moulavi, J. Sander, *Density-based clustering based on hierarchical density estimates*, in **Adv. Knowl. Discov. Data Min.** (PAKDD 2013), pp. 160–172.

- [39] L. McInnes, J. Healy, S. Astels, *hdbscan: Hierarchical density based clustering*, **J. Open Source Softw.** **2**, 205 (2017).
- [40] S. Hammes-Schiffer, *Theory of proton-coupled electron transfer in energy conversion processes*, **Acc. Chem. Res.** **42**, 1881–1889 (2009). DOI: 10.1021/ar9001284.
- [41] S. J. Edwards, A. V. Soudackov, S. Hammes-Schiffer, *Driving force dependence of rates for nonadiabatic proton and proton-coupled electron transfer: Conditions for inverted region behavior*, **J. Phys. Chem. B** **113**, 14545–14548 (2009).
- [42] J. P. Layfield, S. Hammes-Schiffer, *Hydrogen tunneling in enzymes and biomimetic models*, **Chem. Rev.** **114**, 3466–3494 (2014).
- [43] Q. Cui, M. Karplus, *Allostery and cooperativity revisited*, **Protein Sci.** **17**, 1295–1307 (2008).
- [44] M. Bergner, S. Dechert, S. Demeshko, C. Kupper, J. M. Mayer, F. Meyer, *Model of the MitoNEET [2Fe-2S] cluster shows proton coupled electron transfer*, **J. Am. Chem. Soc.** **139**, 701–707 (2017). DOI: 10.1021/jacs.6b09180.
- [45] D. Kuila, J. R. Schoonover, R. B. Dyer, C. J. Batie, D. P. Ballou, J. A. Fee, W. H. Woodruff, *Resonance Raman studies of Rieske-type proteins*, **Biochim. Biophys. Acta** **1140**, 175–183 (1992).
- [46] H. Wang, V. Pelmeshnikov, Y. Yoda, S. P. Cramer, *NRVS of Fe-S cluster proteins and models – A bestiary of nifty normal modes*, **J. Inorg. Biochem.** **270**, 112935 (2025). DOI: 10.1016/j.jinorgbio.2025.112935.
- [47] J. A. Zuris, D. A. Halim, A. R. Conlan *et al.*, *Engineering the redox potential over a wide range within a new class of FeS proteins*, **J. Am. Chem. Soc.** **132**, 13120–13122 (2010).
- [48] T. Kuroda, S. Hammes-Schiffer, *Vibronic coupling for proton-coupled electron transfer reactions: Recent insights from theory*, **Curr. Opin. Electrochem.** **29**, 100789 (2021).
- [49] S. Hammes-Schiffer, A. V. Soudackov, *Proton-coupled electron transfer in solution, proteins, and electrochemistry*, **J. Phys. Chem. B** **112**, 14108–14123 (2008).
- [50] K. Huang, A. Rhys, *Theory of light absorption and non-radiative transitions in F-centres*, **Proc. R. Soc. Lond. A** **204**, 406–423 (1950).
- [51] H. Beinert, R. H. Holm, E. Münck, *Iron-sulfur clusters: nature’s modular, multipurpose structures*, **Science** **277**, 653–659 (1997).
- [52] S. Han, R. S. Czernuszewicz, T. G. Spiro, *Vibrational spectra and normal mode analysis for [2Fe-2S] protein analogs using sulfur-34, iron-54 and deuterium substitution: coupling of iron-sulfur stretching and sulfur-carbon-carbon bending modes*, **J. Am. Chem. Soc.** **111**, 3496–3504 (1989).

- [53] R. S. Czernuszewicz, J. LeGall, I. Moura, T. G. Spiro, *Resonance Raman spectra of rubredoxin: new assignments and vibrational coupling mechanism from iron-54/iron-56 isotope shifts and variable-wavelength excitation*, **Inorg. Chem.** **25**, 696–700 (1986).
- [54] U. Bergmann, W. Sturhahn, D. E. Linn, F. E. Jenney, M. W. W. Adams, K. Rupnik, B. J. Hales, E. E. Alp, A. Mayse, S. P. Cramer, *Observation of Fe-H/D modes by nuclear resonant vibrational spectroscopy*, **J. Am. Chem. Soc.** **125**, 4016–4017 (2003).
- [55] C. T. Saouma, M. M. Pinney, J. M. Mayer, *Electron transfer and proton-coupled electron transfer reactivity and self-exchange of synthetic [2Fe-2S] complexes: Models for Rieske and mitoNEET clusters*, **Inorg. Chem.** **53**, 3153–3161 (2014).
- [56] A. Albers, S. Demeshko, S. Dechert, C. T. Saouma, J. M. Mayer, F. Meyer, *Fast proton-coupled electron transfer observed for a high-fidelity structural and functional [2Fe-2S] Rieske model*, **J. Am. Chem. Soc.** **136**, 3946–3954 (2014).
- [57] S. J. Cyvin, *Molecular Vibrations and Mean Square Amplitudes*, Universitetsforlaget, Oslo / Elsevier, Amsterdam (1968).
- [58] J. W. Ochterski, *Vibrational Analysis in Gaussian*, Gaussian, Inc., White Paper (1999). <https://gaussian.com/vib/>
- [59] M. J. Frisch *et al.*, *Gaussian 16, Revision C.01*, Gaussian, Inc., Wallingford CT (2016).
- [60] F. Neese, *The ORCA program system: user’s manual*, Version 6.0, Max-Planck-Institut für Kohlenforschung, Mülheim a. d. Ruhr (2023). <https://www.faccts.de/docs/orca/6.0/manual/>
- [61] F. Neese, *Software update: The ORCA program system—Version 5.0*, **WIREs Comput. Mol. Sci.** **12**, e1606 (2022).